O aprendizado de máquina realmente supera o modelo clínico? Um estudo de caso com plano prévio na colangite biliar primária

Autoria omitida para revisão

[1]Afiliação omitida para revisão

Abstract. *ML models for health should be judged by what they add to the available clinical model. In a case study with a prior plan, we compared, pairwise and on the same folds, random survival forests (RSF) with 5 or 17 variables and a 17-variable penalized Cox with a re-estimated five-variable Mayo Cox model in 418 patients with primary biliary cholangitis (death or transplant within five years). No model outperformed the reference in Uno's C (*0.831*; differences* -0.014 *to* $+0.015$*). A 0.02 gain was ruled out only for the five-variable RSF; for the other two, the cohort lacks precision to decide. In later analyses, no model beat the 1989 Mayo formula, and evaluating the RSF on its training data raised its C by* 0.043*, more than any difference between models.*

Resumo. *Modelos de aprendizado de máquina devem ser julgados pelo que acrescentam ao modelo clínico. Num estudo de caso com plano prévio, comparamos, em pares, nas mesmas partições, random survival forests (RSF) com 5 ou 17 variáveis e um Cox penalizado com 17 a um Cox reestimado com as cinco variáveis de Mayo, em 418 pacientes com colangite biliar primária (óbito ou transplante em cinco anos). Nenhum superou a referência no C de Uno (*0,831*; diferenças de* $-0{,}014$ *a* $+0{,}015$*). Um ganho de 0,02 só foi descartado na RSF de 5 variáveis; para os outros dois, faltou precisão. Em análises posteriores, nenhum superou a fórmula de Mayo de 1989, e avaliar a RSF no próprio treino elevou seu C em* 0,043*, mais que qualquer diferença entre modelos.*

1. Introdução

Um modelo de aprendizado de máquina (AM) para a saúde costuma ser apresentado pelo seu desempenho isolado. A pergunta de quem decide adotá-lo é outra: ele acrescenta algo ao modelo que a clínica já usa? A lacuna é sentida na própria comunidade: um trabalho recente do SBCAS aponta, como limitação, não ter comparado seus modelos com as abordagens clínicas em uso, o que impede medir o ganho incremental do AM [Lodi et al. 2026]. Este artigo faz essa comparação num caso clássico e separa o que se pode e o que não se pode concluir dela.

A colangite biliar primária (CBP, antes chamada de cirrose biliar primária) é uma doença hepática autoimune e crônica que pode evoluir para cirrose e transplante. Em 1989, o modelo de Mayo, uma regressão de Cox [Cox 1972] com cinco variáveis de rotina (idade, bilirrubina, albumina, tempo de protrombina e edema), selecionadas em dois ensaios clínicos da Mayo Clinic [Dickson et al. 1989b], tornou-se a referência clássica para estimar o risco que orienta o acompanhamento e o encaminhamento ao transplante. Os dados desses ensaios são públicos e viraram um conjunto clássico, em análise

Tabela 1. Cuidados de avaliação: o erro que cada um evita e onde aparece neste artigo.

Passo	Erro que evita	Neste artigo
1. Registrar plano, margem e regra de leitura antes dos resultados	Escolher métrica, modelo ou critério após ver os números	Seção 3.1
2. Comparar com o modelo clínico disponível, em pares, nas mesmas partições	Creditar ao AM o que o modelo atual já faz	Tabela 3
3. Tratar a censura como sobrevivência, sem excluir pacientes pelo horizonte	Amostra selecionada pelo próprio desfecho	Seções 3.4 e 4.4
4. Avaliar calibração e benefício líquido, não só a discriminação	Modelo que ordena bem, mas erra o risco ou não muda decisões	Figura 1
5. Testar variáveis indisponíveis no momento da predição	Vazamento que infla o desempenho	Tabela 4 (classificação)

de sobrevivência [Fleming and Harrington 1991] e em AM, do artigo que propôs a RSF [Ishwaran et al. 2008] ao repositório da UCI [Dickson et al. 1989a] e a uma competição do Kaggle [Reade and Chow 2023].

Por que voltar a esses dados hoje? Porque conclusões otimistas continuam a ser publicadas sobre eles: trabalhos de 2025 relatam acurácias próximas de 90% em dados sintéticos derivados da coorte, para outros desfechos [Shakir et al. 2025, Tu 2025], e um estudo de 2026 relatou vantagem pontual de uma RSF sobre um Cox nos 312 pacientes randomizados [Graf et al. 2026]. Duas coisas dificultam uma comparação justa nesse conjunto: o enquadramento (tratar o problema como classificação, excluir os censurados antes do horizonte ou usar o tempo de seguimento como entrada, o que vaza o desfecho [Kapoor and Narayanan 2023]) e a flexibilidade de análise (escolher métrica, modelos e critérios depois de ver os resultados). No Brasil, onde o SUS financia a maior parte dos transplantes de fígado [Agência Gov 2025] e um modelo de IA de apoio à decisão clínica é software dispositivo médico sujeito a validação [Brasil. Agência Nacional de Vigilância Sanitária 2022], a pergunta interessa à alocação de recursos e à regulação, impactos que este trabalho não avalia.

Usamos essa coorte como estudo de caso de avaliação, com uma pergunta prática: um serviço que já estima o risco com as cinco variáveis de Mayo ganharia algo ao trocar o Cox por uma floresta, ou por um modelo com os 17 exames de linha de base? Comparamos, em pares, nas mesmas partições e sob um plano registrado antes dos resultados de sobrevivência, RSF e Cox penalizado com um Cox reestimado com as cinco variáveis de Mayo, na predição de óbito ou transplante em cinco anos. Não propomos algoritmo nem escore para uso clínico atual. O artigo separa três leituras que se confundem quando se diz que o AM "supera" ou "não supera" um modelo clínico: ganho não demonstrado, ganho relevante descartado e ganho aparente produzido pela forma de avaliar. As contribuições são empíricas: (i) a reavaliação pareada, com os 418 pacientes e as mesmas partições, da vantagem relatada para a RSF nesta coorte [Graf et al. 2026], contra o modelo clínico reestimado e, em análise posterior, contra a fórmula publicada em 1989; (ii) a medida, nos mesmos dados, de quanto cada escolha de avaliação muda o resultado (Tabela 4); e (iii) plano, desvios, código e resultados públicos. Os cinco cuidados da Tabela 1 são boas práticas conhecidas, não um método novo.

2. Trabalhos relacionados

Depois do modelo de Mayo [Dickson et al. 1989b], a adoção do ácido ursodesoxicólico levou a outros escores de Cox, para pacientes tratados, como o GLOBE [Lammers et al. 2015] e o UK-PBC [Carbone et al. 2016], construídos com exames medidos após um ano de tratamento, para outro momento e outra população.

O trabalho mais próximo é o de [Graf et al. 2026], que compara Cox e RSF nos 312 pacientes randomizados, com um Cox de variáveis escolhidas por critérios de informação (e não as cinco de Mayo), C de Harrell e *bootstrap* .632+, com intervalos por modelo e nenhum para a diferença. A RSF teve valores pontuais melhores (C de 0,855 contra 0,776), com intervalos sobrepostos, exceto em uma de seis regras de divisão, cujo intervalo exclui o C pontual do Cox.

Os trabalhos recentes de AM sobre esse conjunto seguem o enquadramento da competição do Kaggle, com dados sintéticos gerados a partir do original [Reade and Chow 2023]: classificam o desfecho em três classes ou em óbito sem horizonte [Shakir et al. 2025, Tu 2025]. No próprio SBCAS, trabalhos recentes mediram a inflação de desempenho causada por vazamento proposital, com dados do SUS [Pereira et al. 2026], e avaliaram a calibração ao prever óbito por febre amarela [Lodi et al. 2026]. No levantamento feito, não se encontrou estudo que compare, nos mesmos pacientes e partições e sob plano prévio, AM de sobrevivência com o modelo de Mayo.

3. Materiais e métodos

3.1. O plano prévio, seus limites e a reprodutibilidade

O relato segue o TRIPOD+AI [Collins et al. 2024], sem verificação formal de todos os itens. O plano de análise (desfechos, modelos, métricas, comparações e regra de leitura) foi registrado em 01/11/2026 no controle de versões do repositório, antes dos resultados da análise de sobrevivência, e não foi alterado. Três limites devem ficar claros. O registro é um *commit* no repositório da autoria, verificável pela cronologia pública, e não um registro independente. O plano foi escrito depois de uma análise de classificação nos mesmos dados (Seção 3.6): é prospectivo para a sobrevivência, não anterior a toda exploração. E tudo o que mudou depois está registrado como desvio, com data e motivo: são dezessete. O principal veio de uma auditoria por outro agente de IA, sem permissão para alterar o repositório: na primeira execução, as florestas eram ajustadas com uma saída de risco diferente da avaliada; o procedimento foi corrigido e a análise repetida. Os outros dezesseis acrescentam análises, sem mudar as previstas: um anterior a qualquer resultado, seis da mesma auditoria, antes da execução final, e nove posteriores aos resultados finais, entre eles a regra de leitura mais exigente usada no resumo e na conclusão (Seção 3.5), as sementes extras e o plano complementar (Seção 3.6). Ficaram aquém do plano a AUC do subgrupo, sem intervalo pareado, e a importância por permutação, só na primeira repetição. O experimento usa Python 3.13 e scikit-survival 0.28.0 [Pölsterl 2020]; versões, sementes e manifestos estão no suplementar. Os dados são públicos e anonimizados. Código, dados, plano, desvios, cronologia, resultados e auditorias estão em repositório público, anonimizado para a revisão (`https://anonymous.4open.science/r/ml4health-sbcas`).

3.2. Dados e desfechos

A coorte foi escolhida por ser pública e muito usada como referência para o AM, não por representar os pacientes atuais. O conjunto é o da Mayo Clinic, distribuído pela UCI (identificador 878) [Dickson et al. 1989a] e pelo pacote `survival` do R. São 418 pacientes recrutados entre 1974 e 1984: 312 participaram de dois ensaios randomizados sobre D-penicilamina, e 106 eram elegíveis mas recusaram a randomização, tendo só as medidas de rotina [Dickson et al. 1989b, Fleming and Harrington 1991].

O **desfecho principal** é a sobrevida livre de transplante: o evento é óbito ou transplante (186 pacientes, sendo 161 óbitos e 25 transplantes), e os 232 pacientes sem evento registrado até o último acompanhamento são censurados nesse momento. Não houve cálculo prévio de tamanho amostral; a precisão alcançada aparece na largura dos intervalos. O seguimento mediano foi de 7,0 anos (Kaplan-Meier reverso), e o horizonte de interesse é de cinco anos, com 132 eventos até ele. Como **sensibilidade**, o evento é só o óbito, e o transplante é tratado como censura (161 eventos). Os preditores são as 5 variáveis de Mayo ou as 17 de linha de base. As 12 adicionais são sexo, tratamento atribuído, achados de exame físico, exames laboratoriais e estágio histológico, que exige biópsia. Nove delas só foram medidas nos ensaios e faltam em todos os 106 não randomizados; 276 pacientes têm as 17 completas, e as cinco de Mayo faltam em apenas 2. A coorte tem 374 mulheres e idade mediana de 51 anos. O tempo de seguimento nunca é preditor: só se conhece após o desfecho.

3.3. Modelos e o alcance da comparação

O desenho é 2×2. A **referência** é um Cox de riscos proporcionais com as cinco variáveis de Mayo, nas mesmas transformações do modelo original (logaritmo de bilirrubina, albumina e protrombina), reestimado no treino de cada partição; não é a fórmula publicada em 1989, e "Cox de Mayo" designa aqui esse modelo reestimado. Com as 17 variáveis, o Cox é penalizado por *elastic net* [Simon et al. 2011], que encolhe ou zera coeficientes para evitar o sobreajuste. Os modelos de AM são RSF [Ishwaran et al. 2008], florestas de 300 árvores de sobrevivência, com 5 e com 17 variáveis. Os hiperparâmetros são buscados em 50 configurações por floresta e 40 para o Cox penalizado. Imputação e padronização são aprendidas só no treino de cada partição (grades no suplementar).

A comparação não é equilibrada. As variáveis e transformações de Mayo foram escolhidas em 1989 nos mesmos 312 pacientes randomizados desta coorte, o que favorece a referência; nove das variáveis extras, inclusive o tratamento, faltam nos 106 não randomizados e foram imputadas, o que desfavorece os modelos de 17 variáveis. Disso decorre o alcance da comparação. Ela responde à pergunta de adoção da Introdução, com a imputação que os dados reais exigem. Não responde se florestas superam Cox em condições iguais, nem se as 12 variáveis extras carregam informação que outro desenho capturaria: um empate aqui é compatível com as duas hipóteses. A pergunta do plano sobre a origem de um eventual ganho ficou, por isso, sem resposta (desvio D13).

3.4. Validação e métricas

A validação é cruzada, com 5 repetições de 5 partições estratificadas pelo evento, as mesmas para os quatro modelos, e os hiperparâmetros são escolhidos dentro do treino de cada partição (validação aninhada) [Varma and Simon 2006]. Cada modelo produz,

para cada paciente, o risco previsto de ter o evento em até cinco anos; a predição fora da partição é a média das 5 repetições, o que pode estreitar os intervalos.

Um paciente censurado saiu do acompanhamento sem evento; as métricas, próprias para sobrevivência, ponderam os pacientes pela chance de continuarem em acompanhamento. A **métrica principal** é o C de Uno em cinco anos [Uno et al. 2011]. Como a AUC, ele mede ordenação: tome dois pacientes em que se sabe quem teve o evento primeiro; o C é a fração desses pares em que o modelo deu risco maior a esse paciente (0,5 é o acaso; 1, a ordenação perfeita). Diferente do C de Harrell [Harrell et al. 1982], ele repondera os pares pela probabilidade de censura, evitando o viés da censura intensa. As secundárias são a AUC em cinco anos [Uno et al. 2007] e o escore de Brier em cinco anos e integrado de 1 a 5 anos [Graf et al. 1999], o erro quadrático da probabilidade prevista (menor é melhor). Um modelo é **calibrado** quando, entre pacientes com risco previsto de 20%, cerca de 20% têm o evento; comparamos, por quintis, o risco previsto com o observado por Kaplan-Meier e resumimos a coorte pela razão observado/esperado (O/E). A **utilidade clínica** é medida por curva de decisão [Vickers et al. 2008]: para a decisão hipotética de intensificar o acompanhamento quando o risco passa de um limiar entre 5% e 50%, o benefício líquido desconta dos verdadeiros positivos os falsos positivos, com o peso que o limiar lhes dá.

3.5. Como se lê uma diferença entre modelos

Cada modelo é comparado à referência nos mesmos 418 pacientes: em 2.000 reamostragens *bootstrap* pareadas, calcula-se a diferença de C de Uno entre os dois, e os intervalos são ajustados para as três comparações (Bonferroni, 98,3%). Por usar as predições agregadas, a diferença não é a subtração das médias da Tabela 2. O plano fixou duas regras. Uma diferença só é demonstrada quando o intervalo exclui zero. E, se o limite superior ficar abaixo da **margem de +0,02** no C de Uno, ganhos dessa magnitude são descartados; a margem é um critério de leitura do estudo, não um limiar clínico validado. Esse *bootstrap* reamostra pacientes: captura a incerteza de quem está na coorte, mas não a de retreinar o modelo em outra partição. Para cobrir essa segunda fonte, depois de conhecidos os resultados, acrescentamos o teste t corrigido para validação cruzada repetida [Nadeau and Bengio 2003] sobre as diferenças nas 25 partições (desvio D11), e passamos a declarar descartado um ganho de 0,02 só quando os dois métodos o descartam. A leitura só pelo plano continua relatada.

3.6. Análises complementares

Quatro análises apoiam a principal e estavam no plano. **Subgrupo fora do treino:** treino nos 312 pacientes randomizados e teste nos 106 não randomizados (42 eventos); com 17 variáveis é um teste de transporte, não uma validação externa, porque nove delas faltam em todos os 106 e são imputadas. **Pressupostos da referência:** razões de risco e teste de riscos proporcionais [Grambsch and Therneau 1994] de um Cox descritivo nos 418, com o *lifelines* [Davidson-Pilon 2019]. **Importância por permutação** da RSF de 17 variáveis: quanto o C de Uno cai no teste quando os valores de uma variável são embaralhados. **Classificação**, anterior ao plano: óbito em cinco anos sem os censurados antes desse prazo (regressão logística com 5 variáveis contra regressão penalizada, *random forest* e XGBoost) e XGBoost com e sem o tempo de seguimento na entrada.

Tabela 2. Desempenho, desfecho principal (418 pacientes; 186 eventos no seguimento, 132 até cinco anos): média (desvio) nas 25 partições; O/E (IC 95%) nas predições agregadas.

Modelo	C de Uno	AUC 5 anos	Brier 5 anos	Brier integr.	O/E 5 anos
Cox, 5 var. (referência)	0,833 (0,029)	0,889 (0,031)	0,128 (0,021)	0,102 (0,009)	0,99 (0,87 a 1,10)
Cox penalizado, 17 var.	0,846 (0,024)	0,903 (0,028)	0,132 (0,018)	0,104 (0,008)	0,93 (0,82 a 1,03)
RSF, 5 var.	0,821 (0,034)	0,869 (0,039)	0,143 (0,019)	0,107 (0,009)	0,99 (0,87 a 1,10)
RSF, 17 var.	0,832 (0,028)	0,886 (0,031)	0,135 (0,015)	0,104 (0,008)	0,99 (0,88 a 1,11)

Duas análises vieram de um **plano complementar**, registrado antes de ser executado, mas depois dos resultados principais; devem ser lidas como posteriores. Primeira, a **fórmula de Mayo de 1989**, com os coeficientes publicados e sem reajuste, entra como segunda referência na discriminação. Das duas versões publicadas, a final, de uso clínico, foi estimada nos 418 e é usada na coorte inteira, onde é avaliada nos pacientes em que foi estimada, o que a favorece; a inicial, estimada nos 312, é usada nos 106, que nunca viu. Essa análise não é cega: um cálculo exploratório já era conhecido ao registrá-la. Segunda, as **fontes de ganho aparente**, nos 312 randomizados: um Cox com as sete variáveis do conjunto final de [Graf et al. 2026] contra o Cox de Mayo, e a avaliação de cada modelo nos próprios pacientes de treino. Após auditoria da primeira execução, o procedimento foi emendado e reexecutado; a métrica prevista para o otimismo era o C de Harrell (0,041 na RSF), e o artigo relata o C de Uno (0,043), a métrica principal.

4. Resultados

4.1. Discriminação: a resposta para cada modelo

Nenhum modelo apresentou superioridade demonstrada na discriminação (Tabelas 2 e 3). A referência alcançou C de Uno de 0,831 nas predições agregadas (média de 0,833 entre as 25 partições). As diferenças dos três modelos para ela ficaram entre $-0{,}014$ e +0,015, e nenhum intervalo do C de Uno excluiu zero, em nenhuma das duas inferências. A segunda pergunta, se um ganho de 0,02 pode ser descartado, tem resposta diferente para cada modelo. Para a RSF de 5 variáveis, sim: os dois limites superiores ficaram abaixo da margem. Para a RSF de 17, o limite do plano (0,0197) ficou colado à margem: no teste corrigido chegou a 0,024 e, em 25 sementes diferentes do *bootstrap*, passou de 0,02 em 10; tratamos esse caso como inconclusivo. Para o Cox penalizado, o modelo de maior C (+0,015), não: os limites superiores, 0,032 e 0,038, passam da margem. Essa divisão decorre da precisão alcançada: a meia-largura dos intervalos pareados ficou entre 0,018 e 0,021 pelo plano e entre 0,023 e 0,026 pelo teste corrigido, a própria ordem da margem; com 132 eventos até cinco anos, um ganho de 0,02 só poderia ser descartado para um modelo com estimativa negativa. Na sensibilidade só com óbito (suplementar), o padrão se repete: nenhuma diferença demonstrada (diferenças de $-0{,}013$ a +0,010) e ganho de 0,02 descartado só para a RSF de 5 variáveis (limites de 0,003 e 0,006; nos outros dois, ao menos um limite acima da margem). Na AUC em cinco anos, a RSF de 5 variáveis ficou abaixo da referência só no *bootstrap* ($-0{,}024$; $-0{,}047$ a $-0{,}001$); as demais não diferiram no desfecho principal.

Tabela 3. Valor incremental no C de Uno em cinco anos (predições agregadas, desfecho principal): modelo menos referência (C de 0,831; fórmula de 1989 [Dickson et al. 1989b], avaliada onde foi estimada, 0,831). IC de Bonferroni para as três comparações de AM (98,3%) pelo *bootstrap* do plano e pelo teste corrigido (centrado na média por partição); a linha com * é uma comparação à parte, com IC 95%. Intervalo que cruza zero: nenhuma diferença demonstrada. Limite superior abaixo de 0,02 nos dois intervalos: ganho dessa ordem descartado ("só no plano": apenas o *bootstrap* o descarta).

Comparação	ΔC	IC, plano	IC, teste corrigido	Ganho de 0,02 descartado?
Contra o Cox de Mayo reestimado (referência do plano)				
Cox penalizado, 17 var.	0,015	−0,0042 a 0,0324	−0,012 a 0,038	não
RSF, 5 var.	−0,014	−0,0323 a 0,0042	−0,036 a 0,011	sim
RSF, 17 var.	−0,001	−0,0220 a 0,0197	−0,027 a 0,024	não (só no plano)
Contra a fórmula de 1989 sem reajuste (análise posterior)				
Cox, 5 var. (reestimado)*	0,001	−0,0054 a 0,0066	−0,007 a 0,010	sim
Cox penalizado, 17 var.	0,016	−0,0046 a 0,0357	−0,017 a 0,046	não
RSF, 5 var.	−0,013	−0,0367 a 0,0089	−0,041 a 0,019	sim
RSF, 17 var.	0,000	−0,0249 a 0,0237	−0,031 a 0,031	não

4.2. Calibração e utilidade clínica

Calibração e benefício líquido, avaliados de forma descritiva, não mostraram vantagem do AM. A razão O/E ficou próxima de 1 em todos os modelos (0,93 a 0,99), mas esse resumo global esconde erros locais. Nos quintis (Figura 1, esquerda; os quatro modelos estão no suplementar), os desvios da referência ficaram dentro dos intervalos, e a RSF de 17 variáveis subestimou o risco no quintil mais alto (0,712 contra 0,808), no limite do intervalo. O desvio mais nítido foi o do Cox penalizado, o modelo de maior C: superestimou o risco nos dois quintis mais baixos e o subestimou no mais alto, fora dos intervalos. No Brier, as três alternativas tiveram erro maior que a referência, de modo mais nítido na RSF de 5 variáveis (Tabela 2). Na curva de decisão (Figura 1, direita), as curvas da referência e da RSF de 17 variáveis quase se sobrepõem entre 5% e 50% de risco, e ambas ficam acima de tratar todos e de não tratar ninguém. A maior distância entre elas, 1,5 verdadeiro positivo líquido por 100 pacientes no limiar de 26%, favoreceu a referência; a RSF ficou à frente, por menos, em 29 dos 46 limiares. Sem intervalo para essa diferença, a figura não permite afirmar utilidade igual.

4.3. Contra a fórmula de 1989 e fora do treino (análises posteriores)

Contra a fórmula de 1989 sem reajuste (último bloco da Tabela 3), o quadro do desfecho principal se repete: o Cox reestimado ficou praticamente igual a ela (0,001), e nenhum modelo de AM mostrou ganho demonstrado, embora a fórmula seja avaliada nos pacientes em que foi estimada, favorecimento pequeno (Tabela 4). No desfecho só óbito, para o qual a fórmula foi derivada, ela ficou nominalmente à frente do Cox reestimado (C de 0,855 contra 0,850; diferença de −0,005, com intervalo do *bootstrap* sem zero, de −0,008 a −0,002, e do teste corrigido com zero, até 0,001), e a RSF de 5 variáveis ficou abaixo dela só no *bootstrap* (−0,018; −0,036 a −0,002; teste corrigido até 0,002), um indício, não uma demonstração; os outros dois modelos não diferiram dela, e em nenhum desfecho houve ganho de AM sobre a fórmula.

Nos 106 pacientes não randomizados, que nenhum modelo viu no treino, o C de

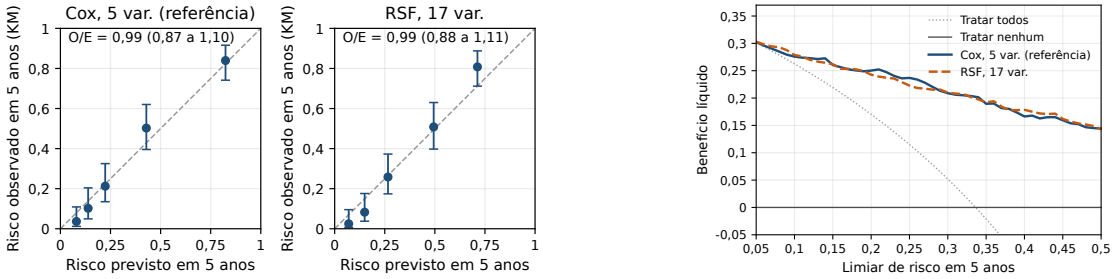


Figura 1. Esquerda: calibração em cinco anos por quintis de risco previsto (predições fora da partição), na referência e na RSF de maior C de Uno médio, regra fixada após a primeira execução, que introduz seleção; barras: IC 95% do Kaplan-Meier. Direita: curva de decisão em cinco anos, com censura tratada por Kaplan-Meier, para a referência e a mesma RSF, cuja curva pode ser otimista pela seleção.

Uno foi de 0,790 (0,718 a 0,857) na referência, 0,806 no Cox penalizado, 0,797 na RSF de 5 variáveis, 0,807 na de 17 e 0,782 na fórmula inicial de 1989, que também não os viu. Os modelos de 17 variáveis ficaram nominalmente à frente (até +0,016 contra o Cox reestimado e até +0,024 contra a fórmula inicial), sem nenhuma diferença demonstrada nas comparações pareadas, com 42 eventos. O ajuste descritivo da referência (suplementar) deu evidência contra a proporcionalidade dos riscos para o tempo de protrombina (impacto preditivo não quantificado); não detectá-la nas demais não prova que valha. Na importância por permutação da RSF de 17 variáveis (figura no suplementar), a bilirrubina dominou (queda de 0,128 no C de Uno), seguida de longe por cobre (0,019) e albumina (0,007); da quarta posição em diante, a ordem está dentro do desvio entre partições.

4.4. De onde vêm os ganhos aparentes?

Algumas escolhas de avaliação produzem ganho sem que o modelo melhore. A Tabela 4 mede, nestes dados, o efeito de cada uma e separa as que mudaram o resultado das que não mudaram. Entre os contrastes em C de Uno, o maior foi avaliar o modelo nos próprios pacientes do treino: nos 312 randomizados, o C da RSF de 17 variáveis subiu 0,043, mais que qualquer diferença entre modelos da Tabela 3, medidas nos 418; o do Cox de Mayo subiu 0,007. Usar o tempo de seguimento como entrada, um vazamento, elevou a AUROC macro de um XGBoost em 0,034, em outra tarefa e métrica, na análise de classificação anterior ao plano. Já avaliar a fórmula de 1989 nos pacientes em que foi estimada, ou trocar as variáveis do comparador pelas de [Graf et al. 2026], mudou o C em poucos milésimos; a primeira dessas linhas muda também o modelo, e por isso não isola o efeito de avaliar na amostra de derivação. Na classificação de óbito em cinco anos, sem os censurados antes disso, o melhor AM tampouco mostrou superioridade (AUROC +0,009; intervalo de Bonferroni para 5 comparações, $-0{,}017$ a 0,035).

5. Discussão

A resposta à pergunta do título é “não demonstrado”, e não “não supera”. Nas duas inferências, nenhum modelo teve ganho demonstrado sobre o Cox de Mayo reestimado, no desfecho principal nem na sensibilidade só com óbito; em análise posterior, tampouco sobre a fórmula de 1989. Mas o estudo só descarta um ganho de 0,02 para a RSF de 5

Tabela 4. Escolhas de avaliação medidas nestes dados. No primeiro bloco, cada linha muda só a condição indicada; no segundo, a linha da fórmula muda também o modelo. Entre parênteses, IC 95% pareado ou contagem de partições; métricas e amostras diferem, e os efeitos não se somam.

Fonte	Comparação	Métrica	Efeito
Fontes de ganho aparente (sem intervalo pareado)			
Avaliar no próprio treino	RSF, 17 var.: no próprio treino contra fora da partição (312)	C de Uno	+0,043
	Cox de Mayo: idem (312)	C de Uno	+0,007
Vazamento do desfecho	XGBoost, 17 var., com e sem o tempo de seguimento (418; classificação)	AUROC macro	+0,034 (24 de 25 partições)
Escolhas que pouco mudaram o resultado (IC 95% pareado)			
Fórmula avaliada onde foi estimada (muda também o modelo)	Fórmula de 1989 (estimada nos 312) contra Cox de Mayo ajustado só nos 312, fora da partição	C de Uno	+0,005 (−0,001 a 0,011)
Outras variáveis no comparador	Cox com as 7 variáveis de Graf et al. contra Cox de Mayo (312)	C de Uno	+0,001 (−0,012 a 0,013)
Sensibilidade da inferência (não é ganho)			
Sorteio do *bootstrap*	Limite superior do IC da RSF, 17 var., em 25 sementes (418)	C de Uno	0,0188 a 0,0212; acima de 0,02 em 10

variáveis; para o Cox penalizado e a RSF de 17 variáveis, a resposta é "não sabemos". Essa divisão é parte do resultado e decorre do tamanho do estudo: com 132 eventos até cinco anos (186 no seguimento todo), a meia-largura dos intervalos ficou na ordem da margem (Seção 4.1). Pela regra só do plano, a RSF de 17 variáveis também teria o ganho descartado; a regra combinada, posterior, endurece a leitura em vez de afrouxá-la. Como o desenho favorece a referência (Seção 3.3), um resultado nulo era o mais provável, e não o tratamos como prova de equivalência; ele vale para o cenário de adoção descrito, não como veredito sobre famílias de algoritmos, e é compatível, em sentido geral, com [Christodoulou et al. 2019].

Para além do caso, o trabalho quantifica, nos mesmos dados, quais escolhas de avaliação importam e quais não. Avaliar no próprio treino e deixar o tempo de seguimento entrar como preditor mudaram o resultado; reestimar a fórmula, trocar as variáveis do comparador ou sortear outra semente, não (Tabela 4). O ganho aparente de avaliar no treino foi medido nos 312 e as diferenças entre modelos nos 418, e [Graf et al. 2026] não avalia no próprio treino: usa *bootstrap* .632+, um estimador com correção de otimismo, e o otimismo medido aqui não explica o C de 0,855 daquele trabalho. O que a medida mostra é a ordem de grandeza do erro quando esse cuidado falta.

O contraste com [Graf et al. 2026] é instrutivo. Nos mesmos 312 randomizados e com as partições deste estudo, um Cox com as sete variáveis do conjunto final daquele trabalho teve C de Harrell de 0,819, praticamente igual ao do Cox de Mayo (0,817) e ao da RSF de 17 variáveis (0,819); o 0,776 relatado lá vem de outro protocolo (seguimento completo, *bootstrap* .632+) e de um modelo que o texto não identifica, e não é diretamente comparável. Com comparação pareada fora da amostra, a vantagem da RSF não aparece nestes dados. As acurácias próximas de 90% em dados sintéticos derivados da coorte [Shakir et al. 2025, Tu 2025] tampouco são comparáveis (outro desfecho, ou-

tros dados), e procedimentos descritos nesses trabalhos, como balanceamento antes da divisão e teste nos pacientes que geraram os dados de treino, podem produzir vazamento [Kapoor and Narayanan 2023].

Limitações. Os dados vêm de um único centro, de 1974 a 1984, antes do ácido ursodesoxicólico, e não representam os pacientes atuais; não houve coorte externa. A ponderação pela censura supõe censura independente dos preditores, não verificada. Na sensibilidade com óbito, censurar os transplantados não dá a probabilidade observável de morrer antes de um transplante, que exigiria riscos competitivos [Putter et al. 2007]. O desenho não é equilibrado (Seção 3.3). A comparação com a fórmula de 1989, a medida das fontes de ganho aparente e a regra de leitura combinada são posteriores aos resultados, e a primeira não é cega. Por fim, a conclusão vale para os modelos e grades avaliados; na sobrevivência, não testamos *boosting* nem redes neurais.

6. Conclusão

Na coorte pública da Mayo Clinic, sob plano registrado antes dos resultados de sobrevivência, nem a RSF nem o Cox penalizado mostraram ganho sobre o Cox reestimado com as cinco variáveis de Mayo na predição de óbito ou transplante em cinco anos. O estudo responde "não" para a RSF de 5 variáveis, cujo ganho de 0,02 no C de Uno foi descartado, e "não sabemos" para os outros dois: a coorte é pequena demais para decidir a margem escolhida, e essa distinção é parte do resultado, que vale para um cenário de adoção que favorece a referência e penaliza os modelos de 17 variáveis pela imputação. Em análises posteriores ao plano, nenhum modelo superou a fórmula publicada em 1989, e avaliar a floresta no próprio treino produziu um ganho aparente maior que qualquer diferença entre modelos. A lição é de método: julgar o ganho do AM contra o modelo clínico pertinente à população e ao momento da predição, fora da amostra de treino, com a incerteza explícita e sem variáveis que vazem o desfecho. A continuidade natural é repetir a pergunta em coortes atuais de pacientes tratados, contra GLOBE e UK-PBC e com riscos competitivos.

Declaração de uso de inteligência artificial generativa

Ferramentas de IA generativa foram usadas sob supervisão da autoria, que definiu a pergunta, o desenho, o plano de análise e a regra de leitura, decidiu cada desvio e interpretou os resultados. O Claude (Anthropic) apoiou a escrita do código, a execução dos experimentos e a redação. O Codex (OpenAI) auditou código e conclusões sem permissão para alterar o repositório, onde estão seus relatórios; outros agentes de IA fizeram revisões críticas e sugeriram e auditaram as análises do plano complementar; o ChatGPT (OpenAI) revisou o texto. O conteúdo final é de responsabilidade da autoria, que conferiu os números.

Referências

Agência Gov (2025). Brasil bate recorde de transplantes e anuncia medidas para modernizar sistema e aumentar doações. Ministério da Saúde, 4 jun. 2025, `https://agenciagov.ebc.com.br`.

Brasil. Agência Nacional de Vigilância Sanitária (2022). Resolução RDC nº 657, de 24 de março de 2022: dispõe sobre a regularização de software como dispositivo médico (Software as a Medical Device – SaMD). Diário Oficial da União.

Carbone, M., Sharp, S. J., Flack, S., et al. (2016). The UK-PBC risk scores: derivation and validation of a scoring system for long-term prediction of end-stage liver disease in primary biliary cholangitis. *Hepatology*, 63(3):930–950.

Christodoulou, E., Ma, J., Collins, G. S., Steyerberg, E. W., Verbakel, J. Y., and Van Calster, B. (2019). A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *Journal of Clinical Epidemiology*, 110:12–22.

Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.

Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2):187–202.

Davidson-Pilon, C. (2019). lifelines: survival analysis in Python. *Journal of Open Source Software*, 4(40):1317.

Dickson, E., Grambsch, P., Fleming, T., Fisher, L., and Langworthy, A. (1989a). Cirrhosis patient survival prediction. UCI Machine Learning Repository, `https://doi.org/10.24432/C5R02G`.

Dickson, E. R., Grambsch, P. M., Fleming, T. R., Fisher, L. D., and Langworthy, A. (1989b). Prognosis in primary biliary cirrhosis: model for decision making. *Hepatology*, 10(1):1–7.

Fleming, T. R. and Harrington, D. P. (1991). *Counting Processes and Survival Analysis*. John Wiley & Sons, New York.

Graf, E., Schmoor, C., Sauerbrei, W., and Schumacher, M. (1999). Assessment and comparison of prognostic classification schemes for survival data. *Statistics in Medicine*, 18(17–18):2529–2545.

Graf, R., Todd, S., and Baksh, M. F. (2026). Comparison of the Cox proportional hazards model and Random Survival Forest algorithm for predicting patient-specific survival probabilities in clinical trial data. *Biometrical Journal*, 68(5):e70171. Números citados da versão preprint, arXiv:2502.03119.

Grambsch, P. M. and Therneau, T. M. (1994). Proportional hazards tests and diagnostics based on weighted residuals. *Biometrika*, 81(3):515–526.

Harrell, Jr., F. E., Califf, R. M., Pryor, D. B., Lee, K. L., and Rosati, R. A. (1982). Evaluating the yield of medical tests. *JAMA*, 247(18):2543–2546.

Ishwaran, H., Kogalur, U. B., Blackstone, E. H., and Lauer, M. S. (2008). Random survival forests. *The Annals of Applied Statistics*, 2(3):841–860.

Kapoor, S. and Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804.

Lammers, W. J., Hirschfield, G. M., Corpechot, C., et al. (2015). Development and validation of a scoring system to predict outcomes of patients with primary biliary cirrhosis receiving ursodeoxycholic acid therapy. *Gastroenterology*, 149(7):1804–1812.e4.

Lodi, V. K., Oliveira Júnior, C. L., Cerqueira, F. R., Fracalossi, K. O., Costa, G. D. d., and Fernandes, D. L. (2026). Predição de risco de Óbito por febre amarela em diferentes estágios do acompanhamento clínico usando aprendizado de máquina. In *Anais do XXVI Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS)*, pages 693–704, Porto Alegre. Sociedade Brasileira de Computação.

Nadeau, C. and Bengio, Y. (2003). Inference for the generalization error. *Machine Learning*, 52(3):239–281.

Pereira, R. G., Brito, L. E. L., Avelar, I., Carvalho, M., Vasconcelos, M., Brandão, M. A., and Meira Jr., W. (2026). Responsible AI for public health: A methodological illustration with a forecasting model applied to respiratory hospitalizations on SUS data. In *Anais do XXVI Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS)*, Porto Alegre. Sociedade Brasileira de Computação.

Pölsterl, S. (2020). scikit-survival: a library for time-to-event analysis built on top of scikit-learn. *Journal of Machine Learning Research*, 21(212):1–6.

Putter, H., Fiocco, M., and Geskus, R. B. (2007). Tutorial in biostatistics: competing risks and multi-state models. *Statistics in Medicine*, 26(11):2389–2430.

Reade, W. and Chow, A. (2023). Multi-class prediction of cirrhosis outcomes. Kaggle, Playground Series, Season 3, Episode 26, `https://kaggle.com/competitions/playground-series-s3e26`.

Shakir, Y. H., Mandhari, E. A. A. A., and Alkhazraji, A. (2025). Leveraging machine learning for early risk prediction in cirrhosis outcome patients. *Public Research Journal of Engineering, Data Technology and Computer Science*, 3(1):22–30.

Simon, N., Friedman, J., Hastie, T., and Tibshirani, R. (2011). Regularization paths for Cox's proportional hazards model via coordinate descent. *Journal of Statistical Software*, 39(5):1–13.

Tu, T. E. (2025). Predicting cirrhosis patient survival utilizing machine learning techniques. Master's thesis, University of California, Los Angeles.

Uno, H., Cai, T., Pencina, M. J., D'Agostino, R. B., and Wei, L.-J. (2011). On the C-statistics for evaluating overall adequacy of risk prediction procedures with censored survival data. *Statistics in Medicine*, 30(10):1105–1117.

Uno, H., Cai, T., Tian, L., and Wei, L.-J. (2007). Evaluating prediction rules for t-year survivors with censored regression models. *Journal of the American Statistical Association*, 102(478):527–537.

Varma, S. and Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91.

Vickers, A. J., Cronin, A. M., Elkin, E. B., and Gonen, M. (2008). Extensions to decision curve analysis, a novel method for evaluating diagnostic tests, prediction models and molecular markers. *BMC Medical Informatics and Decision Making*, 8:53.