O aprendizado de máquina realmente supera o modelo clínico? Protocolo de avaliação e estudo de caso na colangite biliar primária

Autoria omitida para revisão

[1]Afiliação omitida para revisão

Abstract. *The five-variable Mayo Cox model (1989) is a classic prognostic reference in primary biliary cholangitis, and its public cohort is still used to test machine learning. In this evaluation case study, we compared random survival forests (RSF) and a 17-variable penalized Cox model with a re-estimated five-variable Mayo Cox model for five-year transplant-free survival, under a prior analysis plan. No gain in Uno's C was shown (reference 0.833; differences −0.014 to +0.015), also with intervals that include retraining variability; gains of 0.02 or more were excluded only for the five-variable RSF. Calibration and net benefit showed no advantage. In an exploratory analysis, using follow-up time as input, which leaks the outcome, inflated performance.*

Resumo. *O Cox de cinco variáveis de Mayo (1989) é uma referência prognóstica clássica na colangite biliar primária, e sua coorte pública ainda serve para testar aprendizado de máquina. Neste estudo de caso, comparamos random survival forests (RSF) e um Cox penalizado com 17 variáveis a um Cox reestimado com as cinco de Mayo, na sobrevida livre de transplante em cinco anos, com plano prévio. Nenhum ganho no C de Uno foi demonstrado (referência 0,833; diferenças de −0,014 a +0,015), mesmo com intervalos que incluem o retreino; ganhos de 0,02 ou mais só foram excluídos para a RSF de 5 variáveis. Calibração e benefício líquido não mostraram vantagem. Em análise exploratória, o tempo de seguimento como entrada, que vaza o desfecho, inflou o desempenho.*

1. Introdução

Modelos de aprendizado de máquina (AM) para a saúde costumam ser avaliados pelo seu desempenho isolado, mas a pergunta que interessa a quem vai adotá-los é outra: eles acrescentam algo ao que a clínica já usa? Este trabalho examina essa pergunta num caso clássico. A colangite biliar primária (CBP), chamada de cirrose biliar primária até 2015 [Beuers et al. 2015], é uma doença hepática autoimune e crônica que pode evoluir para cirrose, insuficiência hepática e transplante. Em 1989, o modelo de Mayo, uma regressão de Cox [Cox 1972] com cinco variáveis de rotina (idade, bilirrubina, albumina, tempo de protrombina e edema), derivada de dois ensaios clínicos da Mayo Clinic [Dickson et al. 1989b], tornou-se a referência clássica para estimar o risco que orienta a intensidade do acompanhamento e o momento de encaminhar o paciente ao transplante; escores posteriores o complementaram em pacientes tratados.

Os dados desses ensaios são públicos e se tornaram um conjunto clássico, primeiro em análise de sobrevivência [Fleming and Harrington 1991] e depois em AM, no repositório da UCI [Dickson et al. 1989a] e numa competição do Kaggle

[Reade and Chow 2023]. Modelos de AM prometem mais precisão, mas trazem custos: perdem a transparência de uma fórmula de cinco termos e, quando usam mais variáveis, exigem mais exames. Por isso o que se mede aqui é o **valor incremental** do AM: o quanto ele acrescenta ao modelo já disponível. Uma revisão de 71 estudos não encontrou vantagem do AM sobre a regressão logística nas comparações com baixo risco de viés [Christodoulou et al. 2019].

Por que voltar a esses dados hoje? Porque eles continuam a servir de banco de provas para o AM em saúde, e conclusões otimistas continuam a ser publicadas sobre eles: a competição do Kaggle de 2023 gerou dados sintéticos a partir da coorte, trabalhos de 2025 relatam acurácias próximas de 90% nesse enquadramento [Shakir et al. 2025, Tu 2025], e um estudo publicado em 2026 relatou vantagem pontual de uma RSF sobre um Cox nos 312 pacientes randomizados [Graf et al. 2026]. Há dois obstáculos a uma comparação justa nesse conjunto. O primeiro é o enquadramento: muitos trabalhos tratam o problema como classificação, excluem quem foi censurado antes do horizonte ou usam o tempo de seguimento como entrada, o que vaza o desfecho [Kapoor and Narayanan 2023]. O segundo é a flexibilidade de análise: escolher métrica, modelos e critérios depois de ver os resultados torna fácil encontrar alguma vantagem.

A pergunta tem peso particular no Brasil. A CBP é acompanhada em centros de hepatologia de todo o país, e numa coorte de 28 centros brasileiros a resposta ao tratamento padrão variou de 39% a 67%, conforme o critério usado [Cançado et al. 2022]. O transplante hepático, destino dos casos graves, é majoritariamente público: o SUS financia mais de 85% dos transplantes do país, que realizou 2.454 transplantes de fígado em 2024 [Agência Gov 2025]. E um modelo de IA usado para apoiar decisões clínicas é tratado pela Anvisa como software dispositivo médico, cuja regularização exige validação [Brasil. Agência Nacional de Vigilância Sanitária 2022]. Saber se um modelo novo acrescenta algo ao que já se usa interessa, portanto, também à alocação de recursos públicos e à regulação, impactos que este trabalho não avalia.

Este trabalho usa essa coorte como estudo de caso de avaliação e pergunta se modelos de AM para sobrevivência acrescentam valor, em discriminação, calibração e utilidade clínica, a um Cox reestimado com as cinco variáveis de Mayo, na predição de óbito ou transplante em até cinco anos, e se um eventual ganho viria do algoritmo ou das variáveis extras. Este trabalho não propõe um algoritmo novo nem um escore para uso clínico atual. As contribuições são: (i) uma comparação 2×2 (Cox ou RSF; 5 ou 17 variáveis) em análise de sobrevivência, com todos os 418 pacientes e as mesmas partições para todos os modelos; (ii) um plano de análise registrado antes dos resultados da análise de sobrevivência, com margem de relevância e regra de leitura fixadas, e o registro público de todos os desvios; (iii) uma comparação descritiva e exploratória de quatro enquadramentos da tarefa, em que o único ganho consistente apareceu quando o tempo de seguimento vazou para a entrada; e (iv) a sistematização desses cuidados em cinco passos replicáveis em outros conjuntos públicos de saúde (Tabela 1), sem reivindicar uma metodologia inédita, com código, dados, plano, desvios e resultados abertos.

2. Trabalhos relacionados

Os escores prognósticos de CBP são, em sua maioria, modelos de Cox. Depois do modelo de Mayo [Dickson et al. 1989b], a adoção do ácido ursodesoxicólico levou a

Tabela 1. Protocolo de avaliação do valor incremental, replicável em outros conjuntos públicos de saúde: cada passo, o erro que ele evita e onde aparece neste artigo.

Passo	Erro que evita	Neste artigo
1. Registrar o plano, com margem de relevância e regra de leitura, antes dos resultados	Escolher métrica, modelo ou critério depois de ver os números	Seção 3
2. Comparar com o modelo clínico disponível, nas mesmas partições e de forma pareada	Creditar ao AM um desempenho que o modelo atual já tem	Tabela 2
3. Tratar a censura como sobrevivência, sem excluir pacientes pelo horizonte	Amostra selecionada pelo próprio desfecho	Tabela 3
4. Avaliar calibração e benefício líquido, além da discriminação	Modelo que ordena bem, mas erra o risco ou não muda decisões	Figuras 1 e 2
5. Testar o efeito de variáveis indisponíveis no momento da predição	Vazamento que infla o desempenho	Tabela 3, linha (d)

escores para pacientes tratados, como o GLOBE [Lammers et al. 2015] e o UK-PBC [Carbone et al. 2016], construídos com exames medidos após um ano de tratamento e, portanto, para outro momento e outra população.

O trabalho mais próximo é o de [Graf et al. 2026], que compara Cox e RSF nos 312 pacientes randomizados, com um Cox de variáveis escolhidas por critérios de informação (e não as cinco de Mayo), C de Harrell e *bootstrap* .632+, com intervalos por modelo e nenhum para a diferença. A RSF teve valores pontuais melhores (C de 0,855 contra 0,776), mas os autores registram que os intervalos se sobrepõem, exceto em uma de seis regras de divisão; nas simulações, o Cox foi mais bem calibrado.

Os trabalhos recentes de AM sobre esse conjunto seguem o enquadramento da competição do Kaggle, com dados sintéticos gerados a partir do original [Reade and Chow 2023]: classificam o desfecho em três classes ou em óbito sem horizonte, sem avaliar calibração [Shakir et al. 2025, Tu 2025]. No próprio SBCAS, trabalhos recentes já mediram a inflação de desempenho causada por vazamento proposital, com dados do SUS [Pereira et al. 2026], e avaliaram a calibração ao prever óbito por febre amarela [Lodi et al. 2026]. No levantamento feito, não se encontrou estudo que compare, nos mesmos pacientes e partições, AM de sobrevivência com o Cox de Mayo, avaliando discriminação, calibração e benefício líquido sob um plano prévio. Este trabalho reúne esses cuidados num protocolo e mede o ganho contra uma referência clínica estabelecida.

3. Materiais e métodos

O relato se orienta pelo TRIPOD+AI [Collins et al. 2024], sem verificação formal de todos os itens. O plano de análise (desfechos, modelos, métricas, orçamento de ajuste, comparações e regra de leitura) foi registrado no controle de versões do repositório em 01/11/2026 (commit `677a281`), antes dos resultados da análise de sobrevivência, e não foi alterado; a análise anterior de classificação nos mesmos dados é descrita na Seção 3.5. Toda mudança posterior está registrada em uma lista de desvios, resumida na Seção 3.6.

3.1. Dados e desfechos

A coorte foi escolhida por ser pública e muito usada como referência para o AM, e não por representar os pacientes atuais: o objetivo é comparar modelos sob um protocolo comum, e não validar seu uso clínico hoje. O conjunto é o da Mayo Clinic, distribuído pela UCI (identificador 878, licença CC BY 4.0) [Dickson et al. 1989a] e pelo pacote `survival` do R. Usou-se uma cópia versionada e verificada por SHA-256, idêntica à da UCI em todos os valores. São 418 pacientes recrutados entre 1974 e 1984: 312 participaram de dois ensaios randomizados sobre D-penicilamina, e 106 eram elegíveis mas recusaram a randomização (106 dos 112 que recusaram; os demais foram perdidos no seguimento), tendo só as medidas de rotina [Dickson et al. 1989b, Fleming and Harrington 1991]. Cada paciente tem uma linha, com variáveis medidas no registro (linha de base), o desfecho (censura, óbito ou transplante) e o tempo até ele, em dias (`N_Days`).

O **desfecho principal** é a sobrevida livre de transplante: o evento é óbito ou transplante (186 pacientes, sendo 161 óbitos e 25 transplantes), e os 232 pacientes sem evento registrado até o último acompanhamento são censurados nesse momento. Todos os 418 pacientes entram na análise. Usaram-se todos os pacientes disponíveis, sem cálculo prévio de tamanho amostral; a precisão alcançada aparece na largura dos intervalos. O seguimento mediano foi de 7,0 anos (Kaplan-Meier reverso), e o horizonte de interesse é de cinco anos (1.826 dias), com 132 eventos até ele. Como **sensibilidade**, o evento é só o óbito, e o transplante é tratado como censura (161 eventos). Os preditores são as 5 variáveis de Mayo ou as 17 de linha de base. As 12 adicionais são sexo, tratamento atribuído (D-penicilamina ou placebo), ascite, hepatomegalia, aranhas vasculares, colesterol, cobre urinário, fosfatase alcalina, AST, triglicerídeos, plaquetas e estágio histológico, que exige biópsia; nove delas só foram colhidas nos ensaios e faltam nos 106 não randomizados, de modo que 276 pacientes têm as 17 completas, enquanto as 5 de Mayo faltam em apenas 2; as ausências por variável e por subgrupo estão no material suplementar. A coorte tem 374 mulheres (89,5%) e idade mediana de 51 anos. O tempo de seguimento nunca é preditor, porque só é conhecido depois do desfecho.

3.2. Modelos

O desenho é 2×2. A **referência** é um Cox de riscos proporcionais com as cinco variáveis de Mayo, nas mesmas transformações do modelo original (logaritmo de bilirrubina, albumina e protrombina), reestimado no treino de cada partição; não é a fórmula publicada em 1989, que além disso tratava o transplante como censura, e "Cox de Mayo" designa aqui esse modelo reestimado. Com as 17 variáveis, o Cox é penalizado por *elastic net* [Simon et al. 2011], que encolhe ou zera coeficientes para evitar o sobreajuste. Os modelos de AM são RSF [Ishwaran et al. 2008], florestas de 300 árvores de sobrevivência, com 5 e com 17 variáveis. Os hiperparâmetros são buscados em 50 configurações para cada floresta e em 40 combinações para o Cox penalizado; a referência não tem hiperparâmetros. A imputação de ausentes e a padronização são aprendidas só no treino de cada partição. Grades e pré-processamento estão detalhados no material suplementar.

3.3. Validação e métricas

A validação é cruzada, com 5 repetições de 5 partições estratificadas pelo evento, as mesmas para os quatro modelos, e os hiperparâmetros são escolhidos dentro do treino de cada partição (validação aninhada) [Varma and Simon 2006]. Cada modelo produz, para

cada paciente, o risco previsto de ter o evento em até cinco anos, $\hat{r}$; a predição fora da partição é a média das 5 repetições.

Um paciente censurado deixou o acompanhamento sem evento; sabe-se apenas que, se o evento ocorreu, foi depois. Por isso, as métricas são próprias para sobrevivência e ponderam os pacientes pela chance de continuarem em acompanhamento. A **métrica principal** é o C de Uno em cinco anos [Uno et al. 2011]: a probabilidade de que, de dois pacientes, o que teve o evento antes tenha recebido o risco maior (0,5 é o acaso; 1, a ordenação perfeita); ele corrige o viés do C de Harrell [Harrell et al. 1982] sob censura intensa. As secundárias são a AUC em cinco anos [Uno et al. 2007], que mede quão bem o risco separa quem teve e quem não teve o evento nesse prazo, e o escore de Brier em cinco anos e integrado de 1 a 5 anos [Graf et al. 1999], o erro quadrático da probabilidade prevista (menor é melhor). Um modelo é **calibrado** quando, entre pacientes com risco previsto de 20%, cerca de 20% têm o evento; comparamos, por quintis, o risco previsto com o observado por Kaplan-Meier e resumimos a coorte pela razão observado/esperado (O/E). A **utilidade clínica** é medida por curva de decisão [Vickers et al. 2008]: para a decisão hipotética de intensificar o acompanhamento, ou antecipar a avaliação para transplante, quando o risco passa de um limiar entre 5% e 50%, o benefício líquido desconta dos verdadeiros positivos os falsos positivos, com o peso que o limiar lhes dá.

3.4. Valor incremental e regra de leitura

Cada modelo é comparado à referência nos mesmos 418 pacientes, com 2.000 reamostragens *bootstrap* pareadas sobre as predições fora da partição (por isso a diferença não é a subtração das médias da Tabela 2), e os intervalos são ajustados para as três comparações (Bonferroni, 98,3%). A regra foi fixada no plano: um ganho ou uma perda só é demonstrado quando o intervalo exclui zero; e, se o limite superior ficar abaixo da **margem de +0,02** no C de Uno, um critério de leitura e não um limiar clínico validado, ganhos dessa magnitude são declarados incompatíveis com os dados. Esses intervalos não incluem a variação de retreinar os modelos; por isso, como sensibilidade acrescentada depois da auditoria (desvio D11), a leitura foi refeita com o teste t corrigido para validação cruzada repetida [Nadeau and Bengio 2003], que inclui essa variação.

3.5. Análises de apoio

Subgrupo fora do treino: treino nos 312 pacientes randomizados e teste nos 106 não randomizados (42 eventos); como nove das 17 variáveis faltam em todos os 106 e são imputadas, com 17 variáveis esse é um teste de transporte, não uma validação externa. **Pressupostos da referência:** um Cox descritivo nos 418 pacientes fornece razões de risco e o teste de riscos proporcionais de [Grambsch and Therneau 1994], calculados com o *lifelines* [Davidson-Pilon 2019]; formas funcionais e observações influentes não foram examinadas. **Importância por permutação** da RSF de 17 variáveis: quanto o C de Uno cai no teste quando os valores de uma variável são embaralhados. **Enquadramentos:** a Tabela 3 reúne quatro maneiras de formular a tarefa nos mesmos dados. As duas de classificação foram analisadas antes deste plano e estão documentadas no repositório: em (a), a regressão logística com as 5 variáveis é a referência, contra regressão penalizada, *random forest* e XGBoost; em (d), o mesmo XGBoost é ajustado com e sem o tempo de seguimento para prever as três classes do desfecho (censura, transplante e óbito). Os detalhes técnicos de todas as análises estão no material suplementar.

3.6. Desvios do plano e reprodutibilidade

Onze desvios e complementações estão registrados, com data e motivo. O principal veio de uma auditoria feita por outro agente de IA, sem permissão para alterar o repositório: na primeira execução, as florestas eram ajustadas com uma saída de risco diferente da usada na avaliação, que ordena os pacientes de outra forma; o procedimento foi corrigido e a análise repetida, e a primeira execução é citada como sensibilidade. Os demais são complementações fixadas antes dos resultados finais, exceto D9 a D11, registrados depois deles (regra de escolha da Tabela 3, documentação de entregas parciais e o teste corrigido). Ficaram aquém do plano os intervalos do subgrupo (só C de Uno e AUC, sem intervalo pareado) e a importância por permutação (só a RSF de 17 variáveis, na primeira repetição). O experimento usa Python 3.13 e scikit-survival 0.28.0 [Pölsterl 2020]; versões, sementes e manifestos estão no material suplementar. Código, dados, plano, desvios, resultados, auditorias e o material suplementar (`sbcas/MATERIAL_SUPLEMENTAR.md`) estão em um repositório público, com endereço anonimizado para a revisão (`https://anonymous.4open.science/r/ml4health-sbcas`). Os dados são públicos e anonimizados, e o estudo é uma análise secundária, sem contato com participantes.

4. Resultados

4.1. Discriminação e valor incremental

Nenhum modelo superou a referência na discriminação. A Tabela 2 resume o desempenho. A referência teve C de Uno médio de 0,833, e as diferenças em relação a ela ficaram entre $-0{,}014$ e +0,015, menores que a variação da própria diferença entre as 25 partições (desvios de 0,017 a 0,018). Nenhuma diferença foi estatisticamente demonstrada. Na inferência principal, o limite superior das duas RSF ficou abaixo da margem de +0,02; na de 17 variáveis, por pouco (0,0197; 0,0209 na primeira execução, com a busca desalinhada). Com o teste corrigido, que inclui a variação de retreinar os modelos, nenhuma diferença foi demonstrada, e a margem continuou excluída para a RSF de 5 variáveis (limite de 0,011), mas não para a de 17 (0,024) nem para o Cox penalizado (0,038). A ausência de ganho demonstrado é, portanto, robusta; a exclusão de ganhos relevantes só se sustenta para a RSF de 5 variáveis. Para o Cox penalizado, que teve a maior diferença nominal (+0,015, ganho em 68% das 25 partições), um ganho relevante não pode ser excluído. Na AUC em cinco anos, a RSF de 5 variáveis foi menor que a referência ($-0{,}024$; intervalo de $-0{,}047$ a $-0{,}001$), e as demais não diferiram.

Na sensibilidade com óbito como evento, o padrão se repetiu: a referência teve C de Uno de 0,854, e as diferenças foram de +0,010 ($-0{,}006$ a 0,026) no Cox penalizado, $-0{,}013$ ($-0{,}031$ a 0,003) na RSF de 5 variáveis e $-0{,}007$ ($-0{,}029$ a 0,014) na de 17, com ganhos de 0,02 incompatíveis com os dados para as duas florestas.

4.2. Calibração e utilidade clínica

A calibração e o benefício líquido também não favoreceram o AM. A razão O/E ficou próxima de 1 em todos os modelos (0,93 a 0,99), mas esse resumo global pode esconder erros em sentidos opostos, como superestimar o risco dos pacientes menos graves e subestimar o dos mais graves. Nos quintis (Figura 1; os quatro modelos estão no suplementar), os desvios da referência ficaram dentro dos intervalos, e a RSF de 17 variáveis previu 0,712 no quintil mais alto contra 0,808 observado, praticamente no limite do intervalo, o que

Tabela 2. Desempenho na validação cruzada 5×5, desfecho principal (418 pacientes, 186 eventos). Média (desvio entre as 25 partições); O/E com IC 95% por *bootstrap*; ΔC: diferença no C de Uno contra a referência, calculada sobre as predições agregadas dos 418 pacientes (nelas, a referência tem C de 0,831), com IC de Bonferroni (98,3%).

Modelo	C de Uno	AUC 5 anos	Brier 5 anos	Brier integr.	O/E 5 anos	ΔC de Uno
Cox, 5 var. (referência)	0,833 (0,029)	0,889 (0,031)	0,128 (0,021)	0,102 (0,009)	0,99 (0,87 a 1,10)	–
Cox penalizado, 17 var.	0,846 (0,024)	0,903 (0,028)	0,132 (0,018)	0,104 (0,008)	0,93 (0,82 a 1,03)	0,0148 (−0,0042 a 0,0324)
RSF, 5 var.	0,821 (0,034)	0,869 (0,039)	0,143 (0,019)	0,107 (0,009)	0,99 (0,87 a 1,10)	−0,0136 (−0,0323 a 0,0042)
RSF, 17 var.	0,832 (0,028)	0,886 (0,031)	0,135 (0,015)	0,104 (0,008)	0,99 (0,88 a 1,11)	−0,0010 (−0,0220 a 0,0197)

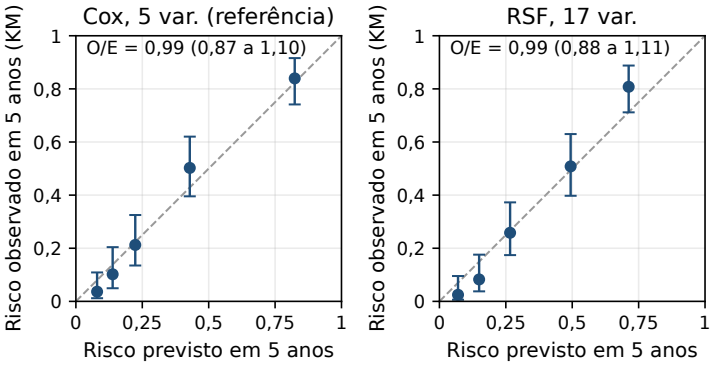


Figura 1. Calibração em cinco anos por quintis de risco previsto, na referência e na RSF de maior C de Uno médio (regra fixada antes da figura), sobre as predições fora da partição. Barras: IC 95% do Kaplan-Meier.

sugere compressão das probabilidades nos riscos altos. O desvio mais nítido foi o do Cox penalizado: nos dois quintis mais baixos, o risco previsto (0,127 e 0,202) ficou acima do limite superior do observado (0,054 e 0,171), e no mais alto (0,738), abaixo do limite inferior (0,748). Na curva de decisão (Figura 2a), referência e RSF de 17 variáveis tiveram benefício líquido próximo nos 46 limiares (diferença máxima de 0,015, ou 1,5 verdadeiro positivo líquido por 100 pacientes), ambas acima de tratar todos e de não tratar ninguém; sem intervalo para a diferença nem margem de equivalência, isso não demonstra utilidade igual.

4.3. Subgrupo fora do treino e pressupostos da referência

No subgrupo fora do treino, as estimativas dos quatro modelos ficaram próximas, sem base para afirmar superioridade de nenhum. No teste nos 106 pacientes não randomizados, o C de Uno foi de 0,790 (0,718 a 0,857) na referência, 0,806 no Cox penalizado, 0,797 na RSF de 5 variáveis e 0,807 na de 17, com intervalos amplamente sobrepostos. As razões O/E foram de 1,05, 1,06, 1,12 e 1,16, respectivamente: as florestas subestimaram mais o risco nesse grupo.

No ajuste descritivo da referência, as cinco variáveis se associaram ao desfecho

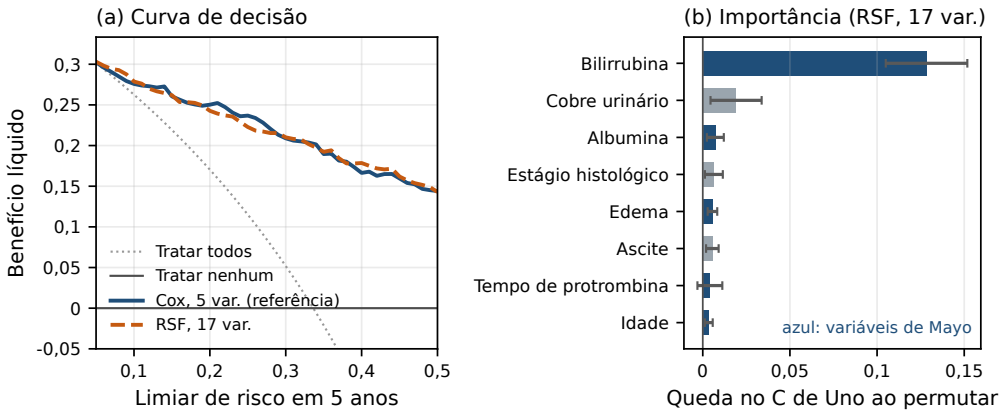


Figura 2. (a) Curva de decisão em cinco anos, com censura tratada por Kaplan-Meier; a RSF exibida foi escolhida pelo maior C de Uno nesta mesma coorte, o que introduz seleção e pode tornar sua curva otimista. (b) Importância por permutação na RSF de 17 variáveis: queda média do C de Uno no teste (barras: desvio entre as 5 partições); as oito maiores.

na direção esperada (razões de risco e testes no material suplementar). Houve evidência contra a proporcionalidade dos riscos para o tempo de protrombina, também dentro de cinco anos; para as demais variáveis, o teste não a detectou, o que não demonstra que o pressuposto valha para elas. A referência tem, portanto, ao menos uma variável cujo efeito parece variar no tempo e, mesmo assim, não foi superada pelas florestas, que não dependem desse pressuposto. Na importância por permutação da RSF de 17 variáveis (Figura 2b), a bilirrubina dominou (queda de 0,128 no C de Uno), seguida de longe por cobre (0,019) e albumina (0,007), e as cinco variáveis de Mayo ficaram entre as oito mais importantes, o que indica que, nessa análise, a floresta usou em grande parte a mesma informação que a referência. O tratamento não teve contribuição preditiva positiva, o que nada diz sobre sua eficácia.

4.4. O enquadramento muda a conclusão?

A Tabela 3 compara de forma descritiva quatro maneiras de formular a tarefa, mostrando em cada uma o modelo com a maior diferença contra a referência, a escolha mais favorável ao AM. Nas três primeiras, nenhum modelo demonstrou superioridade, e o melhor resultado nominal veio de uma regressão penalizada, não de árvores; como essas linhas mudam ao mesmo tempo tarefa, amostra, métrica e comparador, a tabela não isola o efeito de nenhuma escolha. A linha (d), exploratória e sem intervalo de confiança, mostra o aumento aparente mais consistente: com o mesmo modelo, incluir o tempo de seguimento, informação indisponível no momento da predição, elevou a AUROC macro em 0,034, com ganho em 24 das 25 partições. As métricas não estão na mesma escala, e a margem de 0,02 do C de Uno não se aplica às linhas de classificação.

5. Discussão

Nenhum modelo superou o Cox de Mayo, nem na inferência principal nem no teste que inclui a variação de retreinar os modelos, e essa ausência de ganho demonstrado se repetiu com óbito isolado, no subgrupo fora do treino e nos enquadramentos de classificação.

Tabela 3. Conclusões em quatro enquadramentos (comparação descritiva). (a) a (c): modelo com maior diferença contra a referência (em (a), os 312 pacientes com rótulo em cinco anos, não os 312 randomizados), IC de Bonferroni de 99% em (a) e de 98,3% em (b) e (c). (d): o mesmo XGBoost com e sem `N_Days`, diferença pareada por partição, em três classes (232 censuras, 25 transplantes, 161 óbitos).

Enquadramento	n / eventos	Métrica	Modelo	Δ	IC
(a) Classificação de óbito em 5 anos, sem os censurados antes de 5 anos	312 / 115	AUROC	RL penalizada, 17 var.	0,009	−0,017 a 0,035
(b) Sobrevivência, óbito ou transplante (principal)	418 / 186	C de Uno	Cox penalizado, 17 var.	0,015	−0,004 a 0,032
(c) Sobrevivência, só óbito	418 / 161	C de Uno	Cox penalizado, 17 var.	0,010	−0,006 a 0,026
(d) Classificação C/CL/D, `N_Days` na entrada	418 / 161	AUROC macro	XGBoost, 17 var., com e sem `N_Days`	0,034	sem IC; ganho em 96% das partições

Ganhos de 0,02 ou mais no C de Uno só podem ser excluídos para a RSF de 5 variáveis; calibração e benefício líquido não mostraram vantagem do AM, o que não equivale a demonstrar equivalência. Isso concorda com [Christodoulou et al. 2019]. Com 186 eventos e uma referência que já aproxima as relações por logaritmos, sobra pouco para a floresta aprender, e a informação se concentra na bilirrubina (Figura 2b); é uma explicação plausível, não testada.

Para além do caso, o trabalho ilustra como o protocolo condiciona a conclusão sobre o AM. Neste mesmo conjunto, os resultados publicados vão de acurácias próximas de 90% a vantagem pontual da RSF, e, aqui, o único aumento consistente apareceu quando o tempo de seguimento vazou para a entrada. O protocolo da Tabela 1 resume essa lição em cinco passos. Para quem desenvolve modelos com bases públicas ou para o SUS, o recado prático é comparar o AM ao escore que a clínica já usa, nas mesmas partições, e verificar se o ganho resiste à retirada das variáveis que só existem depois do desfecho.

O contraste com [Graf et al. 2026] é instrutivo. Aqui, o C de Harrell, a métrica usada lá, do Cox de referência foi de 0,814, e o da RSF de 17 variáveis, de 0,815. Os protocolos diferem em amostra, referência, métrica e validação, e não é possível dizer qual fator explica a diferença; o que se mostra é que, sob plano prévio e comparação pareada, a vantagem da RSF não aparece nestes dados. As acurácias próximas de 90% do enquadramento do Kaggle [Shakir et al. 2025, Tu 2025] também não são comparáveis: outro desfecho, dados sintéticos e vazamento [Kapoor and Narayanan 2023] (balanceamento antes da divisão; teste nos pacientes que geraram os dados de treino).

Vale notar que o melhor resultado nominal veio sempre de uma regressão penalizada com 17 variáveis, para a qual um ganho relevante não foi excluído; o estudo, porém, não demonstra superioridade de nenhuma família de modelos.

Limitações. Os dados vêm de um único centro, de 1974 a 1984, antes do ácido ursodesoxicólico, e não representam os pacientes atuais; não houve coorte externa. A ponderação pela censura supõe censura independente, estimada por Kaplan-Meier marginal, sem verificação de dependência em relação aos preditores. Na sensibilidade com

óbito, o transplante é tratado como censura: o risco estimado é o de uma análise de causa específica, hipotético na ausência de transplante, e não a incidência cumulativa observável de óbito, que exigiria uma análise de riscos competitivos [Putter et al. 2007]. O desenho também não é equilibrado. A referência parte com vantagem, porque as variáveis e transformações de Mayo foram escolhidas em 1989 nos mesmos 312 pacientes randomizados que integram esta coorte; os modelos de 17 variáveis partem em desvantagem, porque nove das variáveis extras, inclusive o tratamento, não foram coletadas nos 106 não randomizados e foram imputadas; e as famílias diferem no pré-processamento. Por isso, o desenho 2×2 não isola de forma estrita o efeito do algoritmo nem o das variáveis extras. Por fim, a conclusão vale para os modelos, as grades e o orçamento de ajuste avaliados.

6. Conclusão

Na coorte pública da Mayo Clinic, sob um plano de análise registrado antes dos resultados, nem a RSF nem o Cox penalizado com 17 variáveis acrescentaram valor demonstrável ao Cox reestimado com as cinco variáveis de Mayo na predição da sobrevida livre de transplante em cinco anos. Ganhos de 0,02 ou mais no C de Uno só puderam ser excluídos para a RSF de 5 variáveis, e calibração e benefício líquido não mostraram vantagem. A ausência de ganho demonstrado se repetiu entre desfechos e enquadramentos; o único ganho consistente veio do uso do tempo de seguimento como entrada, que é vazamento. Como lição, a conclusão sobre o AM depende do protocolo de avaliação, e o aqui descrito se aplica a outros conjuntos públicos. A continuidade natural é repetir a comparação em coortes atuais de pacientes tratados, em que GLOBE e UK-PBC são as referências, com análise de riscos competitivos, mantendo a pergunta que orientou este trabalho: quanto o novo modelo acrescenta ao que a clínica já usa, e a que custo.

Declaração de uso de inteligência artificial generativa

Ferramentas de IA generativa foram usadas sob supervisão da autoria. O Claude (Anthropic) apoiou a escrita do código de análise, a execução dos experimentos e a redação do texto. O Codex (OpenAI) auditou o código e as conclusões como agente separado, sem permissão para alterar o repositório, e seus relatórios estão no repositório; outro agente de IA, sem acesso à produção do texto, fez uma revisão crítica do artigo. O ChatGPT (OpenAI) foi usado na revisão do texto. Todas as decisões de desenho, a interpretação dos resultados e o conteúdo final são de responsabilidade da autoria, que conferiu os números contra os arquivos de resultados.

Referências

Agência Gov (2025). Brasil bate recorde de transplantes e anuncia medidas para modernizar sistema e aumentar doações. Ministério da Saúde, 4 jun. 2025, `https://agenciagov.ebc.com.br`.

Beuers, U., Gershwin, M. E., Gish, R. G., et al. (2015). Changing nomenclature for PBC: from “cirrhosis” to “cholangitis”. *Hepatology*, 62(5):1620–1622.

Brasil. Agência Nacional de Vigilância Sanitária (2022). Resolução RDC nº 657, de 24 de março de 2022: dispõe sobre a regularização de software como dispositivo médico (Software as a Medical Device – SaMD). Diário Oficial da União.

Cançado, G. G. L., Braga, M. H., Ferraz, M. L. G., Villela-Nogueira, C. A., Terrabuio, D. R. B., Cançado, E. L. R., et al. (2022). Clinical features and treatment outcomes of primary biliary cholangitis in a highly admixed population. *Annals of Hepatology*, 27(1):100546.

Carbone, M., Sharp, S. J., Flack, S., et al. (2016). The UK-PBC risk scores: derivation and validation of a scoring system for long-term prediction of end-stage liver disease in primary biliary cholangitis. *Hepatology*, 63(3):930–950.

Christodoulou, E., Ma, J., Collins, G. S., Steyerberg, E. W., Verbakel, J. Y., and Van Calster, B. (2019). A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *Journal of Clinical Epidemiology*, 110:12–22.

Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.

Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2):187–202. Com discussão, p. 202–220.

Davidson-Pilon, C. (2019). lifelines: survival analysis in Python. *Journal of Open Source Software*, 4(40):1317.

Dickson, E., Grambsch, P., Fleming, T., Fisher, L., and Langworthy, A. (1989a). Cirrhosis patient survival prediction. UCI Machine Learning Repository, `https://doi.org/10.24432/C5R02G`.

Dickson, E. R., Grambsch, P. M., Fleming, T. R., Fisher, L. D., and Langworthy, A. (1989b). Prognosis in primary biliary cirrhosis: model for decision making. *Hepatology*, 10(1):1–7.

Fleming, T. R. and Harrington, D. P. (1991). *Counting Processes and Survival Analysis*. John Wiley & Sons, New York.

Graf, E., Schmoor, C., Sauerbrei, W., and Schumacher, M. (1999). Assessment and comparison of prognostic classification schemes for survival data. *Statistics in Medicine*, 18(17–18):2529–2545.

Graf, R., Todd, S., and Baksh, M. F. (2026). Comparison of the Cox proportional hazards model and Random Survival Forest algorithm for predicting patient-specific survival probabilities in clinical trial data. *Biometrical Journal*, 68(5):e70171. Números citados da versão preprint, arXiv:2502.03119.

Grambsch, P. M. and Therneau, T. M. (1994). Proportional hazards tests and diagnostics based on weighted residuals. *Biometrika*, 81(3):515–526.

Harrell, Jr., F. E., Califf, R. M., Pryor, D. B., Lee, K. L., and Rosati, R. A. (1982). Evaluating the yield of medical tests. *JAMA*, 247(18):2543–2546.

Ishwaran, H., Kogalur, U. B., Blackstone, E. H., and Lauer, M. S. (2008). Random survival forests. *The Annals of Applied Statistics*, 2(3):841–860.

Kapoor, S. and Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804.

Lammers, W. J., Hirschfield, G. M., Corpechot, C., et al. (2015). Development and validation of a scoring system to predict outcomes of patients with primary biliary cirrhosis receiving ursodeoxycholic acid therapy. *Gastroenterology*, 149(7):1804–1812.e4.

Lodi, V. K., Oliveira Júnior, C. L., Cerqueira, F. R., Fracalossi, K. O., Costa, G. D. d., and Fernandes, D. L. (2026). Predição de risco de Óbito por febre amarela em diferentes estágios do acompanhamento clínico usando aprendizado de máquina. In *Anais do XXVI Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS)*, pages 693–704, Porto Alegre. Sociedade Brasileira de Computação.

Nadeau, C. and Bengio, Y. (2003). Inference for the generalization error. *Machine Learning*, 52(3):239–281.

Pereira, R. G., Brito, L. E. L., Avelar, I., Carvalho, M., Vasconcelos, M., Brandão, M. A., and Meira Jr., W. (2026). Responsible AI for public health: A methodological illustration with a forecasting model applied to respiratory hospitalizations on SUS data. In *Anais do XXVI Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS)*, Porto Alegre. Sociedade Brasileira de Computação.

Pölsterl, S. (2020). scikit-survival: a library for time-to-event analysis built on top of scikit-learn. *Journal of Machine Learning Research*, 21(212):1–6.

Putter, H., Fiocco, M., and Geskus, R. B. (2007). Tutorial in biostatistics: competing risks and multi-state models. *Statistics in Medicine*, 26(11):2389–2430.

Reade, W. and Chow, A. (2023). Multi-class prediction of cirrhosis outcomes. Kaggle, Playground Series, Season 3, Episode 26, `https://kaggle.com/competitions/playground-series-s3e26`.

Shakir, Y. H., Mandhari, E. A. A. A., and Alkhazraji, A. (2025). Leveraging machine learning for early risk prediction in cirrhosis outcome patients. *Public Research Journal of Engineering, Data Technology and Computer Science*, 3(1):22–30.

Simon, N., Friedman, J., Hastie, T., and Tibshirani, R. (2011). Regularization paths for Cox's proportional hazards model via coordinate descent. *Journal of Statistical Software*, 39(5):1–13.

Tu, T. E. (2025). Predicting cirrhosis patient survival utilizing machine learning techniques. Master's thesis, University of California, Los Angeles.

Uno, H., Cai, T., Pencina, M. J., D'Agostino, R. B., and Wei, L.-J. (2011). On the C-statistics for evaluating overall adequacy of risk prediction procedures with censored survival data. *Statistics in Medicine*, 30(10):1105–1117.

Uno, H., Cai, T., Tian, L., and Wei, L.-J. (2007). Evaluating prediction rules for t-year survivors with censored regression models. *Journal of the American Statistical Association*, 102(478):527–537.

Varma, S. and Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91.

Vickers, A. J., Cronin, A. M., Elkin, E. B., and Gonen, M. (2008). Extensions to decision curve analysis, a novel method for evaluating diagnostic tests, prediction models and molecular markers. *BMC Medical Informatics and Decision Making*, 8:53.