O aprendizado de máquina realmente supera o modelo clínico? Um estudo de caso com plano prévio na colangite biliar primária

Autoria omitida para revisão

[1]Afiliação omitida para revisão

Abstract. *ML models should be judged by what they add to the clinical model. In a case study with a prior plan, we compared, pairwise and on the same folds, random survival forests (RSF) with 5 or 17 variables and a 17-variable penalized Cox with a re-estimated five-variable Mayo Cox model in 418 patients with primary biliary cholangitis (death or transplant within five years). No model outperformed the reference in Uno's C (*0.831*; differences* -0.014 *to* $+0.015$*). A 0.02 gain was ruled out only for the five-variable RSF; for the other two, precision was lacking. Post hoc, no model beat the 1989 Mayo formula, evaluated where it was fitted, and evaluating the RSF on its training data (no interval) raised its C by* 0.043*, more than any difference between models.*

Resumo. *Modelos de aprendizado de máquina devem ser julgados pelo que acrescentam ao modelo clínico. Sob plano prévio, comparamos, em pares, nas mesmas partições, random survival forests (RSF) com 5 ou 17 variáveis e um Cox penalizado com 17 a um Cox reestimado com as cinco variáveis de Mayo, em 418 pacientes com colangite biliar primária (óbito ou transplante em cinco anos). Nenhum superou a referência no C de Uno (*0,831*; diferenças de* $-0{,}014$ *a* $+0{,}015$*). Um ganho de 0,02 só foi descartado na RSF de 5 variáveis; nos outros dois, faltou precisão. Em análise posterior, nenhum superou a fórmula de 1989, avaliada onde foi estimada, e avaliar a RSF no próprio treino (sem intervalo) elevou seu C em* 0,043*, mais que qualquer diferença entre modelos.*

1. Introdução

Um modelo de aprendizado de máquina (AM) para a saúde costuma ser apresentado pelo desempenho isolado. A pergunta de quem decide adotá-lo é outra: ele acrescenta algo ao modelo que a clínica já usa? Um trabalho recente do SBCAS aponta, como limitação, não ter comparado seus modelos com as abordagens clínicas em uso, o que impede medir o ganho incremental do AM [Lodi et al. 2026]. Este artigo faz essa comparação num caso clássico e separa o que se pode e o que não se pode concluir.

A colangite biliar primária (CBP, antes chamada de cirrose biliar primária) é uma doença hepática autoimune e crônica que pode evoluir para cirrose e transplante. Em 1989, o modelo de Mayo, uma regressão de Cox com cinco variáveis de rotina (idade, bilirrubina, albumina, tempo de protrombina e edema), selecionadas em dois ensaios clínicos da Mayo Clinic [Dickson et al. 1989b], tornou-se a referência para estimar o risco que orienta acompanhamento e encaminhamento ao transplante. Os dados desses ensaios são públicos e viraram um conjunto clássico de sobrevivência e de AM, do artigo que propôs a RSF [Ishwaran et al. 2008] à UCI [Dickson et al. 1989a] e ao Kaggle [Reade and Chow 2023].

Por que voltar a esses dados hoje? Porque conclusões otimistas continuam a ser publicadas sobre eles: trabalhos de 2025 relatam acurácias próximas de 90% em dados sintéticos derivados da coorte, para outros desfechos [Shakir et al. 2025, Tu 2025], e um estudo de 2026 relatou vantagem pontual de uma RSF sobre um Cox nos 312 pacientes randomizados [Graf et al. 2026]. Duas coisas dificultam uma comparação justa nesse conjunto: o enquadramento (tratar o problema como classificação, excluir os censurados antes do horizonte ou usar o tempo de seguimento como entrada, o que vaza o desfecho [Kapoor and Narayanan 2023]) e a flexibilidade de análise (escolher métrica, modelos e critérios depois de ver os resultados). A pergunta também tem peso no Brasil: numa coorte de 28 centros, a resposta ao tratamento padrão variou de 39% a 67%, conforme o critério [Cançado et al. 2022]; o SUS financia mais de 85% dos transplantes do país, 2.454 de fígado em 2024 [Agência Gov 2025]; e um modelo de IA de apoio à decisão é software dispositivo médico sujeito a validação [Brasil. Agência Nacional de Vigilância Sanitária 2022]: a pergunta interessa à alocação de recursos e à regulação, impactos que este trabalho não avalia.

Usamos a coorte como estudo de caso, com uma pergunta prática: um serviço que já estima o risco com as cinco variáveis de Mayo ganharia algo ao trocar o Cox por uma floresta, ou por um modelo com os 17 exames de linha de base? A troca tem custo, pois perde a transparência de uma fórmula de cinco termos e, com mais variáveis, exige mais exames. Comparamos, em pares e sob plano prévio, RSF e Cox penalizado com um Cox reestimado com as cinco variáveis de Mayo, na predição de óbito ou transplante em cinco anos. Não propomos algoritmo nem escore para uso clínico atual. O artigo separa três leituras que se confundem quando se diz que o AM "supera" um modelo clínico: ganho não demonstrado, ganho relevante descartado e ganho aparente produzido pela forma de avaliar. As contribuições são empíricas: (i) a reavaliação pareada da vantagem relatada para a RSF nesta coorte [Graf et al. 2026], contra o modelo clínico reestimado e, em análise posterior, contra a fórmula de 1989; (ii) a medida, nos mesmos dados, de quanto cada escolha de avaliação muda o resultado (Tabela 4); e (iii) plano, desvios, código e resultados públicos. Os cinco cuidados da Tabela 1 são boas práticas conhecidas, não um método novo.

2. Trabalhos relacionados

Depois do modelo de Mayo [Dickson et al. 1989b], a adoção do ácido ursodesoxicólico levou a outros escores de Cox, para pacientes tratados, como o GLOBE [Lammers et al. 2015] e o UK-PBC [Carbone et al. 2016], construídos com exames medidos após um ano de tratamento, para outro momento e outra população.

O trabalho mais próximo é o de [Graf et al. 2026], que compara Cox e RSF nos 312 pacientes randomizados, com um Cox de variáveis escolhidas por critérios de informação (e não as cinco de Mayo), C de Harrell e *bootstrap* .632+. A RSF teve valores pontuais melhores (C de 0,855 contra 0,776), com intervalos sobrepostos, exceto em uma de seis regras de divisão, cujo intervalo exclui o C pontual do Cox; não há intervalo para a diferença, e intervalos por modelo não o substituem.

Os trabalhos recentes de AM sobre esse conjunto seguem a competição do Kaggle, com dados sintéticos derivados do original [Reade and Chow 2023]: classificam o desfecho em três classes ou em óbito sem horizonte, sem avaliar calibração

Tabela 1. Cuidados de avaliação: o erro que cada um evita e onde aparece.

Passo	Erro que evita	Neste artigo
1. Registrar plano, margem e regra de leitura antes dos resultados	Escolher métrica, modelo ou critério após ver os números	Seções 3 e 3.6
2. Comparar com o modelo clínico disponível, em pares, nas mesmas partições	Creditar ao AM o que o modelo atual já faz	Tabela 3
3. Tratar a censura como sobrevivência, sem excluir pacientes pelo horizonte	Amostra selecionada pelo próprio desfecho	Seções 3.3 e 4.4
4. Avaliar calibração e benefício líquido, não só a discriminação	Modelo que ordena bem, mas erra o risco ou não muda decisões	Figura 1
5. Testar variáveis indisponíveis no momento da predição	Vazamento que infla o desempenho	Tabela 4 (classificação)

[Shakir et al. 2025, Tu 2025]. No próprio SBCAS, trabalhos recentes mediram a inflação causada por vazamento proposital em dados do SUS [Pereira et al. 2026] e avaliaram a calibração ao prever óbito por febre amarela [Lodi et al. 2026]. Numa busca não sistemática, não encontramos estudo que compare, nos mesmos pacientes e partições e sob plano prévio, AM de sobrevivência com o modelo de Mayo; a contribuição está no protocolo de comparação, não na novidade da pergunta.

3. Materiais e métodos

O relato segue o TRIPOD+AI [Collins et al. 2024], sem verificação formal de todos os itens. O plano de análise (desfechos, modelos, métricas, comparações e regra de leitura) foi registrado em 01/11/2026 no controle de versões do repositório, antes dos resultados da análise de sobrevivência, e não foi alterado; o que mudou ou se acrescentou depois está registrado como **desvio** (D1 a D17), com data e motivo (Seção 3.6).

3.1. Dados e desfechos

A coorte foi escolhida por ser pública e muito usada em AM, não por representar os pacientes atuais. O conjunto é o da Mayo Clinic, distribuído pela UCI (identificador 878, licença CC BY 4.0) [Dickson et al. 1989a] e pelo pacote `survival` do R. São 418 pacientes recrutados entre 1974 e 1984: 312 participaram de dois ensaios randomizados sobre D-penicilamina, e 106 eram elegíveis mas recusaram a randomização, tendo só as medidas de rotina [Dickson et al. 1989b]. Cada paciente é uma linha, com as variáveis medidas no registro (linha de base), o desfecho (censura, óbito ou transplante) e o tempo até ele, em dias (`N_Days`).

O **desfecho principal** é a sobrevida livre de transplante: o evento é óbito ou transplante (186 pacientes: 161 óbitos e 25 transplantes); os 232 sem evento são censurados no último acompanhamento. Sem cálculo prévio de tamanho amostral, a precisão aparece na largura dos intervalos. O seguimento mediano foi de 7,0 anos (Kaplan-Meier reverso), e o horizonte de interesse é de cinco anos, com 132 eventos até ele. Como **sensibilidade**, o evento é só o óbito, e o transplante é tratado como censura (161 eventos). Os preditores são as 5 variáveis de Mayo ou as 17 de linha de base. As 12 adicionais são sexo, tratamento atribuído, achados de exame físico, exames laboratoriais e estágio histológico, que exige biópsia. Nove delas só foram medidas nos ensaios e faltam em todos os 106 não randomizados; 276 pacientes têm as 17 completas, e as cinco de Mayo faltam em apenas

2. A coorte tem 374 mulheres e idade mediana de 51 anos. O tempo de seguimento nunca é preditor: só se conhece após o desfecho.

3.2. Modelos e o alcance da comparação

O desenho é 2×2. A **referência** é um Cox de riscos proporcionais com as cinco variáveis de Mayo, nas mesmas transformações do modelo original (logaritmo de bilirrubina, albumina e protrombina), reestimado no treino de cada partição da validação cruzada (Seção 3.3); não é a fórmula publicada em 1989, e "Cox de Mayo" designa aqui esse modelo reestimado. Com as 17 variáveis, o Cox é penalizado por *elastic net* [Simon et al. 2011], que encolhe ou zera coeficientes para evitar o sobreajuste. Os modelos de AM são RSF [Ishwaran et al. 2008], florestas de 300 árvores de sobrevivência, com 5 e com 17 variáveis. Hiperparâmetros (50 configurações por floresta, 40 para o Cox penalizado), imputação e padronização são escolhidos ou aprendidos só no treino de cada partição (grades no suplementar).

A comparação não é equilibrada. As variáveis e transformações de Mayo foram escolhidas em 1989 nos mesmos 312 pacientes randomizados desta coorte, o que favorece a referência; nove das variáveis extras, inclusive o tratamento, faltam nos 106 não randomizados e foram imputadas, o que desfavorece os modelos de 17 variáveis. Disso decorre o alcance da comparação: ela responde à pergunta de adoção da Introdução, com a imputação que os dados reais exigem. Não responde se florestas superam Cox em condições iguais, nem se as 12 variáveis extras carregam informação que outro desenho capturaria: um empate aqui é compatível com as duas hipóteses. Por isso a pergunta do plano sobre a origem de um eventual ganho (o algoritmo ou as variáveis extras) ficou sem resposta (desvio D13): não houve ganho a decompor, e o desenho não o isolaria.

3.3. Validação e métricas

A validação é cruzada, com 5 repetições de 5 partições estratificadas pelo evento, as mesmas para os quatro modelos, e os hiperparâmetros são escolhidos dentro do treino de cada partição (validação aninhada). Cada modelo produz, por paciente, o risco previsto de evento em até cinco anos; a predição fora da partição é a média das 5 repetições, o que pode estreitar os intervalos.

Um paciente censurado deixou o acompanhamento sem evento; sabe-se apenas que, se o evento ocorreu, foi depois. Por isso as métricas são próprias para sobrevivência e ponderam os pacientes pela chance de continuarem em acompanhamento. A **métrica principal** é o C de Uno em cinco anos [Uno et al. 2011]. Como a AUC, ele mede ordenação: tome dois pacientes em que se sabe quem teve o evento primeiro; o C é a fração desses pares em que o modelo deu risco maior a esse paciente (0,5 é o acaso; 1, a ordenação perfeita). Diferente do C de Harrell, repondera os pares pela probabilidade de censura. As secundárias são a AUC em cinco anos [Uno et al. 2007] e o escore de Brier em cinco anos e integrado de 1 a 5 anos [Graf et al. 1999], o erro quadrático da probabilidade prevista (menor é melhor). Um modelo é **calibrado** quando, entre pacientes com risco previsto de 20%, cerca de 20% têm o evento; comparamos, por quintis, o risco previsto com o observado por Kaplan-Meier e resumimos a coorte pela razão observado/esperado (O/E). A **utilidade clínica** é medida por curva de decisão [Vickers et al. 2008]: para a decisão hipotética de intensificar o acompanhamento acima de um limiar de risco entre 5% e 50%,

o benefício líquido desconta dos verdadeiros positivos os falsos positivos, com o peso que o limiar lhes dá.

3.4. Como se lê uma diferença entre modelos

Cada modelo é comparado à referência nos mesmos 418 pacientes: em 2.000 reamostragens *bootstrap* pareadas, calcula-se a diferença de C de Uno entre os dois, e os intervalos são ajustados para as três comparações (Bonferroni, 98,3%). Por usar as predições agregadas, a diferença não é a subtração das médias da Tabela 2. O plano fixou duas regras. Uma diferença só é demonstrada quando o intervalo exclui zero. E, se o limite superior ficar abaixo da **margem de +0,02** no C de Uno, ganhos dessa magnitude são descartados; a margem é um critério de leitura do estudo, não um limiar clínico validado. Esse *bootstrap* reamostra pacientes: captura a incerteza de quem está na coorte, mas não a de retreinar o modelo em outra partição. Para cobrir essa segunda fonte, depois de conhecidos os resultados, acrescentamos o teste *t* corrigido para validação cruzada repetida [Nadeau and Bengio 2003] sobre as diferenças nas 25 partições (desvio D11), e passamos a declarar descartado um ganho de 0,02 só quando os dois métodos o descartam. A leitura só pelo plano continua relatada.

3.5. Análises complementares

Quatro análises do plano apoiam a principal. **Subgrupo fora do treino:** treino nos 312 pacientes randomizados e teste nos 106 não randomizados (42 eventos); com 17 variáveis é um teste de transporte, não validação externa, porque nove delas faltam nos 106 e são imputadas. **Pressupostos da referência:** razões de risco e teste de riscos proporcionais [Grambsch and Therneau 1994] de um Cox descritivo nos 418 (detalhes no suplementar). **Importância por permutação** da RSF de 17 variáveis: quanto o C de Uno cai no teste ao embaralhar uma variável. **Classificação**, executada antes do plano e incluída nele como comparação de enquadramentos: óbito em cinco anos sem os censurados antes desse prazo (regressão logística com 5 variáveis contra regressão logística penalizada com 17 e *random forest* e XGBoost com 5 e com 17) e XGBoost com e sem o tempo de seguimento na entrada.

Duas análises vieram de um **plano complementar**, registrado pela autoria antes de ser executado, mas depois dos resultados principais e com um cálculo exploratório da fórmula já conhecido: não é uma confirmação pré-especificada independente, e seus resultados devem ser lidos como posteriores. Primeira, a **fórmula de Mayo de 1989**, com os coeficientes publicados e sem reajuste, entra como segunda referência na discriminação. Das duas versões publicadas, a final (de uso clínico, estimada nos 418) é usada na coorte inteira, onde é avaliada nos pacientes em que foi estimada, o que a favorece; a inicial (estimada nos 312) é usada nos 106, que nunca viu. Segunda, as **fontes de ganho aparente**, nos 312 randomizados: um Cox com as sete variáveis do conjunto final de [Graf et al. 2026] contra o Cox de Mayo, e a avaliação de cada modelo nos próprios pacientes de treino. Após auditoria da primeira execução, o procedimento foi emendado e reexecutado; a métrica prevista para o otimismo era o C de Harrell (0,041 na RSF), e o artigo relata o C de Uno (0,043).

3.6. Desvios do plano e reprodutibilidade

Três limites do plano devem ficar claros. O registro é um *commit* no repositório da autoria, verificável pela cronologia pública, não um registro independente. O plano foi escrito

Tabela 2. Desempenho, desfecho principal (418 pacientes; 186 eventos no seguimento, 132 até cinco anos): média (desvio) nas 25 partições; O/E (IC 95%) nas predições agregadas.

Modelo	C de Uno	AUC 5 anos	Brier 5 anos	Brier integr.	O/E 5 anos
Cox, 5 var. (referência)	0,833 (0,029)	0,889 (0,031)	0,128 (0,021)	0,102 (0,009)	0,99 (0,87 a 1,10)
Cox penalizado, 17 var.	0,846 (0,024)	0,903 (0,028)	0,132 (0,018)	0,104 (0,008)	0,93 (0,82 a 1,03)
RSF, 5 var.	0,821 (0,034)	0,869 (0,039)	0,143 (0,019)	0,107 (0,009)	0,99 (0,87 a 1,10)
RSF, 17 var.	0,832 (0,028)	0,886 (0,031)	0,135 (0,015)	0,104 (0,008)	0,99 (0,88 a 1,11)

depois da análise de classificação (Seção 3.5): é prospectivo para a sobrevivência, não anterior a toda exploração. E há dezessete desvios. O principal veio de uma auditoria por outro agente de IA, sem permissão para alterar o repositório: na primeira execução, as florestas eram ajustadas com uma saída de risco diferente da avaliada; o procedimento foi corrigido e a análise repetida. Os demais acrescentam análises sem mudar as previstas; nove são posteriores aos resultados finais, entre eles a regra combinada (Seção 3.4), as sementes extras e o plano complementar. Ficaram aquém do plano a AUC do subgrupo, sem intervalo pareado, e a importância por permutação (Figura 1e). O experimento usa Python 3.13 e scikit-survival 0.28.0 [Pölsterl 2020]; versões, sementes e manifestos no suplementar. Os dados são públicos e anonimizados; código, dados, plano, desvios, cronologia, resultados e auditorias estão em repositório público, anonimizado para a revisão (`https://anonymous.4open.science/r/ml4health-sbcas`).

4. Resultados

4.1. Discriminação: a resposta para cada modelo

Nenhum modelo apresentou superioridade demonstrada na discriminação (Tabelas 2 e 3): contra a referência (C de Uno de 0,831 nas predições agregadas), as diferenças ficaram entre $-0{,}014$ e +0,015, e nenhum intervalo do C de Uno excluiu zero, nas duas inferências. Se um ganho de 0,02 pode ser descartado, a resposta difere por modelo. Para a RSF de 5 variáveis, sim: os dois limites superiores ficaram abaixo da margem. Para a RSF de 17, o limite do plano (0,0197) ficou colado à margem: no teste corrigido chegou a 0,024 e, em 25 sementes diferentes do *bootstrap*, passou de 0,02 em 10; tratamos esse caso como inconclusivo. Para o Cox penalizado, o modelo de maior C (+0,015), não: os limites superiores, 0,032 e 0,038, passam da margem. Essa divisão decorre da precisão alcançada: a meia-largura dos intervalos pareados ficou entre 0,018 e 0,021 pelo plano e entre 0,023 e 0,026 pelo teste corrigido, a própria ordem da margem; com 132 eventos até cinco anos, um ganho de 0,02 só poderia ser descartado para um modelo com estimativa negativa. Na sensibilidade só com óbito (segundo bloco da Tabela 3), o padrão se repete: nenhuma diferença demonstrada e ganho de 0,02 descartado só para a RSF de 5 variáveis. Na AUC em cinco anos, a RSF de 5 variáveis ficou abaixo da referência só no *bootstrap* ($-0{,}024$; $-0{,}047$ a $-0{,}001$); as demais não diferiram.

4.2. Calibração e utilidade clínica

Calibração e benefício líquido, descritivos, não mostraram vantagem do AM. A razão O/E ficou próxima de 1 em todos os modelos (0,93 a 0,99), mas esse resumo global pode esconder erros em sentidos opostos, como superestimar o risco dos pacientes menos graves

Tabela 3. Valor incremental no C de Uno em cinco anos (predições agregadas): modelo menos referência (referência: 0,831 no desfecho principal, 0,850 só óbito; fórmula de 1989 [Dickson et al. 1989b], avaliada onde foi estimada: 0,831 e 0,855). IC de Bonferroni (98,3%) do *bootstrap* do plano e do teste corrigido, centrado na média por partição e por isso não simétrico em torno de ΔC; *: comparação à parte, IC 95%. Intervalo com zero: diferença não demonstrada; limite superior abaixo de 0,02 nos dois intervalos: ganho dessa ordem descartado ("só no plano": só o *bootstrap* o descarta); †0,01996 antes de arredondar, abaixo da margem.

Comparação	ΔC	IC, plano	IC, teste corrigido	Ganho de 0,02 descartado?
Óbito ou transplante, contra o Cox de Mayo reestimado (referência do plano)				
Cox penalizado, 17 var.	0,015	−0,0042 a 0,0324	−0,012 a 0,038	não
RSF, 5 var.	−0,014	−0,0323 a 0,0042	−0,036 a 0,011	sim
RSF, 17 var.	−0,001	−0,0220 a 0,0197	−0,027 a 0,024	não (só no plano)
Só óbito, contra o Cox reestimado (sensibilidade)				
Cox penalizado, 17 var.	0,010	−0,0064 a 0,0261	−0,009 a 0,030	não
RSF, 5 var.	−0,013	−0,0313 a 0,0030	−0,050 a 0,006	sim
RSF, 17 var.	−0,007	−0,0292 a 0,0144	−0,042 a 0,025	não (só no plano)
Óbito ou transplante, contra a fórmula de 1989 sem reajuste (análise posterior)				
Cox, 5 var. (reestimado)*	0,001	−0,0054 a 0,0066	−0,007 a 0,010	sim
Cox penalizado, 17 var.	0,016	−0,0046 a 0,0357	−0,017 a 0,046	não
RSF, 5 var.	−0,013	−0,0367 a 0,0089	−0,041 a 0,019	sim
RSF, 17 var.	0,000	−0,0249 a 0,0237	−0,031 a 0,031	não
Só óbito, contra a fórmula de 1989 sem reajuste (análise posterior)				
Cox, 5 var. (reestimado)*	−0,005	−0,0079 a −0,0023	−0,008 a 0,001	sim
Cox penalizado, 17 var.	0,006	−0,0107 a 0,0200†	−0,012 a 0,026	não (só no plano)
RSF, 5 var.	−0,018	−0,0361 a −0,0024	−0,053 a 0,002	sim
RSF, 17 var.	−0,011	−0,0337 a 0,0084	−0,046 a 0,022	não (só no plano)

e subestimar o dos mais graves. Nos quintis (Figura 1a a c; os quatro modelos no suplementar), os desvios da referência ficaram dentro dos intervalos, e a RSF de 17 variáveis subestimou o risco no quintil mais alto (0,712 contra 0,808), no limite do intervalo. O desvio mais nítido foi o do Cox penalizado, o modelo de maior C: superestimou o risco nos dois quintis mais baixos e o subestimou no mais alto, fora dos intervalos. No Brier, as três alternativas tiveram erro maior que a referência, de modo mais nítido na RSF de 5 variáveis (Tabela 2). Na curva de decisão (Figura 1d), referência e RSF de 17 variáveis quase se sobrepõem entre 5% e 50% de risco, ambas acima de tratar todos e de não tratar ninguém. A maior distância entre elas, 1,5 verdadeiro positivo líquido por 100 pacientes no limiar de 26%, favoreceu a referência; a RSF ficou à frente, por menos, em 29 dos 46 limiares. Sem intervalo para a diferença, a figura não demonstra utilidade igual.

4.3. Contra a fórmula de 1989 e fora do treino (análises posteriores)

Contra a fórmula de 1989 sem reajuste (dois últimos blocos da Tabela 3), o quadro se repete. No desfecho principal, o Cox reestimado ficou praticamente igual a ela (0,001), e nenhum modelo de AM mostrou ganho demonstrado, embora a fórmula seja avaliada onde foi estimada, favorecimento pequeno (Tabela 4). No desfecho só óbito, para o qual a fórmula foi derivada, ela ficou nominalmente à frente do Cox reestimado e da RSF de 5 variáveis, com intervalos do *bootstrap* sem zero, mas do teste corrigido com zero: um indício, não uma demonstração. Os outros dois modelos não diferiram dela, e em nenhum

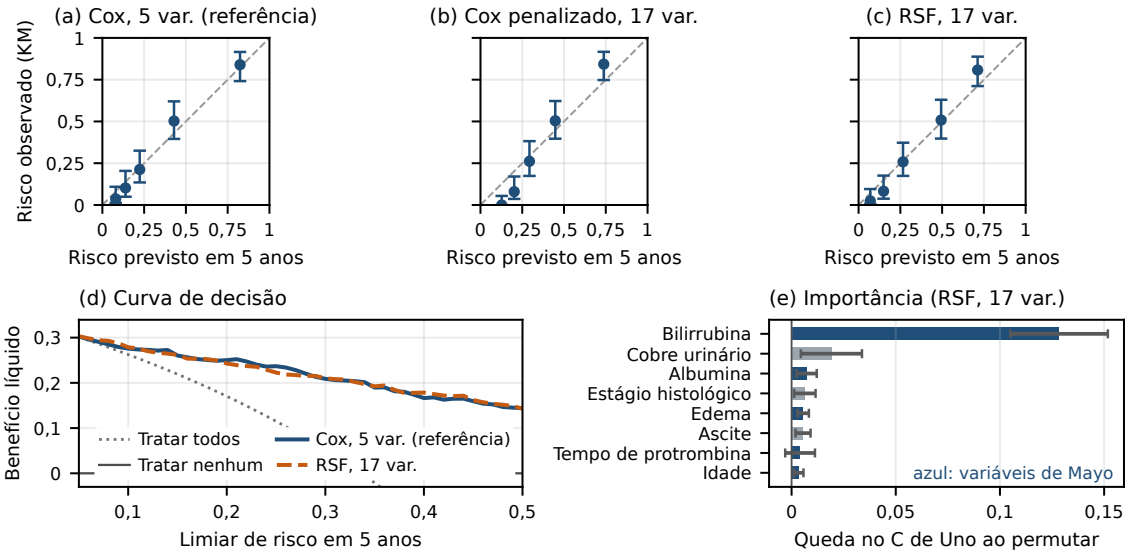


Figura 1. (a) a (c): calibração em cinco anos por quintis de risco previsto na referência, no Cox penalizado (acrescentado após os resultados por ser o desvio mais nítido) e na RSF de maior C de Uno médio (regra fixada após a primeira execução, que introduz seleção); barras: IC 95% do Kaplan-Meier; O/E na Tabela 2. (d) Curva de decisão em cinco anos, censura por Kaplan-Meier, para a referência e a mesma RSF, cuja curva pode ser otimista pela seleção. (e) Importância por permutação na RSF de 17 variáveis, só nas 5 partições da primeira repetição: queda média do C de Uno no teste (barras: desvio entre partições); as oito maiores.

desfecho houve ganho de AM sobre a fórmula.

Nos 106 pacientes não randomizados, que nenhum modelo viu no treino, o C de Uno foi de 0,790 (0,718 a 0,857) na referência, 0,806 no Cox penalizado, 0,797 na RSF de 5 variáveis, 0,807 na de 17 e 0,782 na fórmula inicial de 1989. Os modelos de 17 variáveis ficaram nominalmente à frente (diferenças pareadas, calculadas antes de arredondar, de até +0,016 contra o Cox reestimado e +0,024 contra a fórmula inicial), sem diferença demonstrada (42 eventos). O ajuste descritivo da referência (suplementar) deu evidência contra a proporcionalidade dos riscos só para o tempo de protrombina, de impacto preditivo não quantificado. Na importância por permutação da RSF de 17 variáveis (Figura 1e), a bilirrubina dominou (queda de 0,128 no C de Uno), seguida de longe por cobre (0,019) e albumina (0,007); da quarta posição em diante, a ordem está dentro do desvio entre partições e não deve ser interpretada.

4.4. De onde vêm os ganhos aparentes?

Algumas escolhas de avaliação produzem ganho sem que o modelo melhore. A Tabela 4 mede, nestes dados, o efeito de cada uma. Entre os contrastes em C de Uno, o maior foi avaliar o modelo nos próprios pacientes do treino: nos 312 randomizados, o C da RSF de 17 variáveis subiu 0,043, mais que qualquer diferença entre modelos da Tabela 3, medidas nos 418; o do Cox de Mayo subiu 0,007. Usar o tempo de seguimento como entrada, um vazamento, elevou a AUROC macro de um XGBoost em 0,034, em outra tarefa e métrica, na classificação anterior ao plano. Já avaliar a fórmula de 1989 nos pacientes em que foi estimada, ou trocar as variáveis do comparador pelas de [Graf et al. 2026], mudou o C em

Tabela 4. Escolhas de avaliação medidas nestes dados. No primeiro bloco, cada linha muda só a condição indicada; no segundo, a linha da fórmula muda também o modelo. Entre parênteses, IC 95% pareado ou contagem de partições; métricas e amostras diferem, e os efeitos não se somam.

Fonte	Comparação	Métrica	Efeito
Fontes de ganho aparente (sem intervalo pareado)			
Avaliar no próprio treino	RSF, 17 var.: no próprio treino contra fora da partição (312)	C de Uno	+0,043
	Cox de Mayo: idem (312)	C de Uno	+0,007
Vazamento do desfecho	XGBoost, 17 var., com e sem o tempo de seguimento (418; classificação)	AUROC macro	+0,034 (24 de 25 partições)
Escolhas que pouco mudaram o resultado (IC 95% pareado)			
Fórmula avaliada onde foi estimada	Fórmula de 1989 (estimada nos 312) contra Cox de Mayo ajustado só nos 312, fora da partição	C de Uno	+0,005 (−0,001 a 0,011)
Outras variáveis no comparador	Cox com as 7 variáveis de Graf et al. contra Cox de Mayo (312)	C de Uno	+0,001 (−0,012 a 0,013)
Sensibilidade da inferência (não é ganho)			
Sorteio do *bootstrap*	Limite superior do IC da RSF, 17 var., em 25 sementes (418)	C de Uno	0,0188 a 0,0212; acima de 0,02 em 10

poucos milésimos; a primeira dessas linhas muda também o modelo, e por isso não isola o efeito de avaliar na amostra de derivação. Na classificação de óbito em cinco anos, sem os censurados antes disso, nenhuma alternativa mostrou superioridade; a melhor, a regressão logística penalizada, teve AUROC +0,009 (intervalo de Bonferroni para 5 comparações, −0,017 a 0,035).

5. Discussão

A resposta à pergunta do título é "não demonstrado", e não "não supera". Nas duas inferências, nenhum modelo teve ganho demonstrado sobre o Cox de Mayo reestimado, no desfecho principal nem na sensibilidade só com óbito; em análise posterior, tampouco sobre a fórmula de 1989, avaliada onde foi estimada. Mas o estudo só descarta um ganho de 0,02 ou mais para a RSF de 5 variáveis, sem excluir ganhos menores; para o Cox penalizado e a RSF de 17 variáveis, a resposta é "não sabemos". Essa divisão é parte do resultado e decorre do tamanho do estudo: com 132 eventos até cinco anos (186 no seguimento todo), a meia-largura dos intervalos ficou na ordem da margem (Seção 4.1). Pela regra só do plano, a RSF de 17 variáveis também teria o ganho descartado; a regra combinada, posterior, endurece a leitura. Como o desenho favorece a referência (Seção 3.2), um resultado nulo era o mais provável; mantivemos esse desenho porque é o da pergunta de adoção, e não lemos o resultado como equivalência: ele vale para esse cenário, não como veredito sobre famílias de algoritmos, e é compatível, em sentido geral, com [Christodoulou et al. 2019].

Nestes dados, o trabalho também mede quanto cada escolha de avaliação muda o resultado (Tabela 4). O otimismo de avaliar no próprio treino (0,043 na RSF, nos 312, sem intervalo pareado; as diferenças entre modelos foram medidas nos 418) dá a ordem de grandeza do erro quando esse cuidado falta, não a explicação de resultados obtidos com outros protocolos. Avaliar a fórmula de 1989 onde foi estimada e trocar as variáveis

do comparador mudaram o C em milésimos, conclusão local: a fórmula foi estimada nestes mesmos pacientes, e em outra população a distância entre coeficientes congelados e reestimados pode ser maior. E o sorteio do *bootstrap*, que não é ganho, bastou para mudar a leitura da margem na RSF de 17 variáveis.

O contraste com [Graf et al. 2026] é instrutivo. Aquele trabalho usa *bootstrap* .632+, um estimador com correção de otimismo, e seu 0,776 para o Cox vem de outro protocolo (seguimento completo) e de um modelo que o texto não identifica; o otimismo medido aqui não o explica. Nos mesmos 312 e com as partições deste estudo, um Cox com as sete variáveis do conjunto final daquele trabalho teve C de Harrell de 0,819, praticamente igual ao do Cox de Mayo (0,817) e ao da RSF de 17 variáveis (0,819): com comparação pareada fora da amostra, a vantagem da RSF não aparece. As acurácias próximas de 90% em dados sintéticos derivados da coorte [Shakir et al. 2025, Tu 2025] tampouco são comparáveis: outro desfecho, outros dados e procedimentos, como balanceamento antes da divisão, que podem produzir vazamento [Kapoor and Narayanan 2023].

Limitações. Os dados vêm de um único centro, de 1974 a 1984, antes do ácido ursodesoxicólico, e não representam os pacientes atuais; não houve coorte externa. A ponderação pela censura supõe censura independente dos preditores, não verificada. Na sensibilidade com óbito, censurar os transplantados não dá a probabilidade observável de morrer antes do transplante, que exigiria riscos competitivos [Putter et al. 2007]. O desenho não é equilibrado (Seção 3.2). A comparação com a fórmula de 1989, a medida das fontes de ganho aparente e a regra de leitura combinada são posteriores aos resultados, e a primeira não é cega. Por fim, a conclusão vale para os modelos e grades avaliados; na sobrevivência, não testamos *boosting* nem redes neurais.

6. Conclusão

Na coorte pública da Mayo Clinic, sob plano prévio, nem a RSF nem o Cox penalizado mostraram ganho sobre o Cox reestimado com as cinco variáveis de Mayo na predição de óbito ou transplante em cinco anos. Para a RSF de 5 variáveis, o estudo descarta um ganho de 0,02 ou mais no C de Uno, sem excluir ganhos menores; para os outros dois, a resposta é "não sabemos", porque a coorte é pequena demais para decidir a margem escolhida. O resultado vale para um cenário de adoção que favorece a referência e penaliza os modelos de 17 variáveis pela imputação. Em análises posteriores, nenhum modelo superou a fórmula de 1989, avaliada onde foi estimada, e avaliar a floresta no próprio treino produziu um ganho aparente maior que qualquer diferença entre modelos. A lição é de método: julgar o ganho do AM contra o modelo clínico pertinente à população e ao momento da predição, fora da amostra de treino, com a incerteza explícita e sem variáveis que vazem o desfecho. A continuidade natural é repetir a comparação em coortes atuais de pacientes tratados, contra GLOBE e UK-PBC e com riscos competitivos, com a mesma pergunta: quanto o novo modelo acrescenta.

Declaração de uso de inteligência artificial generativa

Ferramentas de IA generativa foram usadas sob supervisão da autoria, que definiu pergunta, desenho, plano e regra de leitura, decidiu cada desvio e interpretou os resultados. O Claude (Anthropic) apoiou código, experimentos e redação; o Codex (OpenAI) auditou código e conclusões, sem permissão para alterar o repositório, onde estão seus relatórios;

outros agentes de IA fizeram revisões críticas e sugeriram e auditaram as análises do plano complementar; o ChatGPT (OpenAI) revisou o texto. A autoria responde pelo conteúdo final e conferiu os números.

Referências

Agência Gov (2025). Brasil bate recorde de transplantes e anuncia medidas para modernizar sistema e aumentar doações. Ministério da Saúde, 4 jun. 2025, `https://agenciagov.ebc.com.br`.

Brasil. Agência Nacional de Vigilância Sanitária (2022). Resolução RDC nº 657, de 24 de março de 2022: dispõe sobre a regularização de software como dispositivo médico (Software as a Medical Device – SaMD). Diário Oficial da União.

Cançado, G. G. L., Braga, M. H., Ferraz, M. L. G., Villela-Nogueira, C. A., Terrabuio, D. R. B., Cançado, E. L. R., et al. (2022). Clinical features and treatment outcomes of primary biliary cholangitis in a highly admixed population. *Annals of Hepatology*, 27(1):100546.

Carbone, M., Sharp, S. J., Flack, S., et al. (2016). The UK-PBC risk scores: derivation and validation of a scoring system for long-term prediction of end-stage liver disease in primary biliary cholangitis. *Hepatology*, 63(3):930–950.

Christodoulou, E., Ma, J., Collins, G. S., Steyerberg, E. W., Verbakel, J. Y., and Van Calster, B. (2019). A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *Journal of Clinical Epidemiology*, 110:12–22.

Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.

Dickson, E., Grambsch, P., Fleming, T., Fisher, L., and Langworthy, A. (1989a). Cirrhosis patient survival prediction. UCI Machine Learning Repository, `https://doi.org/10.24432/C5R02G`.

Dickson, E. R., Grambsch, P. M., Fleming, T. R., Fisher, L. D., and Langworthy, A. (1989b). Prognosis in primary biliary cirrhosis: model for decision making. *Hepatology*, 10(1):1–7.

Graf, E., Schmoor, C., Sauerbrei, W., and Schumacher, M. (1999). Assessment and comparison of prognostic classification schemes for survival data. *Statistics in Medicine*, 18(17–18):2529–2545.

Graf, R., Todd, S., and Baksh, M. F. (2026). Comparison of the Cox proportional hazards model and Random Survival Forest algorithm for predicting patient-specific survival probabilities in clinical trial data. *Biometrical Journal*, 68(5):e70171. Números citados da versão preprint, arXiv:2502.03119.

Grambsch, P. M. and Therneau, T. M. (1994). Proportional hazards tests and diagnostics based on weighted residuals. *Biometrika*, 81(3):515–526.

Ishwaran, H., Kogalur, U. B., Blackstone, E. H., and Lauer, M. S. (2008). Random survival forests. *The Annals of Applied Statistics*, 2(3):841–860.

Kapoor, S. and Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804.

Lammers, W. J., Hirschfield, G. M., Corpechot, C., et al. (2015). Development and validation of a scoring system to predict outcomes of patients with primary biliary cirrhosis receiving ursodeoxycholic acid therapy. *Gastroenterology*, 149(7):1804–1812.e4.

Lodi, V. K., Oliveira Júnior, C. L., Cerqueira, F. R., Fracalossi, K. O., Costa, G. D. d., and Fernandes, D. L. (2026). Predição de risco de Óbito por febre amarela em diferentes estágios do acompanhamento clínico usando aprendizado de máquina. In *Anais do XXVI Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS)*, pages 693–704, Porto Alegre. Sociedade Brasileira de Computação.

Nadeau, C. and Bengio, Y. (2003). Inference for the generalization error. *Machine Learning*, 52(3):239–281.

Pereira, R. G., Brito, L. E. L., Avelar, I., Carvalho, M., Vasconcelos, M., Brandão, M. A., and Meira Jr., W. (2026). Responsible AI for public health: A methodological illustration with a forecasting model applied to respiratory hospitalizations on SUS data. In *Anais do XXVI Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS)*, Porto Alegre. Sociedade Brasileira de Computação.

Pölsterl, S. (2020). scikit-survival: a library for time-to-event analysis built on top of scikit-learn. *Journal of Machine Learning Research*, 21(212):1–6.

Putter, H., Fiocco, M., and Geskus, R. B. (2007). Tutorial in biostatistics: competing risks and multi-state models. *Statistics in Medicine*, 26(11):2389–2430.

Reade, W. and Chow, A. (2023). Multi-class prediction of cirrhosis outcomes. Kaggle, Playground Series, Season 3, Episode 26, `https://kaggle.com/competitions/playground-series-s3e26`.

Shakir, Y. H., Mandhari, E. A. A. A., and Alkhazraji, A. (2025). Leveraging machine learning for early risk prediction in cirrhosis outcome patients. *Public Research Journal of Engineering, Data Technology and Computer Science*, 3(1):22–30.

Simon, N., Friedman, J., Hastie, T., and Tibshirani, R. (2011). Regularization paths for Cox's proportional hazards model via coordinate descent. *Journal of Statistical Software*, 39(5):1–13.

Tu, T. E. (2025). Predicting cirrhosis patient survival utilizing machine learning techniques. Master's thesis, University of California, Los Angeles.

Uno, H., Cai, T., Pencina, M. J., D'Agostino, R. B., and Wei, L.-J. (2011). On the C-statistics for evaluating overall adequacy of risk prediction procedures with censored survival data. *Statistics in Medicine*, 30(10):1105–1117.

Uno, H., Cai, T., Tian, L., and Wei, L.-J. (2007). Evaluating prediction rules for t-year survivors with censored regression models. *Journal of the American Statistical Association*, 102(478):527–537.

Vickers, A. J., Cronin, A. M., Elkin, E. B., and Gonen, M. (2008). Extensions to decision curve analysis, a novel method for evaluating diagnostic tests, prediction models and molecular markers. *BMC Medical Informatics and Decision Making*, 8:53.