O aprendizado de máquina realmente supera o modelo clínico? Um estudo de caso com plano prévio na colangite biliar primária

Autoria omitida para revisão

[1]Afiliação omitida para revisão

Abstract. *Machine learning (ML) models must add to the clinical model already in use. In this case study with a prior plan, we compared random survival forests (RSF) with 5 or 17 variables and a 17-variable penalized Cox model with a re-estimated five-variable Mayo Cox model in 418 patients with primary biliary cholangitis (death or transplant within five years). No model showed superiority in Uno's C (reference 0.831; differences −0.014 to +0.015), nor over the published 1989 Mayo formula; gains of 0.02 were ruled out only for the five-variable RSF. Calibration and net benefit showed no clear advantage. Evaluation choices, however, inflated performance: evaluating on the training data raised the RSF's C by 0.043, more than any difference between models.*

Resumo. *Modelos de aprendizado de máquina (AM) precisam acrescentar algo ao modelo clínico em uso. Num estudo de caso com plano prévio, comparamos random survival forests (RSF) com 5 ou 17 variáveis e um Cox penalizado com 17 a um Cox reestimado com as cinco variáveis de Mayo, em 418 pacientes com colangite biliar primária (óbito ou transplante em cinco anos). Nenhum modelo demonstrou superioridade no C de Uno (referência 0,831; diferenças de −0,014 a +0,015), nem contra a fórmula de Mayo publicada em 1989; ganhos de 0,02 só foram excluídos na RSF de 5 variáveis. Calibração e benefício líquido não mostraram vantagem clara. Já avaliar no próprio treino elevou o C da RSF em* 0,043*, mais que qualquer diferença entre modelos.*

1. Introdução

Modelos de aprendizado de máquina (AM) para a saúde costumam ser avaliados pelo seu desempenho isolado, mas a pergunta que interessa a quem vai adotá-los é outra: eles acrescentam algo ao que a clínica já usa? Este trabalho examina essa pergunta num caso clássico. A colangite biliar primária (CBP), chamada de cirrose biliar primária até 2015 [Beuers et al. 2015], é uma doença hepática autoimune e crônica que pode evoluir para cirrose, insuficiência hepática e transplante. Em 1989, o modelo de Mayo, uma regressão de Cox [Cox 1972] com cinco variáveis de rotina (idade, bilirrubina, albumina, tempo de protrombina e edema), derivada de dois ensaios clínicos da Mayo Clinic [Dickson et al. 1989b], tornou-se a referência clássica para estimar o risco que orienta a intensidade do acompanhamento e o momento de encaminhar o paciente ao transplante; escores posteriores o complementaram em pacientes tratados.

Os dados desses ensaios são públicos e se tornaram um conjunto clássico, primeiro em análise de sobrevivência [Fleming and Harrington 1991] e depois em AM, inclusive como exemplo no artigo que propôs a RSF [Ishwaran et al. 2008], no repositório da UCI

[Dickson et al. 1989a] e numa competição do Kaggle [Reade and Chow 2023]. Modelos de AM prometem mais precisão, mas trazem custos: perdem a transparência de uma fórmula de cinco termos e, quando usam mais variáveis, exigem mais exames. Por isso o que se mede aqui é o **valor incremental** do AM: o quanto ele acrescenta ao modelo clínico de referência, aqui reestimado e também na forma publicada. Uma revisão de 71 estudos não encontrou vantagem do AM sobre a regressão logística nas comparações com baixo risco de viés [Christodoulou et al. 2019].

Por que voltar a esses dados hoje? Porque eles continuam a servir de banco de provas para o AM em saúde, e conclusões otimistas continuam a ser publicadas sobre eles: a competição do Kaggle de 2023 gerou dados sintéticos a partir da coorte, trabalhos de 2025 relatam acurácias próximas de 90% nesse enquadramento [Shakir et al. 2025, Tu 2025], e um estudo publicado em 2026 relatou vantagem pontual de uma RSF sobre um Cox nos 312 pacientes randomizados [Graf et al. 2026]. Há dois obstáculos a uma comparação justa nesse conjunto. O primeiro é o enquadramento: muitos trabalhos tratam o problema como classificação, excluem quem foi censurado antes do horizonte ou usam o tempo de seguimento como entrada, o que vaza o desfecho [Kapoor and Narayanan 2023]. O segundo é a flexibilidade de análise: escolher métrica, modelos e critérios depois de ver os resultados torna fácil encontrar alguma vantagem.

A pergunta tem peso particular no Brasil. A CBP é acompanhada em centros de hepatologia de todo o país, e numa coorte de 28 centros brasileiros a resposta ao tratamento padrão variou de 39% a 67%, conforme o critério usado [Cançado et al. 2022]. O transplante hepático, destino dos casos graves, é majoritariamente público: o SUS financia mais de 85% dos transplantes do país, que realizou 2.454 transplantes de fígado em 2024 [Agência Gov 2025]. E um modelo de IA usado para apoiar decisões clínicas é tratado pela Anvisa como software dispositivo médico, cuja regularização exige validação [Brasil. Agência Nacional de Vigilância Sanitária 2022]. Saber se um modelo novo acrescenta algo ao que já se usa interessa, portanto, também à alocação de recursos públicos e à regulação, impactos que este trabalho não avalia.

Usamos essa coorte como estudo de caso de avaliação e perguntamos se modelos de AM para sobrevivência acrescentam valor, em discriminação, calibração e utilidade clínica, a um Cox reestimado com as cinco variáveis de Mayo, na predição de óbito ou transplante em até cinco anos. Não propomos um algoritmo novo nem um escore para uso clínico atual: a contribuição é empírica e de avaliação. Verificamos se uma vantagem como a relatada para a RSF nesta coorte [Graf et al. 2026] aparece com referência clínica, predições fora do treino, tratamento da censura e critérios fixados antes, e separamos três coisas que se confundem: não haver ganho demonstrado, poder descartar um ganho relevante e ter ganho aparente produzido pela forma de avaliar. O trabalho traz: (i) uma comparação 2×2 (Cox ou RSF; 5 ou 17 variáveis) com os 418 pacientes e as mesmas partições para todos os modelos; (ii) um plano registrado antes dos resultados de sobrevivência, com margem e regra de leitura, e desvios públicos; (iii) a medida, nestes mesmos dados, do ganho aparente produzido por escolhas de avaliação, como avaliar no próprio treino e o vazamento (Tabela 4), e a comparação com a fórmula publicada em 1989; e (iv) a reunião desses cuidados em cinco passos (Tabela 1), boas práticas conhecidas que podem orientar outras avaliações.

Tabela 1. Protocolo de avaliação do valor incremental, adaptável a outros conjuntos públicos de saúde: cada passo, o erro que ele evita e onde aparece neste artigo.

Passo	Erro que evita	Neste artigo
1. Registrar o plano, com margem de relevância e regra de leitura, antes dos resultados	Escolher métrica, modelo ou critério depois de ver os números	Seção 3
2. Comparar com o modelo clínico disponível, nas mesmas partições e de forma pareada	Creditar ao AM um desempenho que o modelo atual já tem	Tabela 3
3. Tratar a censura como sobrevivência, sem excluir pacientes pelo horizonte	Amostra selecionada pelo próprio desfecho	Seção 3; Seção 4.4
4. Avaliar calibração e benefício líquido, além da discriminação	Modelo que ordena bem, mas erra o risco ou não muda decisões	Figuras 1 e 2
5. Testar o efeito de variáveis indisponíveis no momento da predição	Vazamento que infla o desempenho	Tabela 4

2. Trabalhos relacionados

Os escores prognósticos de CBP são, em sua maioria, modelos de Cox. Depois do modelo de Mayo [Dickson et al. 1989b], a adoção do ácido ursodesoxicólico levou a escores para pacientes tratados, como o GLOBE [Lammers et al. 2015] e o UK-PBC [Carbone et al. 2016], construídos com exames medidos após um ano de tratamento e, portanto, para outro momento e outra população.

O trabalho mais próximo é o de [Graf et al. 2026], que compara Cox e RSF nos 312 pacientes randomizados, com um Cox de variáveis escolhidas por critérios de informação (e não as cinco de Mayo), C de Harrell e *bootstrap* .632+, com intervalos por modelo e nenhum para a diferença. A RSF teve valores pontuais melhores (C de 0,855 contra 0,776), mas os autores registram que os intervalos se sobrepõem, exceto em uma de seis regras de divisão; nas simulações, o Cox foi mais bem calibrado.

Os trabalhos recentes de AM sobre esse conjunto seguem o enquadramento da competição do Kaggle, com dados sintéticos gerados a partir do original [Reade and Chow 2023]: classificam o desfecho em três classes ou em óbito sem horizonte, sem avaliar calibração [Shakir et al. 2025, Tu 2025]. No próprio SBCAS, trabalhos recentes já mediram a inflação de desempenho causada por vazamento proposital, com dados do SUS [Pereira et al. 2026], e avaliaram a calibração ao prever óbito por febre amarela [Lodi et al. 2026]. No levantamento feito, não se encontrou estudo que compare, nos mesmos pacientes e partições, AM de sobrevivência com o Cox de Mayo, avaliando discriminação, calibração e benefício líquido sob um plano prévio. Este trabalho reúne esses cuidados num protocolo e mede o ganho contra uma referência clínica estabelecida.

3. Materiais e métodos

O relato se orienta pelo TRIPOD+AI [Collins et al. 2024], sem verificação formal de todos os itens. O plano de análise (desfechos, modelos, métricas, orçamento de ajuste, comparações e regra de leitura) foi registrado no controle de versões do repositório em 01/11/2026 (commit `677a281`), antes dos resultados da análise de sobrevivência, e não foi alterado, mas foi escrito após uma análise de classificação nos mesmos dados (Se-

ção 3.5): é prospectivo para a sobrevivência, não um pré-registro anterior a toda exploração. As mudanças posteriores são desvios (Seção 3.6).

3.1. Dados e desfechos

A coorte foi escolhida por ser pública e muito usada como referência para o AM, e não por representar os pacientes atuais: o objetivo é comparar modelos sob um protocolo comum, e não validar seu uso clínico hoje. O conjunto é o da Mayo Clinic, distribuído pela UCI (identificador 878, licença CC BY 4.0) [Dickson et al. 1989a] e pelo pacote `survival` do R. São 418 pacientes recrutados entre 1974 e 1984: 312 participaram de dois ensaios randomizados sobre D-penicilamina, e 106 eram elegíveis mas recusaram a randomização, tendo só as medidas de rotina [Dickson et al. 1989b, Fleming and Harrington 1991]. Cada paciente tem uma linha, com variáveis medidas no registro (linha de base), o desfecho (censura, óbito ou transplante) e o tempo até ele, em dias (`N_Days`).

O **desfecho principal** é a sobrevida livre de transplante: o evento é óbito ou transplante (186 pacientes, sendo 161 óbitos e 25 transplantes), e os 232 pacientes sem evento registrado até o último acompanhamento são censurados nesse momento. Todos os 418 pacientes entram na análise. Usaram-se todos os pacientes disponíveis, sem cálculo prévio de tamanho amostral; a precisão alcançada aparece na largura dos intervalos. O seguimento mediano foi de 7,0 anos (Kaplan-Meier reverso), e o horizonte de interesse é de cinco anos (1.826 dias), com 132 eventos até ele. Como **sensibilidade**, o evento é só o óbito, e o transplante é tratado como censura (161 eventos). Os preditores são as 5 variáveis de Mayo ou as 17 de linha de base. As 12 adicionais são sexo, tratamento atribuído (D-penicilamina ou placebo), ascite, hepatomegalia, aranhas vasculares, colesterol, cobre urinário, fosfatase alcalina, AST, triglicerídeos, plaquetas e estágio histológico, que exige biópsia; nove delas só foram colhidas nos ensaios e faltam nos 106 não randomizados, de modo que 276 pacientes têm as 17 completas, enquanto as 5 de Mayo faltam em apenas 2; as ausências por variável e por subgrupo estão no material suplementar. A coorte tem 374 mulheres (89,5%) e idade mediana de 51 anos. O tempo de seguimento nunca é preditor, porque só é conhecido depois do desfecho.

3.2. Modelos

O desenho é 2×2. A **referência** é um Cox de riscos proporcionais com as cinco variáveis de Mayo, nas mesmas transformações do modelo original (logaritmo de bilirrubina, albumina e protrombina), reestimado no treino de cada partição; não é a fórmula publicada em 1989, que além disso tratava o transplante como censura, e "Cox de Mayo" designa aqui esse modelo reestimado. Com as 17 variáveis, o Cox é penalizado por *elastic net* [Simon et al. 2011], que encolhe ou zera coeficientes para evitar o sobreajuste. Os modelos de AM são RSF [Ishwaran et al. 2008], florestas de 300 árvores de sobrevivência, com 5 e com 17 variáveis. Os hiperparâmetros são buscados em 50 configurações para cada floresta e em 40 combinações para o Cox penalizado; a referência não tem hiperparâmetros. A imputação de ausentes e a padronização são aprendidas só no treino de cada partição. Grades e pré-processamento estão detalhados no material suplementar. A comparação pergunta se o AM acrescenta valor à referência disponível, e não qual família de algoritmos é superior, e não é equilibrada: as variáveis e transformações de Mayo foram escolhidas em 1989 nos mesmos 312 pacientes randomizados desta coorte, o que favorece a referência, e nove das variáveis extras, inclusive o tratamento, faltam nos 106 não

randomizados e foram imputadas, o que desfavorece os modelos de 17 variáveis. Assim, o desenho 2×2 não isola o efeito do algoritmo nem o das variáveis extras.

3.3. Validação e métricas

A validação é cruzada, com 5 repetições de 5 partições estratificadas pelo evento, as mesmas para os quatro modelos, e os hiperparâmetros são escolhidos dentro do treino de cada partição (validação aninhada) [Varma and Simon 2006]. Cada modelo produz, para cada paciente, o risco previsto de ter o evento em até cinco anos, $\hat{r}$; a predição fora da partição é a média das 5 repetições, o que reduz o ruído e pode estreitar os intervalos.

Um paciente censurado deixou o acompanhamento sem evento; sabe-se apenas que, se o evento ocorreu, foi depois. Por isso, as métricas são próprias para sobrevivência e ponderam os pacientes pela chance de continuarem em acompanhamento. A **métrica principal** é o C de Uno em cinco anos [Uno et al. 2011], que mede se o modelo ordena bem os pacientes pelo risco: entre pares comparáveis, é a proporção em que quem teve o evento antes recebeu o risco maior (0,5 é o acaso; 1, a ordenação perfeita). Ele pondera os pares pela censura e corrige o viés do C de Harrell [Harrell et al. 1982] sob censura intensa. As secundárias são a AUC em cinco anos [Uno et al. 2007], que mede quão bem o risco separa quem teve e quem não teve o evento nesse prazo, e o escore de Brier em cinco anos e integrado de 1 a 5 anos [Graf et al. 1999], o erro quadrático da probabilidade prevista (menor é melhor). Um modelo é **calibrado** quando, entre pacientes com risco previsto de 20%, cerca de 20% têm o evento; comparamos, por quintis, o risco previsto com o observado por Kaplan-Meier e resumimos a coorte pela razão observado/esperado (O/E). A **utilidade clínica** é medida por curva de decisão [Vickers et al. 2008]: para a decisão hipotética de intensificar o acompanhamento, ou antecipar a avaliação para transplante, quando o risco passa de um limiar entre 5% e 50%, o benefício líquido desconta dos verdadeiros positivos os falsos positivos, com o peso que o limiar lhes dá.

3.4. Valor incremental e regra de leitura

Cada modelo é comparado à referência nos mesmos 418 pacientes: em 2.000 reamostragens *bootstrap* pareadas, calcula-se a diferença de C de Uno entre os dois, e os intervalos são ajustados para as três comparações (Bonferroni, 98,3%). Por usar as predições agregadas, a diferença não é a subtração das médias da Tabela 2. O plano fixou duas regras. Uma diferença só é demonstrada quando o intervalo exclui zero. E, se o limite superior ficar abaixo da **margem de +0,02** no C de Uno, ganhos dessa magnitude são descartados; a margem é um critério de leitura do estudo, não um limiar clínico validado. Esses intervalos medem a incerteza sobre os pacientes, não a do retreino; por isso, como sensibilidade posterior à auditoria (desvio D11), repetimos a leitura com o teste t corrigido para validação cruzada repetida [Nadeau and Bengio 2003], que mede essa outra fonte de incerteza; desde então, um ganho de 0,02 só é dado como excluído quando ambas o excluem.

3.5. Análises de apoio

Subgrupo fora do treino: treino nos 312 pacientes randomizados e teste nos 106 não randomizados (42 eventos); como nove das 17 variáveis faltam em todos os 106 e são imputadas, com 17 variáveis esse é um teste de transporte, não uma validação externa. **Pressupostos da referência:** um Cox descritivo nos 418 pacientes fornece razões de risco e o teste de riscos proporcionais de [Grambsch and Therneau 1994], calculados com

o *lifelines* [Davidson-Pilon 2019]; formas funcionais e observações influentes não foram examinadas. **Importância por permutação** da RSF de 17 variáveis: quanto o C de Uno cai no teste quando os valores de uma variável são embaralhados. **Fórmula publicada e fontes de ganho aparente**, num plano complementar registrado antes de executado: a fórmula de [Dickson et al. 1989b], sem reajuste, entra como segunda referência na discriminação (a versão de uso, estimada nos 418, na coorte; a inicial, estimada nos 312, no subgrupo); nos 312, compara-se um Cox com as sete variáveis do conjunto final de [Graf et al. 2026] e avalia-se cada modelo também no próprio treino. **Classificação:** duas formulações, analisadas antes do plano e documentadas no repositório: em (a), a regressão logística com as 5 variáveis é a referência, contra regressão penalizada, *random forest* e XGBoost; em (d), o mesmo XGBoost é ajustado com e sem o tempo de seguimento para prever as três classes do desfecho (censura, transplante e óbito). Os detalhes técnicos de todas as análises estão no material suplementar.

3.6. Desvios do plano e reprodutibilidade

Dezessete desvios e complementações estão registrados, com data e motivo. O principal veio de uma auditoria feita por outro agente de IA, sem permissão para alterar o repositório: na primeira execução, as florestas eram ajustadas com uma saída de risco diferente da usada na avaliação, que ordena os pacientes de outra forma; o procedimento foi corrigido e a análise repetida, e a primeira execução ficou registrada. Os demais são complementações: D3, anterior a qualquer resultado; D2 e D4 a D8, da mesma auditoria, entre a primeira execução e a final; D9 a D17, após os finais (regra de escolha do modelo de classificação exibido, entregas parciais, teste corrigido, outras sementes, a pergunta não respondida sobre algoritmo ou variáveis e o plano complementar, cuja análise da fórmula não é cega, pois um cálculo exploratório já era conhecido). Ficaram aquém do plano a AUC do subgrupo, sem intervalo pareado, e a importância por permutação (só a RSF de 17 variáveis, na primeira repetição). O experimento usa Python 3.13 e scikit-survival 0.28.0 [Pölsterl 2020]; versões, sementes e manifestos estão no material suplementar. Os dados são públicos e anonimizados, sem contato com pacientes. Código, dados, plano, desvios, cronologia dos *commits*, resultados e auditorias estão em um repositório público, com endereço anonimizado para a revisão (`https://anonymous.4open.science/r/ml4health-sbcas`).

4. Resultados

4.1. Discriminação e valor incremental

Nenhum modelo apresentou superioridade demonstrada na discriminação (Tabelas 2 e 3). A referência teve C de Uno médio de 0,833 entre partições e de 0,831 nas predições agregadas, base das diferenças, que ficaram entre $-0{,}014$ e +0,015; entre as 25 partições, o desvio da diferença foi de 0,017 a 0,018 (descritivo, não um intervalo). A Tabela 3 resume a leitura do valor incremental. Nenhuma diferença foi demonstrada, em nenhuma das duas inferências nem nos dois desfechos. Um ganho de 0,02 ou mais só pode ser descartado para a RSF de 5 variáveis. Na de 17, o plano o descarta por pouco (limite de 0,0197), mas isso não resiste ao teste corrigido nem a outras sementes do *bootstrap*: o limite passou de 0,02 em 10 de 25. Na AUC em cinco anos, também calculada nas predições agregadas, a RSF de 5 variáveis foi menor que a referência ($-0{,}024$; intervalo de $-0{,}047$ a $-0{,}001$), mas não no teste corrigido ($-0{,}048$ a 0,007); as demais não diferiram.

Tabela 2. Desempenho, desfecho principal (418 pacientes, 186 eventos): média (desvio) nas 25 partições; O/E (IC 95%) nas predições agregadas.

Modelo	C de Uno	AUC 5 anos	Brier 5 anos	Brier integr.	O/E 5 anos
Cox, 5 var.	0,833	0,889	0,128	0,102	0,99
(referência)	(0,029)	(0,031)	(0,021)	(0,009)	(0,87 a 1,10)
Cox penalizado, 17 var.	0,846	0,903	0,132	0,104	0,93
	(0,024)	(0,028)	(0,018)	(0,008)	(0,82 a 1,03)
RSF, 5 var.	0,821	0,869	0,143	0,107	0,99
	(0,034)	(0,039)	(0,019)	(0,009)	(0,87 a 1,10)
RSF, 17 var.	0,832	0,886	0,135	0,104	0,99
	(0,028)	(0,031)	(0,015)	(0,008)	(0,88 a 1,11)

Tabela 3. Valor incremental no C de Uno em cinco anos. ΔC nas predições agregadas (nelas, a referência tem C de 0,831**; só com óbito,** 0,850**). IC de Bonferroni (98,3%) pelo *bootstrap* do plano e pelo teste corrigido (este, centrado na diferença média por partição). Ganho descartado: limite superior abaixo de 0,02 nas duas. No último bloco, a referência é a fórmula publicada [Dickson et al. 1989b], avaliada nos pacientes em que foi estimada (C de** 0,831**); *IC de 95%.**

Desfecho e modelo	ΔC	IC, plano	IC, teste corrigido	Ganho de 0,02 descartado?
Óbito ou transplante (principal)				
Cox penalizado, 17 var.	0,015	−0,0042 a 0,0324	−0,012 a 0,038	não
RSF, 5 var.	−0,014	−0,0323 a 0,0042	−0,036 a 0,011	sim
RSF, 17 var.	−0,001	−0,0220 a 0,0197	−0,027 a 0,024	não (só no plano)
Só óbito (sensibilidade)				
Cox penalizado, 17 var.	0,010	−0,0064 a 0,0261	−0,009 a 0,030	não
RSF, 5 var.	−0,013	−0,0313 a 0,0030	−0,050 a 0,006	sim
RSF, 17 var.	−0,007	−0,0292 a 0,0144	−0,042 a 0,025	não (só no plano)
Óbito ou transplante, contra a fórmula de 1989 sem reajuste				
Cox, 5 var. (reestimado)*	0,001	−0,0054 a 0,0066	−0,007 a 0,010	sim
Cox penalizado, 17 var.	0,016	−0,0046 a 0,0357	−0,017 a 0,046	não
RSF, 5 var.	−0,013	−0,0367 a 0,0089	−0,041 a 0,019	sim
RSF, 17 var.	0,000	−0,0249 a 0,0237	−0,031 a 0,031	não

Contra a fórmula de Mayo publicada em 1989, sem reajuste (último bloco da Tabela 3), o quadro se repete: o Cox reestimado ficou praticamente igual a ela (diferença de 0,001), e nenhum modelo de AM mostrou ganho demonstrado, embora a fórmula seja avaliada nos próprios pacientes em que foi estimada, o que a favorece.

4.2. Calibração e utilidade clínica

Calibração e benefício líquido, avaliados de forma descritiva, não mostraram vantagem clara do AM. A razão O/E ficou próxima de 1 em todos os modelos (0,93 a 0,99), mas esse resumo global pode esconder erros em sentidos opostos, como superestimar o risco dos pacientes menos graves e subestimar o dos mais graves. Nos quintis (Figura 1; os quatro modelos estão no suplementar), os desvios da referência ficaram dentro dos intervalos, e a RSF de 17 variáveis previu 0,712 no quintil mais alto contra 0,808 observado, praticamente no limite do intervalo, o que sugere compressão das probabilidades nos riscos altos. O desvio mais nítido foi o do Cox penalizado, que superestimou o risco nos

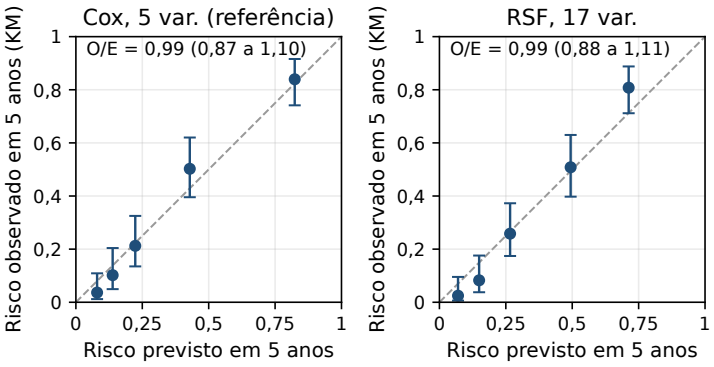


Figura 1. Calibração em cinco anos por quintis de risco previsto, na referência e na RSF de maior C de Uno médio (regra fixada após a primeira execução), sobre as predições fora da partição. Barras: IC 95% do Kaplan-Meier.

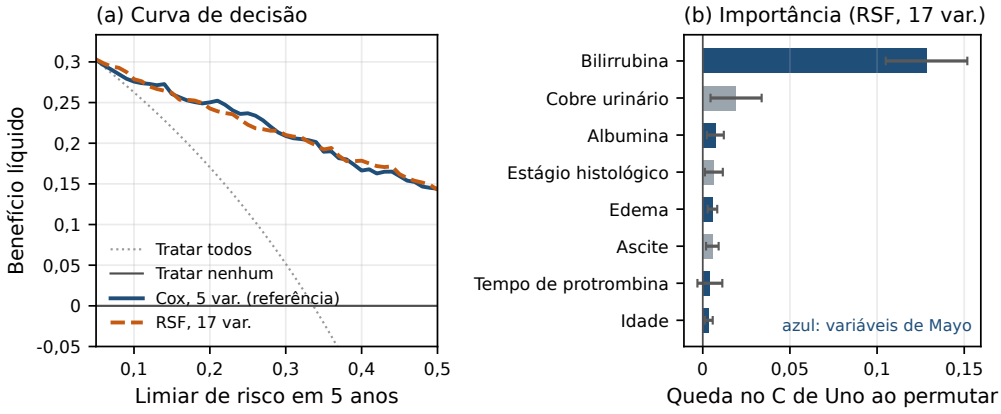


Figura 2. (a) Curva de decisão em cinco anos, com censura tratada por Kaplan-Meier; a RSF exibida foi escolhida pelo maior C de Uno nesta mesma coorte, o que introduz seleção e pode tornar sua curva otimista. (b) Importância por permutação na RSF de 17 variáveis: queda média do C de Uno no teste (barras: desvio entre as 5 partições); as oito maiores.

dois quintis mais baixos e o subestimou no mais alto, fora dos intervalos. No Brier, as três alternativas tiveram erro um pouco maior que a referência (Tabela 2). Na curva de decisão (Figura 2a), referência e RSF de 17 variáveis tiveram benefício líquido próximo nos 46 limiares (a maior diferença, de 0,015 ou 1,5 verdadeiro positivo líquido por 100 pacientes no limiar de 26%, favoreceu a referência; a RSF ficou à frente, por menos, em 29 dos 46), ambas acima de tratar todos e de não tratar ninguém; sem intervalo para a diferença nem margem de equivalência, isso não demonstra utilidade igual.

4.3. Subgrupo fora do treino e pressupostos da referência

No teste nos 106 pacientes não randomizados, que nenhum modelo viu no treino, o C de Uno foi de 0,790 (0,718 a 0,857) na referência, 0,806 no Cox penalizado, 0,797 na RSF de 5 variáveis e 0,807 na de 17: estimativas próximas, sem comparação pareada entre elas e, portanto, sem base para afirmar superioridade de nenhum. As razões O/E foram de 1,05, 1,06, 1,12 e 1,16, respectivamente, sem intervalo e com poucos eventos para

Tabela 4. Fontes de ganho aparente medidas nestes dados: cada linha muda uma só escolha de avaliação, com o resto fixo. Entre parênteses, IC 95% pareado por *bootstrap*. As métricas diferem entre linhas, e os efeitos não se somam.

Fonte	Comparação	Métrica	Efeito
Avaliar no próprio treino	RSF, 17 var., treinada e avaliada nos mesmos 312, contra fora da partição	C de Uno	+0,043
	Cox de Mayo, idem	C de Uno	+0,007
Vazamento do desfecho	XGBoost, 17 var., com e sem o tempo de seguimento (`N_Days`) na entrada, 418	AUROC macro	+0,034 (24 de 25 partições)
Referência avaliada onde foi estimada	Fórmula de 1989 (estimada nos 312) contra o mesmo Cox reestimado fora da partição, 312	C de Uno	+0,005 (−0,001 a 0,011)
Outras variáveis no comparador	Cox com as 7 variáveis de Graf et al. contra Cox de Mayo, 312	C de Uno	+0,001 (−0,012 a 0,013)
Sorteio do *bootstrap*	Limite superior da RSF, 17 var., com 25 sementes alternativas	C de Uno	0,0188 a 0,0212; acima de 0,02 em 10

interpretar as diferenças.

No ajuste descritivo da referência, as cinco variáveis se associaram ao desfecho na direção esperada (razões de risco e testes no material suplementar). Houve evidência contra a proporcionalidade dos riscos para o tempo de protrombina, também dentro de cinco anos; para as demais variáveis, o teste (com Bonferroni) não a detectou, o que não demonstra que o pressuposto valha para elas. Mesmo com essa possível violação, de impacto preditivo não quantificado, as florestas, que não dependem desse pressuposto, não superaram a referência. Na importância por permutação da RSF de 17 variáveis (Figura 2b), a bilirrubina dominou (queda de 0,128 no C de Uno), seguida de longe por cobre (0,019) e albumina (0,007), e as cinco variáveis de Mayo ficaram entre as oito mais importantes, resultado compatível com a floresta apoiar-se em preditores que a referência já usa. O tratamento não contribuiu para a predição, o que nada diz sobre sua eficácia.

4.4. De onde vêm os ganhos aparentes?

Algumas escolhas de avaliação produzem ganho sem que o modelo melhore. A Tabela 4 mede, nestes dados, o efeito de mudar uma só dessas escolhas por vez. O maior foi avaliar o modelo nos próprios pacientes do treino: o C de Uno da RSF de 17 variáveis subiu 0,043, mais que qualquer diferença entre modelos da Tabela 3, e o do Cox de Mayo, 0,007; a floresta, mais flexível, se ajusta mais ao treino. Usar o tempo de seguimento como entrada, um vazamento, elevou a AUROC macro de um XGBoost em 0,034, em outra tarefa e com outra métrica. Já avaliar a fórmula de 1989 nos pacientes em que foi estimada, ou trocar as variáveis do comparador pelas de [Graf et al. 2026], mudou o C em poucos milésimos. Na classificação de óbito em cinco anos, com exclusão dos censurados antes desse prazo, o melhor AM também não mostrou superioridade (AUROC +0,009; −0,017 a 0,035).

5. Discussão

Nenhum modelo teve ganho demonstrado sobre o Cox de Mayo nem sobre a fórmula publicada em 1989, nas duas inferências e com óbito isolado. Para dois dos três modelos,

porém, a resposta é inconclusiva, e isso decorre do tamanho do estudo: com 186 eventos, a meia-largura dos intervalos pareados ficou em torno de 0,02, a própria margem, de modo que um ganho de 0,02 só poderia ser descartado para um modelo com estimativa negativa. O Cox penalizado, o mais promissor, exigiria uma coorte bem maior. No único teste em que a fórmula publicada e os modelos treinados nos 312 foram avaliados em pacientes que nenhum deles viu, os 106 não randomizados, os modelos de 17 variáveis ficaram nominalmente à frente (até +0,024), sem demonstração, com 42 eventos. Calibração e benefício líquido, descritivos, não mostraram vantagem clara do AM, o que não equivale a demonstrar equivalência. O resultado é compatível, em sentido geral, com [Christodoulou et al. 2019]. Com 186 eventos e uma referência que já aproxima as relações por logaritmos, sobra pouco para a floresta aprender, e a informação se concentra na bilirrubina (Figura 2b); é uma explicação plausível, não testada.

Para além do caso, o trabalho mostra por que a forma de avaliar importa. Neste mesmo conjunto, os resultados publicados vão de acurácias próximas de 90% a vantagem pontual da RSF; aqui, comparado em pares com a referência, nenhum modelo mostrou ganho, mas escolhas de avaliação, medidas nos mesmos dados, produziram ganhos aparentes (Tabela 4), e avaliar no próprio treino deu à RSF mais que qualquer diferença entre modelos. Os cinco passos da Tabela 1 reúnem esses cuidados. Como princípio de avaliação, inclusive com dados do SUS, o recado é comparar o AM ao escore que a clínica já usa, nas mesmas partições e fora da amostra de treino, e verificar se o ganho resiste à retirada das variáveis que só existem depois do desfecho.

O contraste com [Graf et al. 2026] é instrutivo. Nos mesmos 312 randomizados e com as partições deste estudo, um Cox com as sete variáveis do conjunto final daquele trabalho teve C de Harrell de 0,819, praticamente igual ao do Cox de Mayo (0,817) e ao da RSF de 17 variáveis (0,819), bem acima do 0,776 relatado para o Cox naquele trabalho. Os protocolos diferem em seleção de variáveis, validação e intervalos, e este estudo não identifica o fator que explica a diferença; o que se mostra é que, com comparação pareada fora da amostra, a vantagem da RSF não aparece nestes dados. As acurácias próximas de 90% do enquadramento do Kaggle [Shakir et al. 2025, Tu 2025] também não são comparáveis: outro desfecho e dados sintéticos; além disso, procedimentos descritos nesses trabalhos, como balanceamento antes da divisão e teste nos pacientes que geraram os dados de treino, podem produzir vazamento [Kapoor and Narayanan 2023].

Limitações. Os dados vêm de um único centro, de 1974 a 1984, antes do ácido ursodesoxicólico, e não representam os pacientes atuais; não houve coorte externa. A ponderação pela censura supõe censura independente, estimada por Kaplan-Meier marginal, sem verificação de dependência em relação aos preditores. Na sensibilidade com óbito, os transplantados foram censurados; o resultado não é, portanto, a probabilidade observável de morrer antes de um transplante, que exigiria tratar o transplante como evento competitivo [Putter et al. 2007]. O desenho não é equilibrado (Seção 3.2), e as famílias também diferem no pré-processamento. Por fim, a conclusão vale para os modelos, as grades e o orçamento de ajuste avaliados; na sobrevivência, não testamos *boosting* nem redes neurais.

6. Conclusão

Na coorte pública da Mayo Clinic, sob um plano de análise registrado antes dos resultados, nem a RSF nem o Cox penalizado acrescentaram valor demonstrável ao Cox reestimado com as cinco variáveis de Mayo, nem à fórmula publicada em 1989, na predição de óbito ou transplante em cinco anos; ganhos de 0,02 no C de Uno só puderam ser excluídos para a RSF de 5 variáveis. Medido nos mesmos dados, avaliar no próprio treino produziu um ganho aparente maior que qualquer diferença entre modelos. Como lição, um ganho do AM deve ser julgado contra a referência clínica, fora da amostra de treino, com a incerteza explícita e sem variáveis que vazem o desfecho; esses cuidados podem orientar avaliações em outros conjuntos públicos de saúde. A continuidade natural é repetir a comparação em coortes atuais de pacientes tratados, em que GLOBE e UK-PBC são as referências, com análise de riscos competitivos, mantendo a pergunta que orientou este trabalho: quanto o novo modelo acrescenta ao que a clínica já usa, e a que custo.

Declaração de uso de inteligência artificial generativa

Ferramentas de IA generativa foram usadas sob supervisão da autoria. O Claude (Anthropic) apoiou a escrita do código de análise, a execução dos experimentos e a redação do texto. O Codex (OpenAI) auditou o código e as conclusões como agente separado, sem permissão para alterar o repositório, e seus relatórios estão no repositório; outro agente de IA, sem acesso à produção do texto, fez uma revisão crítica do artigo. O ChatGPT (OpenAI) foi usado na revisão do texto. Todas as decisões de desenho, a interpretação dos resultados e o conteúdo final são de responsabilidade da autoria, que conferiu os números contra os arquivos de resultados.

Referências

Agência Gov (2025). Brasil bate recorde de transplantes e anuncia medidas para modernizar sistema e aumentar doações. Ministério da Saúde, 4 jun. 2025, `https://agenciagov.ebc.com.br`.

Beuers, U., Gershwin, M. E., Gish, R. G., et al. (2015). Changing nomenclature for PBC: from "cirrhosis" to "cholangitis". *Hepatology*, 62(5):1620–1622.

Brasil. Agência Nacional de Vigilância Sanitária (2022). Resolução RDC nº 657, de 24 de março de 2022: dispõe sobre a regularização de software como dispositivo médico (Software as a Medical Device – SaMD). Diário Oficial da União.

Cançado, G. G. L., Braga, M. H., Ferraz, M. L. G., Villela-Nogueira, C. A., Terrabuio, D. R. B., Cançado, E. L. R., et al. (2022). Clinical features and treatment outcomes of primary biliary cholangitis in a highly admixed population. *Annals of Hepatology*, 27(1):100546.

Carbone, M., Sharp, S. J., Flack, S., et al. (2016). The UK-PBC risk scores: derivation and validation of a scoring system for long-term prediction of end-stage liver disease in primary biliary cholangitis. *Hepatology*, 63(3):930–950.

Christodoulou, E., Ma, J., Collins, G. S., Steyerberg, E. W., Verbakel, J. Y., and Van Calster, B. (2019). A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *Journal of Clinical Epidemiology*, 110:12–22.

Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.

Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2):187–202. Com discussão, p. 202–220.

Davidson-Pilon, C. (2019). lifelines: survival analysis in Python. *Journal of Open Source Software*, 4(40):1317.

Dickson, E., Grambsch, P., Fleming, T., Fisher, L., and Langworthy, A. (1989a). Cirrhosis patient survival prediction. UCI Machine Learning Repository, `https://doi.org/10.24432/C5R02G`.

Dickson, E. R., Grambsch, P. M., Fleming, T. R., Fisher, L. D., and Langworthy, A. (1989b). Prognosis in primary biliary cirrhosis: model for decision making. *Hepatology*, 10(1):1–7.

Fleming, T. R. and Harrington, D. P. (1991). *Counting Processes and Survival Analysis*. John Wiley & Sons, New York.

Graf, E., Schmoor, C., Sauerbrei, W., and Schumacher, M. (1999). Assessment and comparison of prognostic classification schemes for survival data. *Statistics in Medicine*, 18(17–18):2529–2545.

Graf, R., Todd, S., and Baksh, M. F. (2026). Comparison of the Cox proportional hazards model and Random Survival Forest algorithm for predicting patient-specific survival probabilities in clinical trial data. *Biometrical Journal*, 68(5):e70171. Números citados da versão preprint, arXiv:2502.03119.

Grambsch, P. M. and Therneau, T. M. (1994). Proportional hazards tests and diagnostics based on weighted residuals. *Biometrika*, 81(3):515–526.

Harrell, Jr., F. E., Califf, R. M., Pryor, D. B., Lee, K. L., and Rosati, R. A. (1982). Evaluating the yield of medical tests. *JAMA*, 247(18):2543–2546.

Ishwaran, H., Kogalur, U. B., Blackstone, E. H., and Lauer, M. S. (2008). Random survival forests. *The Annals of Applied Statistics*, 2(3):841–860.

Kapoor, S. and Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804.

Lammers, W. J., Hirschfield, G. M., Corpechot, C., et al. (2015). Development and validation of a scoring system to predict outcomes of patients with primary biliary cirrhosis receiving ursodeoxycholic acid therapy. *Gastroenterology*, 149(7):1804–1812.e4.

Lodi, V. K., Oliveira Júnior, C. L., Cerqueira, F. R., Fracalossi, K. O., Costa, G. D. d., and Fernandes, D. L. (2026). Predição de risco de Óbito por febre amarela em diferentes estágios do acompanhamento clínico usando aprendizado de máquina. In *Anais do XXVI Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS)*, pages 693–704, Porto Alegre. Sociedade Brasileira de Computação.

Nadeau, C. and Bengio, Y. (2003). Inference for the generalization error. *Machine Learning*, 52(3):239–281.

Pereira, R. G., Brito, L. E. L., Avelar, I., Carvalho, M., Vasconcelos, M., Brandão, M. A., and Meira Jr., W. (2026). Responsible AI for public health: A methodological illustration with a forecasting model applied to respiratory hospitalizations on SUS data. In *Anais do XXVI Simpósio Brasileiro de Computação Aplicada à Saúde (SBCAS)*, Porto Alegre. Sociedade Brasileira de Computação.

Pölsterl, S. (2020). scikit-survival: a library for time-to-event analysis built on top of scikit-learn. *Journal of Machine Learning Research*, 21(212):1–6.

Putter, H., Fiocco, M., and Geskus, R. B. (2007). Tutorial in biostatistics: competing risks and multi-state models. *Statistics in Medicine*, 26(11):2389–2430.

Reade, W. and Chow, A. (2023). Multi-class prediction of cirrhosis outcomes. Kaggle, Playground Series, Season 3, Episode 26, `https://kaggle.com/competitions/playground-series-s3e26`.

Shakir, Y. H., Mandhari, E. A. A. A., and Alkhazraji, A. (2025). Leveraging machine learning for early risk prediction in cirrhosis outcome patients. *Public Research Journal of Engineering, Data Technology and Computer Science*, 3(1):22–30.

Simon, N., Friedman, J., Hastie, T., and Tibshirani, R. (2011). Regularization paths for Cox's proportional hazards model via coordinate descent. *Journal of Statistical Software*, 39(5):1–13.

Tu, T. E. (2025). Predicting cirrhosis patient survival utilizing machine learning techniques. Master's thesis, University of California, Los Angeles.

Uno, H., Cai, T., Pencina, M. J., D'Agostino, R. B., and Wei, L.-J. (2011). On the C-statistics for evaluating overall adequacy of risk prediction procedures with censored survival data. *Statistics in Medicine*, 30(10):1105–1117.

Uno, H., Cai, T., Tian, L., and Wei, L.-J. (2007). Evaluating prediction rules for t-year survivors with censored regression models. *Journal of the American Statistical Association*, 102(478):527–537.

Varma, S. and Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91.

Vickers, A. J., Cronin, A. M., Elkin, E. B., and Gonen, M. (2008). Extensions to decision curve analysis, a novel method for evaluating diagnostic tests, prediction models and molecular markers. *BMC Medical Informatics and Decision Making*, 8:53.