O aprendizado de máquina realmente supera o modelo clínico? Protocolo de avaliação e estudo de caso na colangite biliar primária

Autoria omitida para revisão

[1]Afiliação omitida para revisão

Abstract. *The five-variable Mayo Cox model (1989) is the classic prognostic reference in primary biliary cholangitis, and its public cohort is still used to test machine learning. As an evaluation case study, we compared random survival forests (RSF) and a 17-variable penalized Cox model with a re-estimated five-variable Mayo Cox model for five-year transplant-free survival (418 patients), under a plan committed before any result. No gain in Uno's C was shown (reference 0.833; differences −0.014 to +0.015); for both RSFs, gains of 0.02 or more were incompatible with the data in conditional intervals, borderline for the 17-variable RSF. Calibration and net benefit showed no advantage. Only follow-up time as input, which leaks the outcome, gave a consistent gain.*

Resumo. *O Cox de cinco variáveis de Mayo (1989) é a referência prognóstica clássica na colangite biliar primária, e sua coorte pública segue em uso para testar aprendizado de máquina. Como estudo de caso, comparamos random survival forests (RSF) e um Cox penalizado com 17 variáveis a um Cox reestimado com as cinco de Mayo, na sobrevida livre de transplante em cinco anos, com plano prévio. Nenhum ganho no C de Uno foi demonstrado (referência 0,833; diferenças de −0,014 a +0,015); para as RSF, ganhos de 0,02 ou mais foram incompatíveis com os dados em intervalos condicionais, de forma limítrofe na de 17. Calibração e benefício líquido não mostraram vantagem. Só o tempo de seguimento como entrada, que vaza o desfecho, deu ganho consistente.*

1. Introdução

Modelos de aprendizado de máquina (AM) para a saúde costumam ser avaliados pelo seu desempenho isolado, mas a pergunta que interessa a quem vai adotá-los é outra: eles acrescentam algo ao que a clínica já usa? Este trabalho examina essa pergunta num caso clássico. A colangite biliar primária (CBP), chamada de cirrose biliar primária até 2015 [Beuers et al. 2015], é uma doença hepática autoimune e crônica que pode evoluir para cirrose, insuficiência hepática e transplante. Desde 1989, o risco de cada paciente é estimado pelo modelo de Mayo, uma regressão de Cox [Cox 1972] com cinco variáveis de rotina (idade, bilirrubina, albumina, tempo de protrombina e edema), derivada de dois ensaios clínicos da Mayo Clinic [Dickson et al. 1989b]; o risco orienta a intensidade do acompanhamento e o momento de encaminhar o paciente ao transplante.

Os dados desses ensaios são públicos e se tornaram um conjunto clássico, primeiro em análise de sobrevivência [Fleming and Harrington 1991] e depois em AM, no repositório da UCI [Dickson et al. 1989a] e numa competição do Kaggle [Reade and Chow 2023]. Modelos de AM prometem mais precisão, mas trazem custos:

perdem a transparência de uma fórmula de cinco termos e, quando usam mais variáveis, exigem mais exames. Por isso o que se mede aqui é o **valor incremental** do AM: o quanto ele acrescenta ao modelo já disponível. Uma revisão de 71 estudos não encontrou vantagem do AM sobre a regressão logística nas comparações com baixo risco de viés [Christodoulou et al. 2019].

Por que voltar a esses dados hoje? Porque eles continuam a servir de banco de provas para o AM em saúde, e conclusões otimistas continuam a ser publicadas sobre eles: a competição do Kaggle de 2023 gerou dados sintéticos a partir da coorte, trabalhos de 2025 relatam acurácias próximas de 90% nesse enquadramento [Shakir et al. 2025, Tu 2025], e um estudo publicado em 2026, nos 312 pacientes randomizados, relatou C de Harrell de 0,855 para uma RSF contra 0,776 para um Cox, com intervalos por modelo em geral sobrepostos e sem intervalo para a diferença [Graf et al. 2026]. Há dois obstáculos a uma comparação justa nesse conjunto. O primeiro é o enquadramento: muitos trabalhos tratam o problema como classificação, excluem quem foi censurado antes do horizonte ou usam o tempo de seguimento como entrada, o que vaza o desfecho [Kapoor and Narayanan 2023]. O segundo é a flexibilidade de análise: escolher métrica, modelos e critérios depois de ver os resultados torna fácil encontrar alguma vantagem.

Este trabalho usa essa coorte como estudo de caso de avaliação e pergunta se modelos de AM para sobrevivência acrescentam valor, em discriminação, calibração e utilidade clínica, a um Cox reestimado com as cinco variáveis de Mayo, na predição de óbito ou transplante em até cinco anos, e se um eventual ganho viria do algoritmo ou das variáveis extras. As contribuições são: (i) uma comparação 2×2 (Cox ou RSF; 5 ou 17 variáveis) em análise de sobrevivência, com todos os 418 pacientes, as mesmas partições para todos os modelos e o mesmo orçamento de busca para as duas florestas; (ii) um plano de análise registrado antes dos resultados, com margem de relevância e regra de leitura fixadas, e o registro público de todos os desvios; (iii) uma comparação descritiva de quatro enquadramentos da tarefa, em que a ausência de ganho demonstrado só muda quando o tempo de seguimento vaza para a entrada; e (iv) um protocolo de avaliação replicável em outros conjuntos públicos de saúde, com código, dados, plano, desvios e resultados abertos.

2. Trabalhos relacionados

Os escores prognósticos de CBP são, em sua maioria, modelos de Cox. Depois do modelo de Mayo [Dickson et al. 1989b], a adoção do ácido ursodesoxicólico levou a escores para pacientes tratados, como o GLOBE [Lammers et al. 2015] e o UK-PBC [Carbone et al. 2016], construídos com exames medidos após um ano de tratamento e, portanto, para outro momento e outra população.

O trabalho mais próximo deste é o de [Graf et al. 2026], que compara Cox e RSF nos 312 pacientes randomizados. O Cox usa variáveis escolhidas por comparação de modelos pelos critérios de Akaike e Bayesiano, e não as cinco de Mayo; a discriminação é medida pelo C de Harrell e a validação é feita por *bootstrap* .632+, com intervalos por modelo. A RSF teve valores pontuais melhores (C de 0,855 contra 0,776), mas os próprios autores registram que os intervalos se sobrepõem e não permitem conclusão definitiva, exceto para uma das seis regras de divisão avaliadas, cujo intervalo excluiu o valor do Cox; nas simulações, o Cox foi mais bem calibrado. O presente trabalho difere em quatro

pontos: usa os 418 pacientes, toma como referência as cinco variáveis de Mayo, compara os modelos de forma pareada nas mesmas partições e fixa a margem de relevância antes dos resultados.

Os trabalhos recentes de AM sobre esse conjunto seguem o enquadramento da competição do Kaggle, cujos dados são sintéticos, gerados a partir do original [Reade and Chow 2023]. Eles classificam o desfecho em três classes ou em óbito sem horizonte e relatam acurácias próximas de 90%, sem avaliar calibração [Shakir et al. 2025, Tu 2025], omissão frequente que já foi chamada de calcanhar de Aquiles da análise preditiva [Van Calster et al. 2019]. No levantamento feito, não se encontrou estudo que compare, nos mesmos pacientes e partições, AM de sobrevivência com o Cox de Mayo, avaliando discriminação, calibração e benefício líquido sob um plano prévio.

3. Materiais e métodos

O relato se orienta pelo TRIPOD+AI [Collins et al. 2024], sem verificação formal de todos os itens. O plano de análise (desfechos, modelos, métricas, orçamento de ajuste, comparações e regra de leitura) foi registrado no controle de versões do repositório antes de qualquer resultado e não foi alterado. Toda mudança posterior está registrada em uma lista de desvios, resumida na Seção 3.6.

3.1. Dados e desfechos

O conjunto é o da Mayo Clinic, distribuído pela UCI (identificador 878, licença CC BY 4.0) [Dickson et al. 1989a] e pelo pacote `survival` do R. Usou-se uma cópia versionada e verificada por SHA-256, idêntica à da UCI em todos os valores. São 418 pacientes recrutados entre 1974 e 1984: 312 participaram de dois ensaios randomizados sobre D-penicilamina, e 106 eram elegíveis mas recusaram a randomização (106 dos 112 que recusaram; os demais foram perdidos no seguimento), tendo só as medidas de rotina [Dickson et al. 1989b, Fleming and Harrington 1991]. Cada paciente tem uma linha, com variáveis medidas no registro (linha de base), o desfecho (censura, óbito ou transplante) e o tempo até ele, em dias (`N_Days`).

O **desfecho principal** é a sobrevida livre de transplante: o evento é óbito ou transplante (186 pacientes, sendo 161 óbitos e 25 transplantes), e os 232 pacientes sem evento registrado até o último acompanhamento são censurados nesse momento. Todos os 418 pacientes entram na análise. Usaram-se todos os pacientes disponíveis, sem cálculo prévio de tamanho amostral; a precisão alcançada aparece na largura dos intervalos. O seguimento mediano foi de 7,0 anos (Kaplan-Meier reverso), e o horizonte de interesse é de cinco anos (1.826 dias), com 132 eventos até ele. Como **sensibilidade**, o evento é só o óbito, e o transplante é tratado como censura (161 eventos). Os preditores são as 5 variáveis de Mayo ou as 17 de linha de base. As 12 adicionais são sexo, tratamento atribuído (D-penicilamina ou placebo), ascite, hepatomegalia, aranhas vasculares, colesterol, cobre urinário, fosfatase alcalina, AST, triglicerídeos, plaquetas e estágio histológico, que exige biópsia; nove delas só foram colhidas nos ensaios e faltam nos 106 não randomizados, de modo que 276 pacientes têm as 17 completas, enquanto as 5 de Mayo faltam em apenas 2; as ausências por variável e por subgrupo estão no material suplementar. A coorte tem 374 mulheres (89,5%) e idade mediana de 51 anos. O tempo de seguimento nunca é preditor, porque só é conhecido depois do desfecho.

3.2. Modelos

O desenho é 2×2. A **referência** é o Cox de riscos proporcionais com as cinco variáveis de Mayo, com bilirrubina, albumina e protrombina em logaritmo, como no modelo original, e sem penalização. É um modelo reestimado no treino de cada partição, e não a fórmula publicada em 1989, que além disso tratava o transplante como censura; ao longo do texto, "Cox de Mayo" designa esse modelo reestimado. Com as 17 variáveis, o Cox é penalizado por *elastic net* [Simon et al. 2011], com proporção L1 em $\{0{,}1;\ 0{,}5;\ 0{,}9;\ 1\}$ e 10 intensidades log-espaçadas entre 10^{-3} e 1. Os modelos de AM são RSF [Ishwaran et al. 2008] com 300 árvores e busca aleatória de 50 configurações (tamanho mínimo da folha, tamanho mínimo para divisão, variáveis por divisão e profundidade), com 5 e com 17 variáveis. O orçamento de ajuste é, portanto, de 50 configurações para cada floresta e de 40 combinações (a grade completa) para o Cox penalizado; a referência não tem hiperparâmetros a ajustar. Nos modelos de Cox, as transformações (logaritmo dos exames assimétricos, imputação pela mediana com 5 variáveis ou iterativa com 17, e padronização) são aprendidas só no treino de cada partição. Nas florestas, a imputação é feita na escala original, sem padronização.

3.3. Validação e métricas

A validação é cruzada, com 5 repetições de 5 partições estratificadas pelo indicador de evento, e as mesmas partições servem aos quatro modelos. Os hiperparâmetros são escolhidos por validação aninhada [Varma and Simon 2006], com 3 partições internas e critério igual ao da métrica principal. Cada modelo produz, para cada paciente, o risco previsto em cinco anos, $\hat{r}(\mathbf{x}) = 1 - \hat{S}(1.826 \mid \mathbf{x})$, em que $\hat{S}$ é a função de sobrevivência estimada. A predição fora da partição é a média das 5 repetições.

Um paciente censurado saiu do acompanhamento sem evento; sabe-se apenas que, se o evento ocorreu, foi depois. A **métrica principal** é o índice C de Uno truncado em cinco anos [Uno et al. 2011], calculado sobre $\hat{r}$: a probabilidade de que, entre dois pacientes, o que teve o evento antes (até cinco anos) tenha recebido o risco maior, com pesos pelo inverso da probabilidade de censura, o que corrige o viés do C de Harrell [Harrell et al. 1982] quando a censura é intensa; varia de 0 a 1, em que 0,5 corresponde ao acaso e 1 à ordenação perfeita. As métricas secundárias são a AUC dependente do tempo em cinco anos [Uno et al. 2007] (quão bem o risco separa quem teve o evento até cinco anos de quem passou dos cinco anos sem ele) e o escore de Brier em cinco anos e integrado de 1 a 5 anos (erro quadrático da probabilidade prevista; menor é melhor), com ponderação da mesma família [Graf et al. 1999]. Nas métricas por partição, a distribuição da censura é estimada por Kaplan-Meier no treino. Um modelo é calibrado quando, entre pacientes com risco previsto de 20%, cerca de 20% têm o evento. A calibração em cinco anos compara, por quintis de risco previsto, o risco médio previsto com o risco observado por Kaplan-Meier, com intervalos de 95% (Greenwood, transformação log-log; num quintil sem eventos, limite superior binomial exato com o número em risco aos cinco anos), e resume a coorte pela razão observado/esperado (O/E). A utilidade clínica é avaliada por curva de decisão [Vickers and Elkin 2006], com o benefício líquido em cinco anos estimado com tratamento da censura por Kaplan-Meier [Vickers et al. 2008], em limiares de risco de 5% a 50%, de 1 em 1 ponto. A decisão hipotética é intensificar o acompanhamento, ou antecipar a avaliação para transplante, quando o risco previsto passa

do limiar; o benefício líquido é a proporção de verdadeiros positivos menos a de falsos positivos ponderada pelo peso que o limiar atribui a cada um deles.

3.4. Valor incremental e regra de leitura

Para cada um dos três modelos contra a referência, calcula-se a diferença no C de Uno (principal) e na AUC em cinco anos sobre as predições fora da partição, com 2.000 reamostragens *bootstrap* pareadas de pacientes. Essa diferença é calculada uma vez sobre os 418 pacientes, e não pela subtração das médias por partição da Tabela 1, por isso os dois números não coincidem exatamente. Nessa análise, a distribuição da censura é estimada na coorte inteira e reestimada em cada reamostragem. Os intervalos usam a correção de Bonferroni para três comparações (nível de 98,3%). A leitura foi fixada no plano: "maior" ou "menor" só quando o intervalo exclui zero; e, se o limite superior ficar abaixo da **margem de relevância de +0,02** no C de Uno, ganhos dessa magnitude são declarados incompatíveis com os dados para aquele modelo. Esses intervalos são condicionais às predições obtidas: não incorporam a variação de refazer o treino e a seleção de hiperparâmetros. Essa variação aparece na dispersão da diferença entre as 25 partições.

3.5. Análises de apoio

Subgrupo independente. Os modelos são treinados nos 312 pacientes randomizados e testados nos 106 não randomizados (42 eventos). Nove das 17 variáveis faltam em todos os 106 e são reconstruídas pelo imputador do treino; por isso, com 17 variáveis, esse é um teste de transporte sob ausência estrutural, não uma validação externa. **Pressupostos da referência.** Um Cox descritivo, ajustado uma única vez nos 418 pacientes com as mesmas covariáveis e transformações da referência, fornece razões de risco em unidades clínicas e o teste de riscos proporcionais de [Grambsch and Therneau 1994], por variável, com correção de Bonferroni para 5 testes, no seguimento completo e censurado em cinco anos. Usou-se o *lifelines* [Davidson-Pilon 2019], que difere dos modelos preditivos em dois detalhes: trata empates pelo método de Efron e imputa os dois valores ausentes de protrombina antes do logaritmo. Formas funcionais e observações influentes não foram examinadas. **Importância por permutação** da RSF de 17 variáveis, fora da amostra: queda do C de Uno no teste ao permutar cada variável (30 permutações), nas 5 partições da primeira repetição. **Enquadramentos.** A Tabela 2 reúne quatro maneiras de formular a tarefa nos mesmos dados. As duas de classificação foram analisadas antes deste plano e estão documentadas no repositório: em (a), a regressão logística com as 5 variáveis é a referência, contra regressão penalizada, *random forest* e XGBoost; em (d), o mesmo XGBoost é ajustado com e sem o tempo de seguimento para prever as três classes do desfecho (censura, transplante e óbito).

3.6. Desvios do plano e reprodutibilidade

Dez desvios e complementações estão registrados, com data e motivo. O principal veio de uma auditoria independente: na primeira execução, a busca de hiperparâmetros calculava o C de Uno sobre o escore nativo de cada modelo, e a avaliação, sobre $\hat{r}$; no Cox as duas saídas ordenam igual, na RSF não. A segunda execução, aqui relatada, otimiza e avalia a mesma quantidade, e a primeira é citada como sensibilidade. Os demais são complementações de detalhe, de apresentação e das análises de apoio, fixadas antes dos resultados finais, com duas exceções registradas depois deles: a regra de escolha da Tabela 2 (D9) e

a documentação, sem mudança de procedimento, de escolhas já executadas e de entregas parciais (D10). Duas entregas ficaram aquém do plano: no subgrupo, só o C de Uno e a AUC têm intervalos de confiança, sem intervalo pareado da diferença; e a importância por permutação foi calculada só para a RSF de 17 variáveis, na primeira repetição. O experimento usa Python 3.13, scikit-learn 1.9.1, scikit-survival 0.28.0 [Pölsterl 2020] e semente 2026 (nas partições internas, sementes derivadas de 2026 a 2050), e cada execução grava um manifesto com versões, commit e comando. Código, dados, plano, desvios, resultados e relatórios de auditoria estão em um repositório público[1]. Os dados são públicos e anonimizados, e o estudo é uma análise secundária, sem contato com participantes.

4. Resultados

4.1. Discriminação e valor incremental

A Tabela 1 resume o desempenho. A referência teve C de Uno médio de 0,833, e as diferenças em relação a ela ficaram entre −0,014 e +0,015, menores que a variação da própria diferença entre as 25 partições (desvios de 0,017 a 0,018). Nenhuma diferença foi estatisticamente demonstrada. Para as duas RSF, o limite superior do intervalo ficou abaixo da margem de +0,02, e ganhos dessa magnitude são incompatíveis com os dados. No caso da RSF de 17 variáveis, porém, essa conclusão depende da quarta casa decimal (limite de 0,0197); na primeira execução, com a busca desalinhada, o limite foi de 0,0209. Para o Cox penalizado, que teve a maior diferença nominal (+0,015, ganho em 68% das 25 partições), um ganho relevante não pode ser excluído. Na AUC em cinco anos, a RSF de 5 variáveis foi menor que a referência (−0,024; intervalo de −0,047 a −0,001), e as demais não diferiram. O Cox penalizado manteve entre 9 e 16 das 17 variáveis nos modelos escolhidos, e o C de Uno médio calculado sobre o escore nativo de cada modelo diferiu do da Tabela 1 em até 0,0012.

Tabela 1. Desempenho na validação cruzada 5×5, desfecho principal (418 pacientes, 186 eventos). Média (desvio entre as 25 partições); O/E com IC 95% por *bootstrap*; ΔC: diferença no C de Uno contra a referência, com IC de Bonferroni (98,3%).

Modelo	C de Uno	AUC 5 anos	Brier 5 anos	Brier integr.	O/E 5 anos	ΔC de Uno
Cox, 5 var.	0,833	0,889	0,128	0,102	0,99	–
(referência)	(0,029)	(0,031)	(0,021)	(0,009)	(0,87 a 1,10)	
Cox penalizado, 17 var.	0,846	0,903	0,132	0,104	0,93	0,0148
	(0,024)	(0,028)	(0,018)	(0,008)	(0,82 a 1,03)	(−0,0042 a 0,0324)
RSF, 5 var.	0,821	0,869	0,143	0,107	0,99	−0,0136
	(0,034)	(0,039)	(0,019)	(0,009)	(0,87 a 1,10)	(−0,0323 a 0,0042)
RSF, 17 var.	0,832	0,886	0,135	0,104	0,99	−0,0010
	(0,028)	(0,031)	(0,015)	(0,008)	(0,88 a 1,11)	(−0,0220 a 0,0197)

Na sensibilidade com óbito como evento, o padrão se repetiu: a referência teve C de Uno de 0,854, e as diferenças foram de +0,010 (−0,006 a 0,026) no Cox penalizado, −0,013 (−0,031 a 0,003) na RSF de 5 variáveis e −0,007 (−0,029 a 0,014) na de 17, com ganhos de 0,02 incompatíveis com os dados para as duas florestas.

[1]Endereço anonimizado para a revisão: `https://anonymous.4open.science/r/ml4health-sbcas`.

4.2. Calibração e utilidade clínica

A razão O/E ficou próxima de 1 em todos os modelos (0,93 a 0,99), mas esse resumo global não demonstra calibração semelhante, porque erros locais em sentidos opostos se compensam. Os quintis mostram padrões diferentes (Figura 1; os quatro modelos estão no material suplementar do repositório). Na referência, o risco previsto no quintil mais baixo (0,080) ficou acima do observado (0,036), mas dentro do seu intervalo (0,012 a 0,109). Na RSF de 17 variáveis, o previsto no quintil mais alto (0,712) ficou abaixo do observado (0,808), praticamente no limite inferior do intervalo (0,712 a 0,888), o que sugere compressão das probabilidades nos riscos altos. O padrão mais nítido foi o do Cox penalizado: nos dois quintis mais baixos, o risco previsto (0,127 e 0,202) ficou acima do limite superior do observado (0,054, sem eventos até cinco anos, e 0,171), e no mais alto (0,738), abaixo do limite inferior (0,748). Na curva de decisão (Figura 2), as estimativas de benefício líquido da referência e da RSF de 17 variáveis ficaram próximas nos 46 limiares (maior diferença absoluta de 0,015, ou 1,5 verdadeiro positivo líquido por 100 pacientes), ambas acima das estratégias de tratar todos e de não tratar ninguém. Sem intervalo para a diferença nem margem de equivalência, essa proximidade não demonstra utilidade equivalente.

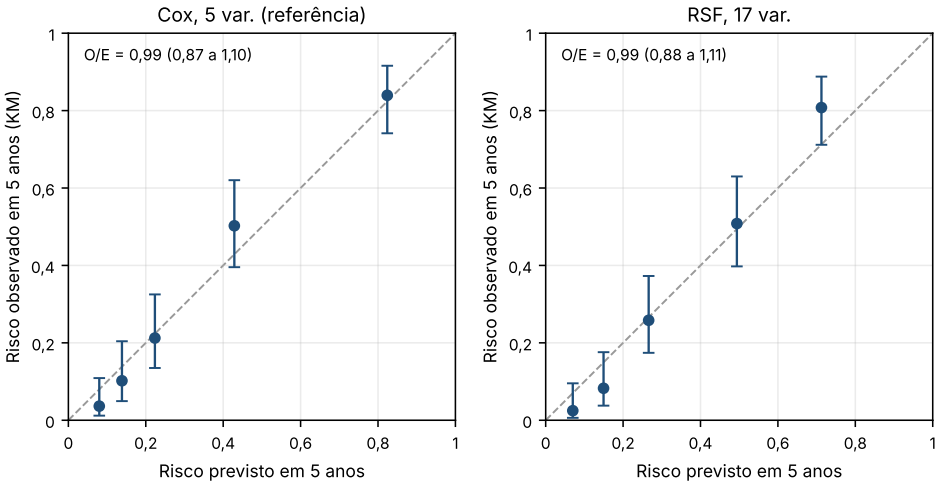


Figura 1. Calibração em cinco anos por quintis de risco previsto, na referência e na RSF de maior C de Uno médio (regra fixada antes da figura), sobre as predições fora da partição. Barras: IC 95% do Kaplan-Meier.

4.3. Subgrupo independente e pressupostos da referência

No teste nos 106 pacientes não randomizados, o C de Uno foi de 0,790 (0,718 a 0,857) na referência, 0,806 no Cox penalizado, 0,797 na RSF de 5 variáveis e 0,807 na de 17, com intervalos amplamente sobrepostos. As razões O/E foram de 1,05, 1,06, 1,12 e 1,16, respectivamente: as florestas subestimaram mais o risco nesse grupo. Como os intervalos não são pareados, esses números não sustentam comparações de superioridade.

No ajuste descritivo da referência, as cinco variáveis se associaram ao desfecho na direção esperada; por exemplo, cada duplicação da bilirrubina multiplicou o risco instantâneo por 1,79 (razões de risco e testes no material suplementar). Houve evidência contra a proporcionalidade dos riscos para o tempo de protrombina, também dentro de

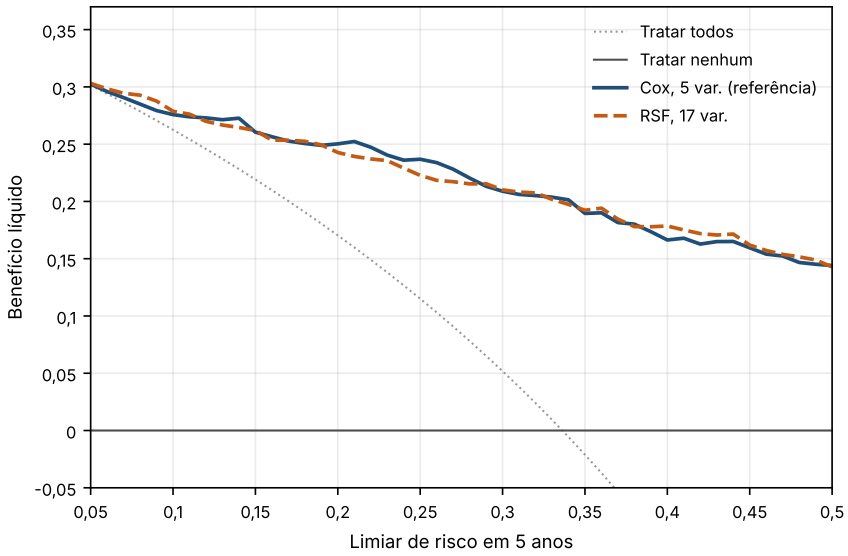


Figura 2. Curva de decisão em cinco anos, com censura tratada por Kaplan-Meier. A RSF exibida foi escolhida pelo maior C de Uno nesta mesma coorte, o que introduz seleção e pode tornar sua curva otimista.

cinco anos; para as demais variáveis, o teste não a detectou, o que não demonstra que o pressuposto valha para elas. A referência tem, portanto, ao menos uma variável cujo efeito parece variar no tempo e, mesmo assim, não foi superada pelas florestas, que não dependem desse pressuposto. Na importância por permutação da RSF de 17 variáveis, a bilirrubina dominou (queda de 0,128 no C de Uno), seguida de longe por cobre (0,019) e albumina (0,007); o tratamento não teve contribuição preditiva positiva, o que nada diz sobre sua eficácia.

4.4. O enquadramento muda a conclusão?

A Tabela 2 compara de forma descritiva as conclusões em quatro enquadramentos, mostrando em cada um o modelo com a maior diferença contra a referência, isto é, a escolha mais favorável ao AM. Os enquadramentos diferem em mais de um aspecto ao mesmo tempo, e a tabela não isola o efeito de nenhum deles: (a) e (c) têm o mesmo evento, mas diferem na tarefa, na amostra, na métrica e no comparador; (b) e (c) diferem só no desfecho. Em nenhuma das três primeiras linhas o intervalo exclui zero, e nelas o melhor resultado nominal veio de um modelo de regressão penalizada, não de árvores. A linha (d) responde a outra pergunta: com o mesmo modelo, incluir o tempo de seguimento como preditor elevou a AUROC macro em 0,034, com ganho em 24 das 25 partições, graças a uma informação indisponível no momento da predição. As métricas das linhas não estão na mesma escala, e a margem de 0,02 do C de Uno não se aplica às linhas de classificação.

5. Discussão

Nenhum modelo superou o Cox de Mayo, e essa ausência de ganho demonstrado se repetiu com óbito isolado, no subgrupo independente e nos enquadramentos de classificação. A exclusão de ganhos de 0,02 ou mais no C de Uno vale para as duas RSF, mas só na inferência condicional às predições e, na de 17 variáveis, de forma limítrofe; calibração

Tabela 2. Conclusões em quatro enquadramentos da tarefa (comparação descritiva). Em (a) a (c), o modelo com maior diferença contra a referência, com IC de Bonferroni de 99% em (a) (5 comparações) e de 98,3% em (b) e (c) (3 comparações). Em (d), o mesmo XGBoost com e sem `N_Days`, diferença pareada por partição; os 161 eventos são os óbitos, numa classificação em três classes (232 censuras, 25 transplantes, 161 óbitos).

Enquadramento	n / eventos	Métrica	Modelo	Δ	IC
(a) Classificação de óbito em 5 anos, sem os censurados antes de 5 anos	312 / 115	AUROC	RL penalizada, 17 var.	0,009	−0,017 a 0,035
(b) Sobrevivência, óbito ou transplante (principal)	418 / 186	C de Uno	Cox penalizado, 17 var.	0,015	−0,004 a 0,032
(c) Sobrevivência, só óbito	418 / 161	C de Uno	Cox penalizado, 17 var.	0,010	−0,006 a 0,026
(d) Classificação C/CL/D, `N_Days` na entrada	418 / 161	AUROC macro	XGBoost, 17 var., com e sem `N_Days`	0,034	sem IC; ganho em 96% das partições

e benefício líquido não mostraram vantagem do AM, o que não equivale a demonstrar equivalência. Isso está de acordo com a revisão de [Christodoulou et al. 2019]. Com 186 eventos e um modelo de referência que já usa transformações logarítmicas escolhidas para aproximar a relação de uma reta, sobra pouco espaço para interações e não linearidades que uma floresta possa aprender, e a importância por permutação mostra que a informação se concentra na bilirrubina. Essa explicação é plausível, mas o desenho não a testa.

Para além do caso, o trabalho ilustra como o protocolo condiciona a conclusão sobre o AM. Neste mesmo conjunto, os resultados publicados vão de acurácias próximas de 90% a vantagem pontual da RSF, e, aqui, a ausência de ganho só mudou quando o tempo de seguimento vazou para a entrada. O protocolo usado tem cinco passos replicáveis em outros conjuntos públicos de saúde: (1) registrar o plano, com margem de relevância e regra de leitura, antes dos resultados; (2) comparar com o modelo clínico disponível, nas mesmas partições e de forma pareada; (3) tratar a censura como sobrevivência, sem excluir pacientes pelo horizonte; (4) avaliar calibração e benefício líquido, além da discriminação; e (5) testar explicitamente o efeito de variáveis indisponíveis no momento da predição.

O contraste com [Graf et al. 2026] é instrutivo. Lá a RSF teve C de Harrell de 0,855 contra 0,776 do Cox. Aqui, o C de Harrell do Cox de referência foi de 0,814, e o da RSF de 17 variáveis, de 0,815. Os protocolos diferem em amostra (312 contra 418), referência (Cox com seleção de variáveis contra as cinco de Mayo), métrica, esquema de validação e ausência de intervalo para a diferença, e este trabalho não permite dizer qual desses fatores explica a diferença. O que ele mostra é que, sob um protocolo fixado antes dos resultados e com comparação pareada, a vantagem da RSF não aparece nestes dados. As acurácias próximas de 90% do enquadramento do Kaggle [Shakir et al. 2025, Tu 2025] também não são comparáveis: outro desfecho, dados sintéticos e duas formas de vazamento [Kapoor and Narayanan 2023], o balanceamento antes da divisão entre treino e teste e o teste nos pacientes que geraram os dados de treino.

Duas observações merecem destaque. A primeira é que o melhor resultado nominal veio sempre de uma regressão penalizada com 17 variáveis, e, para ela, um ganho

relevante não foi excluído; se as variáveis extras têm valor, os dados sugerem que um modelo linear as aproveita ao menos tão bem quanto as árvores, mas isso exigiria um estudo maior para ser afirmado. A segunda é que a evidência contra a proporcionalidade para a protrombina não veio acompanhada de vantagem para as florestas, que não dependem desse pressuposto. Uma leitura possível é que o impacto preditivo dessa violação no horizonte de cinco anos seja pequeno, mas isso é uma hipótese que o desenho não testa.

Limitações. Os dados vêm de um único centro, de 1974 a 1984, antes do ácido ursodesoxicólico, e não representam os pacientes atuais; não houve coorte externa. Os intervalos do valor incremental são condicionais às predições, e a margem só é excluída nessa inferência. A ponderação pela censura supõe censura independente, estimada por Kaplan-Meier marginal, sem verificação de dependência em relação aos preditores. Na sensibilidade com óbito, o transplante é tratado como censura: o risco estimado é o de uma análise de causa específica, hipotético na ausência de transplante, e não a incidência cumulativa observável de óbito, que exigiria uma análise de riscos competitivos [Putter et al. 2007]. O teste no subgrupo, com 17 variáveis, mede transporte sob ausência estrutural. As famílias diferem também no pré-processamento (imputação em escalas diferentes), e o desenho 2×2 não isola de forma estrita o efeito do algoritmo. Na RSF de 17 variáveis, a exclusão da margem é frágil. O Brier integrado usa uma grade anual de cinco pontos. Por fim, a conclusão vale para os modelos, as grades e o orçamento de ajuste avaliados.

6. Conclusão

Na coorte pública da Mayo Clinic, sob um plano de análise registrado antes dos resultados, nem a RSF nem o Cox penalizado com 17 variáveis acrescentaram valor demonstrável ao Cox reestimado com as cinco variáveis de Mayo na predição da sobrevida livre de transplante em cinco anos. Para as florestas, ganhos de 0,02 ou mais no C de Uno foram incompatíveis com os dados nos intervalos condicionais às predições, de forma limítrofe na RSF de 17 variáveis, e calibração e benefício líquido não mostraram vantagem. A ausência de ganho demonstrado se repetiu entre desfechos e enquadramentos; só o uso do tempo de seguimento como entrada produziu ganho, e esse ganho é vazamento. Como lição, a conclusão sobre o valor do AM depende do protocolo de avaliação, e o protocolo aqui descrito pode ser aplicado a outros conjuntos públicos. A continuidade natural é repetir a comparação em coortes atuais de pacientes tratados, em que GLOBE e UK-PBC são as referências, com análise de riscos competitivos, mantendo a pergunta que orientou este trabalho: quanto o novo modelo acrescenta ao que a clínica já usa, e a que custo.

Declaração de uso de inteligência artificial generativa

Ferramentas de IA generativa foram usadas sob supervisão da autoria. O Claude (Anthropic) apoiou a escrita do código de análise, a execução dos experimentos e a redação do texto. O Codex (OpenAI) atuou como auditor independente do código e das conclusões, sem permissão para alterar o repositório, e seus relatórios estão no repositório. O ChatGPT (OpenAI) foi usado na revisão do texto. Todas as decisões de desenho, a interpretação dos resultados e o conteúdo final são de responsabilidade da autoria, que conferiu os números contra os arquivos de resultados.

Referências

Beuers, U., Gershwin, M. E., Gish, R. G., et al. (2015). Changing nomenclature for PBC: from "cirrhosis" to "cholangitis". *Hepatology*, 62(5):1620–1622.

Carbone, M., Sharp, S. J., Flack, S., et al. (2016). The UK-PBC risk scores: derivation and validation of a scoring system for long-term prediction of end-stage liver disease in primary biliary cholangitis. *Hepatology*, 63(3):930–950.

Christodoulou, E., Ma, J., Collins, G. S., Steyerberg, E. W., Verbakel, J. Y., and Van Calster, B. (2019). A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *Journal of Clinical Epidemiology*, 110:12–22.

Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.

Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2):187–202. Com discussão, p. 202–220.

Davidson-Pilon, C. (2019). lifelines: survival analysis in Python. *Journal of Open Source Software*, 4(40):1317.

Dickson, E., Grambsch, P., Fleming, T., Fisher, L., and Langworthy, A. (1989a). Cirrhosis patient survival prediction. UCI Machine Learning Repository, `https://doi.org/10.24432/C5R02G`.

Dickson, E. R., Grambsch, P. M., Fleming, T. R., Fisher, L. D., and Langworthy, A. (1989b). Prognosis in primary biliary cirrhosis: model for decision making. *Hepatology*, 10(1):1–7.

Fleming, T. R. and Harrington, D. P. (1991). *Counting Processes and Survival Analysis*. John Wiley & Sons, New York.

Graf, E., Schmoor, C., Sauerbrei, W., and Schumacher, M. (1999). Assessment and comparison of prognostic classification schemes for survival data. *Statistics in Medicine*, 18(17–18):2529–2545.

Graf, R., Todd, S., and Baksh, M. F. (2026). Comparison of the Cox proportional hazards model and Random Survival Forest algorithm for predicting patient-specific survival probabilities in clinical trial data. *Biometrical Journal*, 68(5):e70171. Números citados da versão preprint, arXiv:2502.03119.

Grambsch, P. M. and Therneau, T. M. (1994). Proportional hazards tests and diagnostics based on weighted residuals. *Biometrika*, 81(3):515–526.

Harrell, Jr., F. E., Califf, R. M., Pryor, D. B., Lee, K. L., and Rosati, R. A. (1982). Evaluating the yield of medical tests. *JAMA*, 247(18):2543–2546.

Ishwaran, H., Kogalur, U. B., Blackstone, E. H., and Lauer, M. S. (2008). Random survival forests. *The Annals of Applied Statistics*, 2(3):841–860.

Kapoor, S. and Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804.

Lammers, W. J., Hirschfield, G. M., Corpechot, C., et al. (2015). Development and validation of a scoring system to predict outcomes of patients with primary biliary cirrhosis receiving ursodeoxycholic acid therapy. *Gastroenterology*, 149(7):1804–1812.e4.

Pölsterl, S. (2020). scikit-survival: a library for time-to-event analysis built on top of scikit-learn. *Journal of Machine Learning Research*, 21(212):1–6.

Putter, H., Fiocco, M., and Geskus, R. B. (2007). Tutorial in biostatistics: competing risks and multi-state models. *Statistics in Medicine*, 26(11):2389–2430.

Reade, W. and Chow, A. (2023). Multi-class prediction of cirrhosis outcomes. Kaggle, Playground Series, Season 3, Episode 26, `https://kaggle.com/competitions/playground-series-s3e26`.

Shakir, Y. H., Mandhari, E. A. A. A., and Alkhazraji, A. (2025). Leveraging machine learning for early risk prediction in cirrhosis outcome patients. *Public Research Journal of Engineering, Data Technology and Computer Science*, 3(1):22–30.

Simon, N., Friedman, J., Hastie, T., and Tibshirani, R. (2011). Regularization paths for Cox's proportional hazards model via coordinate descent. *Journal of Statistical Software*, 39(5):1–13.

Tu, T. E. (2025). Predicting cirrhosis patient survival utilizing machine learning techniques. Master's thesis, University of California, Los Angeles.

Uno, H., Cai, T., Pencina, M. J., D'Agostino, R. B., and Wei, L.-J. (2011). On the C-statistics for evaluating overall adequacy of risk prediction procedures with censored survival data. *Statistics in Medicine*, 30(10):1105–1117.

Uno, H., Cai, T., Tian, L., and Wei, L.-J. (2007). Evaluating prediction rules for t-year survivors with censored regression models. *Journal of the American Statistical Association*, 102(478):527–537.

Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., Steyerberg, E. W., and Topic Group 'Evaluating diagnostic tests and prediction models' of the STRATOS initiative (2019). Calibration: the Achilles heel of predictive analytics. *BMC Medicine*, 17(1):230.

Varma, S. and Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91.

Vickers, A. J., Cronin, A. M., Elkin, E. B., and Gonen, M. (2008). Extensions to decision curve analysis, a novel method for evaluating diagnostic tests, prediction models and molecular markers. *BMC Medical Informatics and Decision Making*, 8:53.

Vickers, A. J. and Elkin, E. B. (2006). Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*, 26(6):565–574.