O aprendizado de máquina acrescenta valor ao modelo de Mayo?
Uma avaliação em análise de sobrevivência, com plano de análise prévio, na colangite biliar primária

Autoria omitida para revisão

[1]Afiliação omitida para revisão

Abstract. *The Mayo model, a five-variable Cox regression published in 1989, is the classic prognostic reference for primary biliary cholangitis. We asked whether random survival forests (RSF) or a penalized Cox model with 17 baseline variables add value over a Cox model with the five Mayo variables in predicting transplant-free survival at five years in the public Mayo Clinic cohort (418 patients, 186 events). The analysis plan, including a relevance margin of 0.02 in Uno's C, was committed before any result. Under nested 5×5 cross-validation with identical partitions, the reference reached a mean Uno's C of 0.833. Differences against it, with Bonferroni-adjusted paired bootstrap intervals, were +0.015 (−0.004 to 0.032) for the penalized Cox, −0.014 (−0.032 to 0.004) for the five-variable RSF and −0.001 (−0.022 to 0.0197) for the 17-variable RSF; gains of 0.02 or more were incompatible with the data for both forests. Calibration and net benefit were similar, and the conclusion held for death alone and across classification framings. Only using follow-up time as an input, which leaks the outcome, produced a consistent gain.*

Resumo. *O modelo de Mayo, uma regressão de Cox com cinco variáveis publicada em 1989, é a referência prognóstica clássica na colangite biliar primária. Este trabalho pergunta se random survival forests (RSF) ou um Cox penalizado com 17 variáveis de linha de base acrescentam valor a um Cox com as cinco variáveis de Mayo na predição da sobrevida livre de transplante em cinco anos, na coorte pública da Mayo Clinic (418 pacientes, 186 eventos). O plano de análise, com margem de relevância de 0,02 no C de Uno, foi registrado antes de qualquer resultado. Com validação cruzada aninhada 5×5 e as mesmas partições para todos os modelos, a referência teve C de Uno médio de 0,833. As diferenças em relação a ela, com intervalos bootstrap pareados e correção de Bonferroni, foram de +0,015 (−0,004 a 0,032) no Cox penalizado, −0,014 (−0,032 a 0,004) na RSF com 5 variáveis e −0,001 (−0,022 a 0,0197) na RSF com 17; ganhos de 0,02 ou mais foram incompatíveis com os dados para as duas florestas. Calibração e benefício líquido foram semelhantes, e a conclusão se manteve para óbito isolado e em enquadramentos de classificação. Só o uso do tempo de seguimento como entrada, que vaza o desfecho, produziu ganho consistente.*

1. Introdução

A colangite biliar primária (CBP), chamada de cirrose biliar primária até 2015 [Beuers et al. 2015], é uma doença hepática autoimune e crônica que destrói os pequenos

ductos biliares e pode evoluir para cirrose, insuficiência hepática e transplante. Estimar o risco individual na primeira avaliação ajuda a decidir a intensidade do acompanhamento e o momento de encaminhar o paciente ao transplante. Desde 1989 existe uma ferramenta para isso: o modelo de Mayo, uma regressão de Cox [Cox 1972] com cinco variáveis de rotina (idade, bilirrubina, albumina, tempo de protrombina e edema), derivada de dois ensaios clínicos da Mayo Clinic [Dickson et al. 1989].

Os dados desses ensaios são públicos e se tornaram um conjunto clássico, primeiro em análise de sobrevivência [Fleming and Harrington 1991] e depois em aprendizado de máquina (AM), no repositório da UCI [Dickson et al. 2023] e numa competição do Kaggle [Reade and Chow 2023]. Modelos de AM prometem mais precisão, mas trazem custos: perdem a transparência de uma fórmula de cinco termos e, quando usam mais variáveis, exigem mais exames. Por isso a pergunta útil para a prática não é se um modelo de AM é preciso, mas se ele acrescenta algo ao modelo já disponível, isto é, qual é o seu **valor incremental**. Uma revisão de 71 estudos não encontrou vantagem do AM sobre a regressão logística nas comparações com baixo risco de viés [Christodoulou et al. 2019].

Por que voltar a esses dados hoje? Porque eles continuam a servir de banco de provas para o AM em saúde, e conclusões otimistas continuam a ser publicadas sobre eles: a competição do Kaggle de 2023 gerou dados sintéticos a partir da coorte, trabalhos de 2025 relatam acurácias próximas de 90% nesse enquadramento [Shakir et al. 2025, Tu 2025], e um estudo do mesmo ano, nos 312 pacientes randomizados, relatou C de Harrell de 0,855 para uma RSF contra 0,776 para um Cox, com intervalos por modelo em geral sobrepostos e sem intervalo para a diferença [Graf et al. 2025]. Há dois obstáculos a uma comparação justa nesse conjunto. O primeiro é o enquadramento: muitos trabalhos tratam o problema como classificação, excluem quem foi censurado antes do horizonte ou usam o tempo de seguimento como entrada, o que vaza o desfecho [Kapoor and Narayanan 2023]. O segundo é a flexibilidade de análise: escolher métrica, modelos e critérios depois de ver os resultados torna fácil encontrar alguma vantagem.

Este trabalho pergunta se modelos de AM para sobrevivência acrescentam valor, em discriminação, calibração e utilidade clínica, a um Cox com as cinco variáveis de Mayo, na predição de óbito ou transplante em até cinco anos, e se um eventual ganho viria do algoritmo ou das variáveis extras. As contribuições são: (i) uma comparação 2×2 (Cox ou RSF; 5 ou 17 variáveis) em análise de sobrevivência, com todos os 418 pacientes, as mesmas partições para todos os modelos e o mesmo orçamento de busca para as duas florestas; (ii) um plano de análise registrado antes dos resultados, com margem de relevância e regra de leitura fixadas, e o registro público de todos os desvios; (iii) a demonstração de que a conclusão não muda entre enquadramentos, exceto quando o tempo de seguimento vaza para a entrada; e (iv) código, dados e resultados abertos.

2. Trabalhos relacionados

Os escores prognósticos de CBP são, em sua maioria, modelos de Cox. Depois do modelo de Mayo [Dickson et al. 1989], a adoção do ácido ursodesoxicólico levou a escores para pacientes tratados, como o GLOBE [Lammers et al. 2015] e o UK-PBC [Carbone et al. 2016], construídos com exames medidos após um ano de tratamento e, portanto, para outro momento e outra população. No conjunto da Mayo Clinic, os 312 pacientes randomizados foram um dos exemplos da proposta das RSF

[Ishwaran et al. 2008], que não tinha como foco o valor incremental sobre o modelo de Mayo.

O trabalho mais próximo deste é o de [Graf et al. 2025], que compara Cox e RSF nos 312 pacientes randomizados. O Cox usa sete variáveis escolhidas por seleção retroativa pelo critério de Akaike, a discriminação é medida pelo C de Harrell e a validação é feita por *bootstrap* .632+, com intervalos por modelo. A RSF teve valores pontuais melhores (C de 0,855 contra 0,776), mas os próprios autores registram que os intervalos se sobrepõem e não permitem conclusão definitiva, exceto para uma das seis regras de divisão avaliadas, cujo intervalo excluiu o valor do Cox; nas simulações, o Cox foi mais bem calibrado. O presente trabalho difere em quatro pontos: usa os 418 pacientes, toma como referência as cinco variáveis de Mayo, compara os modelos de forma pareada nas mesmas partições e fixa a margem de relevância antes dos resultados.

Os trabalhos recentes de AM sobre esse conjunto seguem o enquadramento da competição do Kaggle, cujos dados são sintéticos, gerados a partir do original [Reade and Chow 2023]. Eles classificam o desfecho em três classes ou em óbito sem horizonte e relatam acurácias próximas de 90%, sem avaliar calibração [Shakir et al. 2025, Tu 2025]. A calibração, que mede se as probabilidades previstas correspondem às observadas, é frequentemente omitida e já foi chamada de calcanhar de Aquiles da análise preditiva [Van Calster et al. 2019]. No levantamento feito, não se encontrou estudo que compare, nos mesmos pacientes e partições, AM de sobrevivência com o Cox de Mayo, avaliando discriminação, calibração e benefício líquido sob um plano prévio.

3. Materiais e métodos

O relato segue o TRIPOD+AI [Collins et al. 2024]. O plano de análise (desfechos, modelos, métricas, orçamento de ajuste, comparações e regra de leitura) foi registrado no controle de versões do repositório antes de qualquer resultado e não foi alterado. Toda mudança posterior está registrada em uma lista de desvios, resumida na Seção 3.6.

3.1. Dados e desfechos

O conjunto é o da Mayo Clinic, distribuído pela UCI (identificador 878, licença CC BY 4.0) [Dickson et al. 2023] e pelo pacote `survival` do R. Usou-se uma cópia versionada e verificada por SHA-256, idêntica à da UCI em todos os valores. São 418 pacientes recrutados entre 1974 e 1984: 312 participaram de dois ensaios randomizados sobre D-penicilamina, e 106 eram elegíveis mas recusaram a randomização (106 dos 112 que recusaram; os demais foram perdidos no seguimento), tendo só as medidas de rotina [Dickson et al. 1989, Fleming and Harrington 1991]. Cada paciente tem uma linha, com variáveis medidas no registro (linha de base), o desfecho (censura, óbito ou transplante) e o tempo até ele, em dias (`N_Days`).

O **desfecho principal** é a sobrevida livre de transplante: o evento é óbito ou transplante (186 pacientes, sendo 161 óbitos e 25 transplantes), e os 232 pacientes sem evento registrado até o último acompanhamento são censurados nesse momento. Óbito e transplante também compõem os desfechos dos escores atuais de CBP [Lammers et al. 2015, Carbone et al. 2016], e todos os 418 pacientes entram na análise. O horizonte de interesse é de cinco anos (1.826 dias), com 132 eventos até ele. Como

sensibilidade, o evento é só o óbito, e o transplante é tratado como censura (161 eventos). Os preditores são as 5 variáveis de Mayo ou as 17 de linha de base. O tempo de seguimento nunca é preditor, porque só é conhecido depois do desfecho.

3.2. Modelos

O desenho é 2×2. A **referência** é o Cox de riscos proporcionais com as cinco variáveis de Mayo, com bilirrubina, albumina e protrombina em logaritmo, como no modelo original, e sem penalização. É um modelo reestimado no treino de cada partição, e não a fórmula publicada em 1989, que além disso tratava o transplante como censura; ao longo do texto, "Cox de Mayo" designa esse modelo reestimado. Com as 17 variáveis, o Cox é penalizado por *elastic net* [Simon et al. 2011], com proporção L1 em $\{0{,}1;\ 0{,}5;\ 0{,}9;\ 1\}$ e 10 intensidades log-espaçadas entre 10^{-3} e 1. Os modelos de AM são RSF [Ishwaran et al. 2008] com 300 árvores e busca aleatória de 50 configurações (tamanho mínimo da folha, tamanho mínimo para divisão, variáveis por divisão e profundidade), com 5 e com 17 variáveis. O orçamento de ajuste é, portanto, de 50 configurações para cada floresta e de 40 combinações (a grade completa) para o Cox penalizado; a referência não tem hiperparâmetros a ajustar. Nos modelos de Cox, as transformações (logaritmo dos exames assimétricos, imputação pela mediana com 5 variáveis ou iterativa com 17, e padronização) são aprendidas só no treino de cada partição. Nas florestas, a imputação é feita na escala original, sem padronização. A implementação usa o scikit-survival [Pölsterl 2020].

3.3. Validação e métricas

A validação é cruzada, com 5 repetições de 5 partições estratificadas pelo indicador de evento, e as mesmas partições servem aos quatro modelos. Os hiperparâmetros são escolhidos por validação aninhada [Varma and Simon 2006], com 3 partições internas e critério igual ao da métrica principal. Cada modelo produz, para cada paciente, o risco previsto em cinco anos, $\hat{r}(\mathbf{x}) = 1 - \hat{S}(1.826 \mid \mathbf{x})$, em que $\hat{S}$ é a função de sobrevivência estimada. A predição fora da partição é a média das 5 repetições.

A **métrica principal** é o índice C de Uno truncado em cinco anos [Uno et al. 2011], calculado sobre $\hat{r}$: a probabilidade de que, entre dois pacientes, o que teve o evento antes (até cinco anos) tenha recebido o risco maior, com pesos pelo inverso da probabilidade de censura, o que corrige o viés do C de Harrell [Harrell et al. 1982] quando a censura é intensa. As métricas secundárias são a AUC dependente do tempo em cinco anos [Uno et al. 2007] e o escore de Brier em cinco anos e integrado de 1 a 5 anos, com a mesma ponderação [Graf et al. 1999]. Nas métricas por partição, a distribuição da censura é estimada por Kaplan-Meier no treino. A calibração em cinco anos compara, por quintis de risco previsto, o risco médio previsto com o risco observado por Kaplan-Meier, com intervalos de 95% (Greenwood, transformação log-log; num quintil sem eventos, limite superior binomial exato com o número em risco aos cinco anos), e resume a coorte pela razão observado/esperado (O/E). A utilidade clínica é avaliada por curva de decisão [Vickers and Elkin 2006], com o benefício líquido em cinco anos estimado com tratamento da censura por Kaplan-Meier [Vickers et al. 2008], em limiares de risco de 5% a 50%, de 1 em 1 ponto. A decisão hipotética é intensificar o acompanhamento, ou antecipar a avaliação para transplante, quando o risco previsto passa do limiar; o benefício líquido é a proporção de verdadeiros positivos menos a de falsos positivos ponderada pelo peso que o limiar atribui a cada um deles.

3.4. Valor incremental e regra de leitura

Para cada um dos três modelos contra a referência, calcula-se a diferença no C de Uno (principal) e na AUC em cinco anos sobre as predições fora da partição, com 2.000 reamostragens *bootstrap* pareadas de pacientes. Nessa análise, a distribuição da censura é estimada na coorte inteira e reestimada em cada reamostragem. Os intervalos usam a correção de Bonferroni para três comparações (nível de 98,3%). A leitura foi fixada no plano: "maior" ou "menor" só quando o intervalo exclui zero; e, se o limite superior ficar abaixo da **margem de relevância de +0,02** no C de Uno, ganhos dessa magnitude são declarados incompatíveis com os dados para aquele modelo. Esses intervalos são condicionais às predições obtidas: não incorporam a variação de refazer o treino e a seleção de hiperparâmetros. Essa variação aparece na dispersão da diferença entre as 25 partições.

3.5. Análises de apoio

Subgrupo independente. Os modelos são treinados nos 312 pacientes randomizados e testados nos 106 não randomizados (42 eventos). Nove das 17 variáveis faltam em todos os 106 e são reconstruídas pelo imputador do treino; por isso, com 17 variáveis, esse é um teste de transporte sob ausência estrutural, não uma validação externa. **Pressupostos da referência.** Um Cox descritivo, ajustado uma única vez nos 418 pacientes com as mesmas covariáveis e transformações da referência, fornece razões de risco em unidades clínicas e o teste de riscos proporcionais de [Grambsch and Therneau 1994], por variável, com correção de Bonferroni para 5 testes, no seguimento completo e censurado em cinco anos. Usou-se o *lifelines* [Davidson-Pilon 2019], que difere dos modelos preditivos em dois detalhes: trata empates pelo método de Efron e imputa os dois valores ausentes de protrombina antes do logaritmo. Formas funcionais e observações influentes não foram examinadas. **Importância por permutação** da RSF de 17 variáveis, fora da amostra: queda do C de Uno no teste ao permutar cada variável (30 permutações), nas 5 partições da primeira repetição. **Enquadramentos.** A Tabela 3 reúne quatro maneiras de formular a tarefa nos mesmos dados. As duas de classificação foram analisadas antes deste plano e estão documentadas no repositório: em (a), a regressão logística com as 5 variáveis é a referência, contra regressão penalizada, *random forest* e XGBoost; em (d), o mesmo XGBoost é ajustado com e sem o tempo de seguimento para prever as três classes do desfecho (censura, transplante e óbito).

3.6. Desvios do plano e reprodutibilidade

Dez desvios e complementações estão registrados, com data e motivo. O mais relevante surgiu de uma auditoria independente: na primeira execução, a busca de hiperparâmetros calculava o C de Uno sobre o escore nativo de cada modelo, enquanto a avaliação usava $\hat{r}$. No Cox as duas saídas ordenam os pacientes da mesma forma; na RSF, não. A segunda execução, aqui relatada, otimiza e avalia a mesma quantidade, e a primeira é citada como sensibilidade. Os demais desvios são complementações de detalhes (extremos da grade, sementes internas, verificação de suporte temporal), de apresentação (intervalos na calibração) e o detalhamento das análises de apoio, todos fixados antes dos resultados finais, exceto a regra de escolha do modelo exibido na Tabela 3, definida depois e declarada como tal. Duas entregas ficaram aquém do plano: no subgrupo, só o C de Uno e a AUC têm intervalos de confiança, sem intervalo pareado da diferença; e a importância por permutação foi calculada só para a RSF de 17 variáveis, na primeira repetição. O experimento

usa Python 3.13, scikit-learn 1.9.1, scikit-survival 0.28.0 e semente 2026 (nas partições internas, sementes derivadas de 2026 a 2050), e cada execução grava um manifesto com versões, commit e comando. Código, dados, plano, desvios, resultados e relatórios de auditoria estão em um repositório público[1]. Os dados são públicos e anonimizados, e o estudo é uma análise secundária, sem contato com participantes.

4. Resultados

4.1. Discriminação e valor incremental

A Tabela 1 resume o desempenho. A referência teve C de Uno médio de 0,833, e as diferenças em relação a ela ficaram entre −0,014 e +0,015, menores que a variação da própria diferença entre as 25 partições (desvios de 0,017 a 0,018). Nenhuma diferença foi estatisticamente demonstrada. Para as duas RSF, o limite superior do intervalo ficou abaixo da margem de +0,02, e ganhos dessa magnitude são incompatíveis com os dados. No caso da RSF de 17 variáveis, porém, essa conclusão depende da quarta casa decimal (limite de 0,0197); na primeira execução, com a busca desalinhada, o limite foi de 0,0209. Para o Cox penalizado, que teve a maior diferença nominal (+0,015, ganho em 68% das 25 partições), um ganho relevante não pode ser excluído. Na AUC em cinco anos, a RSF de 5 variáveis foi menor que a referência (−0,024; intervalo de −0,047 a −0,001), e as demais não diferiram. O Cox penalizado manteve entre 9 e 16 das 17 variáveis nos modelos escolhidos, e o C de Uno médio calculado sobre o escore nativo de cada modelo diferiu do da Tabela 1 em até 0,0012.

Tabela 1. Desempenho na validação cruzada 5×5, desfecho principal (418 pacientes, 186 eventos). Média (desvio entre as 25 partições); O/E com IC 95% por *bootstrap*; ΔC: diferença no C de Uno contra a referência, com IC de Bonferroni (98,3%).

Modelo	C de Uno	AUC 5 anos	Brier 5 anos	Brier integr.	O/E 5 anos	ΔC de Uno
Cox, 5 var. (referência)	0,833 (0,029)	0,889 (0,031)	0,128 (0,021)	0,102 (0,009)	0,99 (0,87 a 1,10)	–
Cox penalizado, 17 var.	0,846 (0,024)	0,903 (0,028)	0,132 (0,018)	0,104 (0,008)	0,93 (0,82 a 1,03)	0,0148 (−0,0042 a 0,0324)
RSF, 5 var.	0,821 (0,034)	0,869 (0,039)	0,143 (0,019)	0,107 (0,009)	0,99 (0,87 a 1,10)	−0,0136 (−0,0323 a 0,0042)
RSF, 17 var.	0,832 (0,028)	0,886 (0,031)	0,135 (0,015)	0,104 (0,008)	0,99 (0,88 a 1,11)	−0,0010 (−0,0220 a 0,0197)

Na sensibilidade com óbito como evento, o padrão se repetiu: a referência teve C de Uno de 0,854, e as diferenças foram de +0,010 (−0,006 a 0,026) no Cox penalizado, −0,013 (−0,031 a 0,003) na RSF de 5 variáveis e −0,007 (−0,029 a 0,014) na de 17, com ganhos de 0,02 incompatíveis com os dados para as duas florestas.

4.2. Calibração e utilidade clínica

A razão O/E ficou próxima de 1 em todos os modelos (0,93 a 0,99), mas esse resumo global não demonstra calibração semelhante, porque erros locais em sentidos opostos se

[1]Endereço anonimizado para a revisão: `https://anonymous.4open.science/r/ml4health-sbcas`.

compensam. Os quintis mostram padrões diferentes (Figura 1; os quatro modelos estão no material suplementar do repositório). Na referência, o risco previsto no quintil mais baixo (0,080) ficou acima do observado (0,036), mas dentro do seu intervalo (0,012 a 0,109). Na RSF de 17 variáveis, o previsto no quintil mais alto (0,712) ficou abaixo do observado (0,808), praticamente no limite inferior do intervalo (0,712 a 0,888), o que sugere compressão das probabilidades nos riscos altos. O padrão mais nítido foi o do Cox penalizado: nos dois quintis mais baixos, o risco previsto (0,127 e 0,202) ficou acima do limite superior do observado (0,054, sem eventos até cinco anos, e 0,171), e no mais alto (0,738), abaixo do limite inferior (0,748). Na curva de decisão (Figura 2), as estimativas de benefício líquido da referência e da RSF de 17 variáveis ficaram próximas nos 46 limiares (maior diferença absoluta de 0,015, ou 1,5 verdadeiro positivo líquido por 100 pacientes), ambas acima das estratégias de tratar todos e de não tratar ninguém. Sem intervalo para a diferença nem margem de equivalência, essa proximidade não demonstra utilidade equivalente.

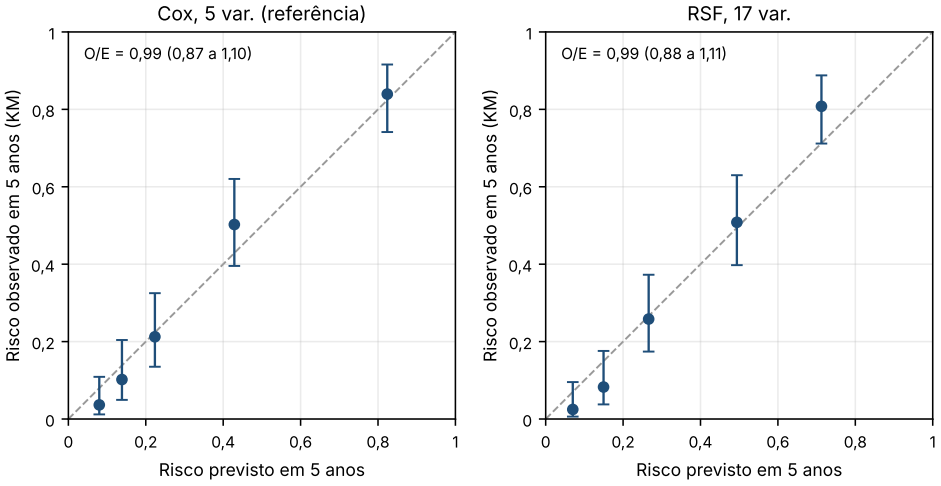


Figura 1. Calibração em cinco anos por quintis de risco previsto, na referência e na RSF de maior C de Uno médio (regra fixada antes da figura), sobre as predições fora da partição. Barras: IC 95% do Kaplan-Meier.

4.3. Subgrupo independente e pressupostos da referência

No teste nos 106 pacientes não randomizados, o C de Uno foi de 0,790 (0,718 a 0,857) na referência, 0,806 no Cox penalizado, 0,797 na RSF de 5 variáveis e 0,807 na de 17, com intervalos amplamente sobrepostos. As razões O/E foram de 1,05, 1,06, 1,12 e 1,16, respectivamente: as florestas subestimaram mais o risco nesse grupo. Como os intervalos não são pareados, esses números não sustentam comparações de superioridade.

A Tabela 2 mostra o ajuste descritivo da referência. As cinco variáveis se associaram ao desfecho na direção esperada. Houve evidência contra a proporcionalidade dos riscos para o tempo de protrombina, também dentro de cinco anos; para as demais variáveis, o teste não a detectou, o que não demonstra que o pressuposto valha para elas. A referência tem, portanto, ao menos uma variável cujo efeito parece variar no tempo e, mesmo assim, não foi superada pelas florestas, que não dependem desse pressuposto. Na importância por permutação da RSF de 17 variáveis, a bilirrubina dominou (queda de

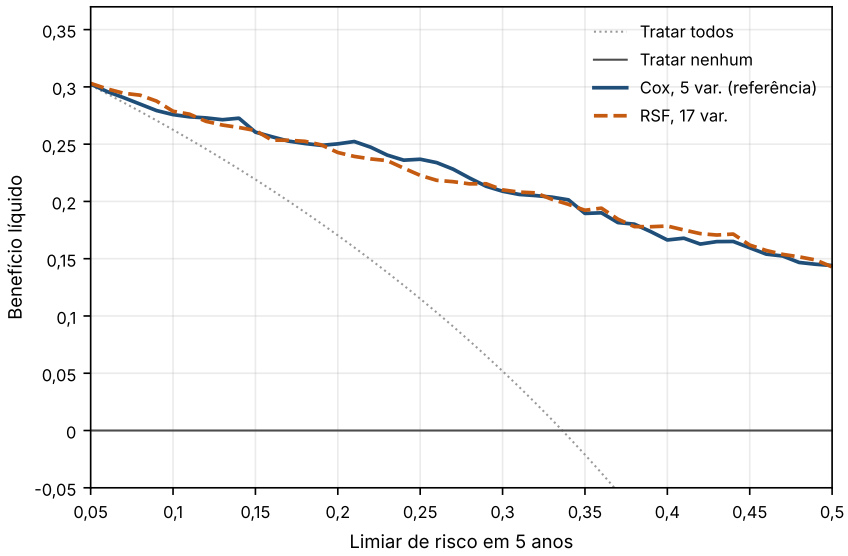


Figura 2. Curva de decisão em cinco anos, com censura tratada por Kaplan-Meier. A RSF exibida foi escolhida pelo maior C de Uno nesta mesma coorte, o que introduz seleção e pode tornar sua curva otimista.

0,128 no C de Uno), seguida de longe por cobre (0,019) e albumina (0,007); o tratamento não contribuiu.

Tabela 2. Ajuste descritivo do Cox de referência nos 418 pacientes: razão de risco (IC 95%) e valor p do teste de riscos proporcionais de Grambsch-Therneau (tempo transformado por Kaplan-Meier), corrigido por Bonferroni para 5 testes.

Variável	Razão de risco	p, todo o seguimento	p, até 5 anos
Idade (por 10 anos)	1,27 (1,10 a 1,46)	$>$ 0,99	$>$ 0,99
Bilirrubina (por duplicação)	1,79 (1,62 a 1,99)	0,689	0,202
Albumina (por duplicação)	0,16 (0,07 a 0,37)	$>$ 0,99	$>$ 0,99
Tempo de protrombina (por duplicação)	3,02 (1,11 a 8,23)	0,007	0,024
Edema (0 a 1)	2,32 (1,39 a 3,86)	$>$ 0,99	$>$ 0,99

4.4. O enquadramento muda a conclusão?

A Tabela 3 compara de forma descritiva as conclusões em quatro enquadramentos, mostrando em cada um o modelo com a maior diferença contra a referência, isto é, a escolha mais favorável ao AM. Os enquadramentos diferem em mais de um aspecto ao mesmo tempo, e a tabela não isola o efeito de nenhum deles: (a) e (c) têm o mesmo evento, mas diferem na tarefa, na amostra, na métrica e no comparador; (b) e (c) diferem só no desfecho. Em nenhuma das três primeiras linhas o intervalo exclui zero, e nelas o melhor resultado nominal veio de um modelo de regressão penalizada, não de árvores. A linha (d) responde a outra pergunta: com o mesmo modelo, incluir o tempo de seguimento como preditor elevou a AUROC macro em 0,034, com ganho em 24 das 25 partições, graças a uma informação indisponível no momento da predição. As métricas das linhas não estão na mesma escala, e a margem de 0,02 do C de Uno não se aplica às linhas de classificação.

Tabela 3. Conclusões em quatro enquadramentos da tarefa (comparação descritiva). Em (a) a (c), o modelo com maior diferença contra a referência, com IC de Bonferroni de 99% em (a) (5 comparações) e de 98,3% em (b) e (c) (3 comparações). Em (d), o mesmo XGBoost com e sem `N_Days`, diferença pareada por partição; os 161 eventos são os óbitos, numa classificação em três classes (232 censuras, 25 transplantes, 161 óbitos).

Enquadramento	n / eventos	Métrica	Modelo	Δ	IC
(a) Classificação de óbito em 5 anos, sem os censurados antes de 5 anos	312 / 115	AUROC	RL penalizada, 17 var.	0,009	−0,017 a 0,035
(b) Sobrevivência, óbito ou transplante (principal)	418 / 186	C de Uno	Cox penalizado, 17 var.	0,015	−0,004 a 0,032
(c) Sobrevivência, só óbito	418 / 161	C de Uno	Cox penalizado, 17 var.	0,010	−0,006 a 0,026
(d) Classificação C/CL/D, `N_Days` na entrada	418 / 161	AUROC macro	XGBoost, 17 var., com e sem `N_Days`	0,034	sem IC; ganho em 96% das partições

5. Discussão

O resultado principal é negativo e estável. Nenhum modelo superou o Cox de Mayo; para as duas RSF, ganhos de 0,02 ou mais no C de Uno são incompatíveis com os dados, e a calibração e o benefício líquido não mostram vantagem que a discriminação tenha escondido. A conclusão se repete com óbito isolado, no subgrupo independente e na formulação como classificação. Isso está de acordo com a revisão de [Christodoulou et al. 2019]. Com 186 eventos e um modelo de referência que já usa as transformações que tornam a relação aproximadamente linear, sobra pouco espaço para interações e não linearidades que uma floresta possa aprender, e a importância por permutação mostra que a informação se concentra na bilirrubina. Essa explicação é plausível, mas o desenho não a testa.

O contraste com [Graf et al. 2025] é instrutivo. Lá a RSF teve C de Harrell de 0,855 contra 0,776 do Cox. Aqui, o C de Harrell do Cox de referência foi de 0,814, e o da RSF de 17 variáveis, de 0,815. Os protocolos diferem em amostra (312 contra 418), referência (Cox com seleção de variáveis contra as cinco de Mayo), métrica, esquema de validação e ausência de intervalo para a diferença, e este trabalho não permite dizer qual desses fatores explica a diferença. O que ele mostra é que, sob um protocolo fixado antes dos resultados e com comparação pareada, a vantagem da RSF não aparece nestes dados. O mesmo vale para os números próximos de 90% de acurácia relatados no enquadramento do Kaggle [Shakir et al. 2025, Tu 2025], que não são comparáveis: outro desfecho, outros dados (sintéticos) e, num dos casos, balanceamento sintético aplicado antes da divisão entre treino e teste e, no outro, teste nos pacientes dos quais os dados de treino foram gerados, duas formas de vazamento [Kapoor and Narayanan 2023].

Duas observações merecem destaque. A primeira é que o melhor resultado nominal veio sempre de uma regressão penalizada com 17 variáveis, e, para ela, um ganho relevante não foi excluído; se as variáveis extras têm valor, os dados sugerem que um modelo linear as aproveita ao menos tão bem quanto as árvores, mas isso exigiria um estudo maior para ser afirmado. A segunda é que a evidência contra a proporcionalidade para a protrombina não veio acompanhada de vantagem para as florestas, que não dependem desse pressuposto. Uma leitura possível é que o impacto preditivo dessa violação no

horizonte de cinco anos seja pequeno, mas isso é uma hipótese que o desenho não testa.

Limitações. Os dados vêm de um único centro, de 1974 a 1984, antes do ácido ursodesoxicólico, e não representam os pacientes atuais; não houve coorte externa. Os intervalos do valor incremental são condicionais às predições e não incluem a variação do treino e da seleção de hiperparâmetros, de modo que a margem só é excluída nessa inferência. A ponderação pela censura supõe censura independente, estimada por Kaplan-Meier marginal, sem verificação de dependência em relação aos preditores. Na sensibilidade com óbito, o transplante é tratado como censura: o risco estimado é o de uma análise de causa específica, hipotético na ausência de transplante, e não a incidência cumulativa observável de óbito, que exigiria uma análise de riscos competitivos [Putter et al. 2007]. O teste no subgrupo, com 17 variáveis, mede transporte sob ausência estrutural. As famílias diferem também no pré-processamento (imputação em escalas diferentes), e o desenho 2×2 não isola de forma estrita o efeito do algoritmo. A conclusão sobre a margem na RSF de 17 variáveis é frágil, como mostram a quarta casa decimal e a primeira execução. O Brier integrado usa uma grade anual de cinco pontos. Por fim, a conclusão vale para os modelos, as grades e o orçamento de ajuste avaliados.

6. Conclusão

Na coorte pública da Mayo Clinic, sob um plano de análise registrado antes dos resultados, nem a RSF nem o Cox penalizado com 17 variáveis acrescentaram valor demonstrável ao Cox com as cinco variáveis de Mayo na predição da sobrevida livre de transplante em cinco anos. Para as florestas, ganhos de 0,02 ou mais no C de Uno são incompatíveis com os dados, e calibração e benefício líquido foram semelhantes. A conclusão se manteve entre desfechos e enquadramentos; só o uso do tempo de seguimento como entrada produziu ganho, e esse ganho é vazamento. A continuidade natural é repetir a comparação em coortes atuais de pacientes tratados, em que GLOBE e UK-PBC são as referências, com análise de riscos competitivos, mantendo a pergunta que orientou este trabalho: quanto o novo modelo acrescenta ao que a clínica já usa, e a que custo.

Declaração de uso de inteligência artificial generativa

Ferramentas de IA generativa foram usadas sob supervisão da autoria. O Claude (Anthropic) apoiou a escrita do código de análise, a execução dos experimentos e a redação do texto. O Codex (OpenAI) atuou como auditor independente do código e das conclusões, sem permissão para alterar o repositório, e seus relatórios estão no repositório. O ChatGPT (OpenAI) foi usado na revisão do texto. Todas as decisões de desenho, a interpretação dos resultados e o conteúdo final são de responsabilidade da autoria, que conferiu os números contra os arquivos de resultados.

Referências

Beuers, U., Gershwin, M. E., Gish, R. G., et al. (2015). Changing nomenclature for PBC: from “cirrhosis” to “cholangitis”. *Hepatology*, 62(5):1620–1622.

Carbone, M., Sharp, S. J., Flack, S., et al. (2016). The UK-PBC risk scores: derivation and validation of a scoring system for long-term prediction of end-stage liver disease in primary biliary cholangitis. *Hepatology*, 63(3):930–950.

Christodoulou, E., Ma, J., Collins, G. S., Steyerberg, E. W., Verbakel, J. Y., and Van Calster, B. (2019). A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *Journal of Clinical Epidemiology*, 110:12–22.

Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.

Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2):187–220.

Davidson-Pilon, C. (2019). lifelines: survival analysis in Python. *Journal of Open Source Software*, 4(40):1317.

Dickson, E., Grambsch, P., Fleming, T., Fisher, L., and Langworthy, A. (2023). Cirrhosis patient survival prediction. UCI Machine Learning Repository, `https://doi.org/10.24432/C5R02G`.

Dickson, E. R., Grambsch, P. M., Fleming, T. R., Fisher, L. D., and Langworthy, A. (1989). Prognosis in primary biliary cirrhosis: model for decision making. *Hepatology*, 10(1):1–7.

Fleming, T. R. and Harrington, D. P. (1991). *Counting Processes and Survival Analysis*. John Wiley & Sons, New York.

Graf, E., Schmoor, C., Sauerbrei, W., and Schumacher, M. (1999). Assessment and comparison of prognostic classification schemes for survival data. *Statistics in Medicine*, 18(17–18):2529–2545.

Graf, R., Todd, S., and Baksh, M. F. (2025). Comparison of the Cox proportional hazards model and Random Survival Forest algorithm for predicting patient-specific survival probabilities in clinical trial data. arXiv:2502.03119.

Grambsch, P. M. and Therneau, T. M. (1994). Proportional hazards tests and diagnostics based on weighted residuals. *Biometrika*, 81(3):515–526.

Harrell, F. E., Califf, R. M., Pryor, D. B., Lee, K. L., and Rosati, R. A. (1982). Evaluating the yield of medical tests. *JAMA*, 247(18):2543–2546.

Ishwaran, H., Kogalur, U. B., Blackstone, E. H., and Lauer, M. S. (2008). Random survival forests. *The Annals of Applied Statistics*, 2(3):841–860.

Kapoor, S. and Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804.

Lammers, W. J., Hirschfield, G. M., Corpechot, C., et al. (2015). Development and validation of a scoring system to predict outcomes of patients with primary biliary cirrhosis receiving ursodeoxycholic acid therapy. *Gastroenterology*, 149(7):1804–1812.e4.

Pölsterl, S. (2020). scikit-survival: a library for time-to-event analysis built on top of scikit-learn. *Journal of Machine Learning Research*, 21(212):1–6.

Putter, H., Fiocco, M., and Geskus, R. B. (2007). Tutorial in biostatistics: competing risks and multi-state models. *Statistics in Medicine*, 26(11):2389–2430.

Reade, W. and Chow, A. (2023). Multi-class prediction of cirrhosis outcomes. Kaggle, Playground Series, Season 3, Episode 26, https://kaggle.com/competitions/playground-series-s3e26.

Shakir, Y. H., Mandhari, E. A. A. A., and Alkhazraji, A. (2025). Leveraging machine learning for early risk prediction in cirrhosis outcome patients. *Public Research Journal of Engineering, Data Technology and Computer Science*, 3(1):22–30.

Simon, N., Friedman, J., Hastie, T., and Tibshirani, R. (2011). Regularization paths for Cox's proportional hazards model via coordinate descent. *Journal of Statistical Software*, 39(5):1–13.

Tu, T. E. (2025). Predicting cirrhosis patient survival utilizing machine learning techniques. Master's thesis, University of California, Los Angeles.

Uno, H., Cai, T., Pencina, M. J., D'Agostino, R. B., and Wei, L.-J. (2011). On the C-statistics for evaluating overall adequacy of risk prediction procedures with censored survival data. *Statistics in Medicine*, 30(10):1105–1117.

Uno, H., Cai, T., Tian, L., and Wei, L.-J. (2007). Evaluating prediction rules for t-year survivors with censored regression models. *Journal of the American Statistical Association*, 102(478):527–537.

Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., and Steyerberg, E. W. (2019). Calibration: the Achilles heel of predictive analytics. *BMC Medicine*, 17:230.

Varma, S. and Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91.

Vickers, A. J., Cronin, A. M., Elkin, E. B., and Gonen, M. (2008). Extensions to decision curve analysis, a novel method for evaluating diagnostic tests, prediction models and molecular markers. *BMC Medical Informatics and Decision Making*, 8:53.

Vickers, A. J. and Elkin, E. B. (2006). Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*, 26(6):565–574.